

# **PROBABILIDAD Y APLICACIONES ESTADISTICAS**

**Paul L. Meyer**

Departamento de Matemáticas  
Washington State University

*Versión en español por*

**Carlos Prado Campos**

Departamento de Estadística  
Instituto de Matemáticas  
Universidad Católica de Chile

*Con la colaboración de*

**Germán Ardila Cuéllar**

Departamento de Matemáticas y Estadística  
Universidad Nacional de Colombia



**ADDISON-WESLEY IBEROAMERICANA**

Argentina • Brasil • Chile • Colombia • Ecuador • España  
Estados Unidos • México • Perú • Puerto Rico • Venezuela

## Prefacio a la primera edición

Este texto está destinado para un curso de un semestre o para dos cursos trimestrales de introducción a la teoría de la probabilidad y algunas de sus aplicaciones. El prerrequisito es un año de cálculo diferencial e integral. No se supone conocimiento previo de probabilidad o estadística. En la Washington State University, el curso para el cual este texto fue desarrollado ha sido enseñado durante varios años y, principalmente, a estudiantes graduándose en ingeniería o en ciencias naturales. La mayoría de tales estudiantes sólo pueden dedicar un semestre al estudio de esta materia. Sin embargo, como esos estudiantes están familiarizados con el cálculo, pueden empezar dicho estudio más allá del nivel estrictamente elemental.

Muchos temas matemáticos pueden ser presentados a diversos grados de dificultad, y esto es realmente cierto de la probabilidad. En este texto se pretende aprovechar la ventaja que suponen los conocimientos matemáticos del lector, sin sobrepasarlos. Se usa en él un lenguaje matemático preciso, pero se tiene cuidado de no llegar a profundizar demasiado en detalles matemáticos innecesarios. Este no es ciertamente un «libro de cocina». Aunque se presentan y exponen varios conceptos de una manera informal, las definiciones y los teoremas son enunciados cuidadosamente. Si no es posible o deseable una demostración detallada de un teorema, al menos se da un bosquejo de las ideas más importantes. Una de las características distintivas de este texto son las «observaciones» que siguen a la mayoría de los teoremas y definiciones; en ellas, el resultado particular o el concepto presentado es examinado desde un punto de vista intuitivo.

Debido a la restricción autoimpuesta de escribir un texto relativamente breve sobre una materia que abarca una extensa área, hubo necesidad de seleccionar en relación con la inclusión o exclusión de ciertos temas. Parece ser que no hay manera obvia de resolver este problema. Ciertamente, yo no sostengo que, para algunos de los temas excluidos, no se podría haber encontrado sitio; ni pretendo que ningún material podía haber sido omitido. Sin embargo, se ha hecho hincapié en gran parte en las nociones fundamentales, presentadas con detalle considerable. Solamente el capítulo 11, sobre confiabilidad, puede ser considerado «artículo de lujo»; pero, aun aquí, creo que las nociones asociadas con problemas de confiabilidad son de interés para muchas personas. Además, los conceptos de confiabilidad son un medio excelente para ilustrar muchas de las ideas presentadas anteriormente en el libro.

Aun si se piensa que la extensión ha sido limitada por el tiempo disponible, se ha logrado una selección amplia y razonable de temas. Una ojeada al Índice general muestra de manera evidente que unas tres cuartas partes del texto trata de temas probabilísticos mientras la cuarta parte está dedicada a una exposición de inferencia estadística. Aunque no hay nada de extraordinario en esta división particular del énfasis entre probabilidad y estadística, creo que un conocimiento profundo de los principios básicos de la probabilidad es imperativo para una comprensión propia de los métodos estadísticos. Idealmente, un curso en probabilidad debería ser seguido por otro en teoría estadística y metodología; sin embargo, como indiqué anteriormente, la mayoría de los estudiantes que toman este curso no tienen tiempo para dos semestres de exposición con estas materias y, por tanto, me sentí obligado

a exponer al menos algunos de los aspectos más importantes en el área general de la inferencia estadística.

El éxito potencial de una presentación particular de la materia no debería ser juzgado solamente en función de las ideas específicas aprendidas y de las técnicas específicas adquiridas; el juicio final debe tener en cuenta también si el estudiante está bien preparado para continuar estudiando el tema bien por sí mismo o por medio de un curso formal adicional. Si se considera que este criterio es importante, se hace evidente que debiera insistirse en los conceptos básicos y en las técnicas fundamentales, relegando al mismo tiempo los métodos y temas muy especializados a un papel secundario. Esto también resultó ser un factor importante en la decisión sobre temas a incluir.

Es difícil exagerar la importancia de la teoría de la probabilidad. El modelo matemático apropiado para el estudio de un gran número de fenómenos observables es probabilístico en vez de determinístico. Además, el tema completo de la inferencia estadística está basado en consideraciones probabilísticas. Las técnicas estadísticas se cuentan entre algunas de las herramientas más importantes de científicos e ingenieros. Para poder utilizar esas técnicas inteligentemente es necesaria una profunda comprensión de los conceptos probabilísticos.

Se espera que, además de familiarizarse con muchos métodos específicos y conceptos, el lector desarrolle cierto criterio: pensar probabilísticamente sustituyendo preguntas tales como: «¿Durante cuánto tiempo funcionará este mecanismo?» por «¿Cuál es la probabilidad de que este mecanismo funcione durante más de cien horas?». En muchas situaciones, la segunda pregunta puede no sólo ser la más atinada sino, de hecho, la única pertinente.

Tradicionalmente, muchos de los conceptos importantes de la probabilidad han sido ilustrados con la ayuda de varios «juegos de azar»: lanzar monedas o dados, sacar cartas de una baraja, hacer girar una ruleta, etc. Aunque yo no he evitado por completo referirme a tales juegos, porque sirven para ilustrar bien nociones básicas, he intentado poner al estudiante con ilustraciones más pertinentes de las aplicaciones de la probabilidad: la emisión de partículas  $\alpha$  de una fuente radiactiva, muestreo de lote, la duración de instrumentos electrónicos y los problemas asociados de mecanismos y confiabilidad del sistema, etc.

Estoy reacio a mencionar una de las características más importantes en cualquier texto de matemáticas: los problemas; y, sin embargo, puede valer la pena señalar que el trabajar con problemas debe ser considerado parte integrante del curso. Sólo mediante el acto personal de plantear y resolver los ejercicios puede el estudiante desarrollar una comprensión y apreciación de las ideas, así como familiarizarse con las técnicas pertinentes. Es por eso que más de 330 problemas se han incluido en el texto y las respuestas a más de la mitad de ellos figuran al final del libro.

Este libro ha sido escrito en una manera bastante consecutiva: la comprensión de la mayoría de los capítulos requiere familiaridad con los anteriores; sin embargo, es posible tratar superficialmente con los capítulos 10 y 11 si se está interesado, en particular, en dedicar más tiempo a las aplicaciones estadísticas examinadas en los capítulos 13 a 15.

Como debe suceder a quienquiera que escribe un texto, debo estar agradecido a muchas personas: a mis colegas, por muchas conversaciones estimulantes y útiles; a mis propios profesores, por el conocimiento del tema y su interés en él; a los revisores de las primeras versiones del manuscrito, por sus muchas sugerencias útiles y críticas; a Addison-Wesley Publishing Company, por su gran ayuda y cooperación desde las primeras etapas de este proyecto hasta su finalización; a la señorita Carol Sloan, por ser una mecanógrafa muy eficiente y activa; a D. Van Nostrand, Inc., The Free Press, Inc. y Macmillan Publishing Company, por sus permisos para reproducir las tablas 3, 6 y 1, respectivamente; a McGraw-Hill Book Company, Inc., Oxford University Press, Inc., Pergamon Press, Ltd. y Prentice-Hall, Inc., por sus permisos para incluir ciertos ejemplos en el texto; y, finalmente, a mi esposa,

no sólo por la paciencia mantenida durante el esfuerzo sino también «por dejarme» y llevarse a nuestros dos hijos a visitar a sus abuelos durante dos cruciales meses de verano, durante los cuales pude convertir nuestro hogar en un taller desordenado pero tranquilo, del cual emergió milagrosamente la última, final, versión de este libro.

*Pullman, Washington*

PAUL L. MEYER

## Prefacio a la segunda edición

En vista del considerable número de comentarios favorables que he recibido tanto de estudiantes como de profesores que han utilizado la primera edición de este libro, se han hecho en él relativamente pocos cambios. Durante mi propio repetido uso del texto he encontrado que su organización básica y el nivel general de presentación (p. ej.: la mezcla de argumentos matemáticos rigurosos con presentaciones y ejemplos más informales) son los más apropiados para el tipo de estudiante que toma este curso.

Sin embargo, se han hecho varios cambios y adiciones. En primer lugar se hizo un esfuerzo para eliminar varias erratas de imprenta y otros errores que aparecieron en la primera edición. El autor está muy agradecido a los muchos lectores que, no sólo descubrieron algunos de ellos, sino que se interesaron lo suficiente como para indicármelos.

En segundo lugar se intentó hacer más claras las relaciones entre varias distribuciones de probabilidades, de modo que el estudiante pueda conseguir una comprensión mayor de cómo usar varios modelos probabilísticos para aproximarlos entre sí.

Finalmente, algunos problemas nuevos han sido añadidos a la ya larga lista incluida en la primera edición.

El autor desea agradecer nuevamente a Addison-Wesley Publishing Company su cooperación en todos los aspectos que condujeron a esta nueva edición.

*Pullman, Washington*

P. L. M.

## Índice general

|                   |                                                                                  |    |
|-------------------|----------------------------------------------------------------------------------|----|
| <b>Capítulo 1</b> | <b>Introducción a la probabilidad</b>                                            |    |
| 1.1               | Modelos matemáticos . . . . .                                                    | 1  |
| 1.2               | Introducción a los conjuntos . . . . .                                           | 3  |
| 1.3               | Ejemplos de experimentos no determinísticos . . . . .                            | 7  |
| 1.4               | El espacio muestral . . . . .                                                    | 8  |
| 1.5               | Sucesos . . . . .                                                                | 10 |
| 1.6               | Frecuencia relativa . . . . .                                                    | 12 |
| 1.7               | Nociones básicas de probabilidad . . . . .                                       | 13 |
| 1.8               | Varias observaciones . . . . .                                                   | 16 |
|                   | Problemas . . . . .                                                              | 18 |
| <b>Capítulo 2</b> | <b>Espacios muestrales finitos</b>                                               |    |
| 2.1               | El espacio muestral finito . . . . .                                             | 21 |
| 2.2               | Resultados igualmente probables . . . . .                                        | 22 |
| 2.3               | Métodos de enumeración . . . . .                                                 | 24 |
|                   | Problemas . . . . .                                                              | 31 |
| <b>Capítulo 3</b> | <b>Probabilidad condicional e independencia</b>                                  |    |
| 3.1               | Probabilidad condicional . . . . .                                               | 34 |
| 3.2               | Teorema de Bayes . . . . .                                                       | 40 |
| 3.3               | Sucesos independientes . . . . .                                                 | 42 |
| 3.4               | Consideraciones esquemáticas; probabilidad condicional e independencia . . . . . | 48 |
|                   | Problemas . . . . .                                                              | 50 |
| <b>Capítulo 4</b> | <b>Variables aleatorias unidimensionales</b>                                     |    |
| 4.1               | Noción general de una variable aleatoria . . . . .                               | 55 |
| 4.2               | Variables aleatorias discretas . . . . .                                         | 60 |
| 4.3               | La distribución binomial . . . . .                                               | 63 |
| 4.4               | Variables aleatorias continuas . . . . .                                         | 67 |
| 4.5               | Función de distribución acumulativa . . . . .                                    | 71 |
| 4.6               | Distribuciones mixtas . . . . .                                                  | 75 |
| 4.7               | Variables aleatorias distribuidas uniformemente . . . . .                        | 76 |
| 4.8               | Una observación . . . . .                                                        | 77 |
|                   | Problemas . . . . .                                                              | 78 |

|                                                                                                |     |
|------------------------------------------------------------------------------------------------|-----|
| <b>Capítulo 5 Funciones de variables aleatorias</b>                                            |     |
| 5.1 Un ejemplo . . . . .                                                                       | 83  |
| 5.2 Sucesos equivalentes . . . . .                                                             | 83  |
| 5.3 Variables aleatorias discretas . . . . .                                                   | 86  |
| 5.4 Variables aleatorias continuas . . . . .                                                   | 88  |
| Problemas . . . . .                                                                            | 93  |
| <b>Capítulo 6 Variables aleatorias bidimensionales y de mayor dimensión</b>                    |     |
| 6.1 Variables aleatorias bidimensionales . . . . .                                             | 95  |
| 6.2 Distribuciones de probabilidades marginales y condicionales . . . . .                      | 101 |
| 6.3 Variables aleatorias independientes . . . . .                                              | 105 |
| 6.4 Funciones de una variable aleatoria . . . . .                                              | 108 |
| 6.5 Distribuciones del producto y el cociente de variables aleatorias independientes . . . . . | 112 |
| 6.6 Variables aleatorias n-dimensionales . . . . .                                             | 114 |
| Problemas . . . . .                                                                            | 117 |
| <b>Capítulo 7 Otras características de las variables aleatorias</b>                            |     |
| 7.1 El valor esperado de una variable aleatoria . . . . .                                      | 120 |
| 7.2 Esperanza de una función de una variable aleatoria . . . . .                               | 126 |
| 7.3 Variables aleatorias bidimensionales . . . . .                                             | 131 |
| 7.4 Propiedades del valor esperado . . . . .                                                   | 132 |
| 7.5 La varianza de una variable aleatoria . . . . .                                            | 138 |
| 7.6 Propiedades de la varianza de una variable aleatoria . . . . .                             | 140 |
| 7.7 Expresiones aproximadas para la esperanza y la varianza . . . . .                          | 143 |
| 7.8 Desigualdad de Chebyshev . . . . .                                                         | 146 |
| 7.9 El coeficiente de correlación . . . . .                                                    | 148 |
| 7.10 Esperanza condicional . . . . .                                                           | 152 |
| 7.11 Regresión del promedio . . . . .                                                          | 154 |
| Problemas . . . . .                                                                            | 158 |
| <b>Capítulo 8 La variable aleatoria de Poisson y otras variables aleatorias</b>                |     |
| 8.1 La distribución de Poisson . . . . .                                                       | 164 |
| 8.2 La distribución de Poisson como una aproximación a la distribución binomial . . . . .      | 165 |
| 8.3 El proceso de Poisson . . . . .                                                            | 170 |
| 8.4 La distribución geométrica . . . . .                                                       | 175 |
| 8.5 La distribución de Pascal . . . . .                                                        | 178 |
| 8.6 Relación entre las distribuciones binomial y de Pascal . . . . .                           | 179 |
| 8.7 La distribución hipergeométrica . . . . .                                                  | 180 |
| 8.8 La distribución multinomial . . . . .                                                      | 181 |
| Problemas . . . . .                                                                            | 183 |
| <b>Capítulo 9 Algunas variables aleatorias continuas importantes</b>                           |     |
| 9.1 Introducción . . . . .                                                                     | 187 |
| 9.2 La distribución normal . . . . .                                                           | 187 |
| 9.3 Propiedades de la distribución normal . . . . .                                            | 188 |
| 9.4 Tabulación de la distribución normal . . . . .                                             | 191 |
| 9.5 La distribución exponencial . . . . .                                                      | 195 |

|                                                                                                    |     |
|----------------------------------------------------------------------------------------------------|-----|
| 9.6 Propiedades de la distribución exponencial . . . . .                                           | 196 |
| 9.7 La distribución gama . . . . .                                                                 | 199 |
| 9.8 Propiedades de la distribución gama . . . . .                                                  | 201 |
| 9.9 La distribución de $\chi$ -cuadrado . . . . .                                                  | 203 |
| 9.10 Comparación entre varias distribuciones . . . . .                                             | 205 |
| 9.11 La distribución normal bivariada . . . . .                                                    | 206 |
| 9.12 Distribuciones truncadas . . . . .                                                            | 208 |
| Problemas . . . . .                                                                                | 212 |
| <b>Capítulo 10 La función generadora de momentos</b>                                               |     |
| 10.1 Introducción . . . . .                                                                        | 217 |
| 10.2 La función generadora de momentos . . . . .                                                   | 218 |
| 10.3 Ejemplos de funciones generadoras de momentos . . . . .                                       | 219 |
| 10.4 Propiedades de la función generadora de momentos . . . . .                                    | 221 |
| 10.5 Propiedades reproductivas . . . . .                                                           | 225 |
| 10.6 Sucesiones de variables aleatorias . . . . .                                                  | 229 |
| 10.7 Nota final . . . . .                                                                          | 230 |
| Problemas . . . . .                                                                                | 230 |
| <b>Capítulo 11 Aplicaciones a la teoría de la confiabilidad</b>                                    |     |
| 11.1 Conceptos básicos . . . . .                                                                   | 233 |
| 11.2 La ley normal de fallas . . . . .                                                             | 236 |
| 11.3 La ley exponencial de fallas . . . . .                                                        | 237 |
| 11.4 La ley exponencial de fallas y la distribución de Poisson . . . . .                           | 240 |
| 11.5 La ley de fallas de Weibull . . . . .                                                         | 242 |
| 11.6 Confiabilidad de los sistemas . . . . .                                                       | 243 |
| Problemas . . . . .                                                                                | 247 |
| <b>Capítulo 12 Sumas de variables aleatorias</b>                                                   |     |
| 12.1 Introducción . . . . .                                                                        | 252 |
| 12.2 La ley de los grandes números . . . . .                                                       | 252 |
| 12.3 Aproximación normal a la distribución binomial . . . . .                                      | 255 |
| 12.4 El teorema del límite central . . . . .                                                       | 259 |
| 12.5 Otras distribuciones aproximadas por la distribución normal: Poisson, Pascal y gama . . . . . | 264 |
| 12.6 La distribución de la suma de un número finito de variables aleatorias . . . . .              | 265 |
| Problemas . . . . .                                                                                | 270 |
| <b>Capítulo 13 Muestras y distribuciones muestrales</b>                                            |     |
| 13.1 Introducción . . . . .                                                                        | 273 |
| 13.2 Muestras aleatorias . . . . .                                                                 | 274 |
| 13.3 Estadígrafos . . . . .                                                                        | 277 |
| 13.4 Algunos estadígrafos importantes . . . . .                                                    | 277 |
| 13.5 La transformación integral . . . . .                                                          | 284 |
| Problemas . . . . .                                                                                | 287 |
| <b>Capítulo 14 Estimación de los parámetros</b>                                                    |     |
| 14.1 Introducción . . . . .                                                                        | 290 |
| 14.2 Criterios para estimadores . . . . .                                                          | 291 |
| 14.3 Algunos ejemplos . . . . .                                                                    | 294 |

|                                                |                                                                          |     |
|------------------------------------------------|--------------------------------------------------------------------------|-----|
| 14.4                                           | Estimadores de máxima verosimilitud . . . . .                            | 298 |
| 14.5                                           | El método de los mínimos cuadrados . . . . .                             | 307 |
| 14.6                                           | El coeficiente de correlación . . . . .                                  | 310 |
| 14.7                                           | Intervalos de confianza . . . . .                                        | 311 |
| 14.8                                           | La distribución <i>t</i> de Student . . . . .                            | 313 |
| 14.9                                           | Más sobre los intervalos de confianza . . . . .                          | 315 |
|                                                | Problemas . . . . .                                                      | 319 |
| <b>Capítulo 15</b>                             | <b>Docimasia de hipótesis</b>                                            |     |
| 15.1                                           | Introducción . . . . .                                                   | 324 |
| 15.2                                           | Formulación general: distribución normal con varianza conocida . . . . . | 329 |
| 15.3                                           | Ejemplos adicionales . . . . .                                           | 333 |
| 15.4                                           | Dócima para la bondad de ajuste . . . . .                                | 336 |
|                                                | Problemas . . . . .                                                      | 343 |
| Referencias . . . . .                          |                                                                          | 346 |
| Apéndice . . . . .                             |                                                                          | 348 |
| Respuestas a problemas seleccionados . . . . . |                                                                          | 362 |
| Índice de materias . . . . .                   |                                                                          | 368 |

## Introducción a la probabilidad

### 1.1 Modelos matemáticos

En este capítulo se tratará el tipo de fenómeno de que nos ocuparemos en este libro. Además, formularemos un modelo matemático que nos servirá para investigar, en forma bastante precisa, este fenómeno.

Al principio es muy importante distinguir entre el fenómeno observable en sí mismo y el modelo matemático para dicho fenómeno. Evidentemente, no influimos en manera alguna sobre lo que observamos; sin embargo, al elegir un modelo, sí podemos aplicar nuestro juicio crítico. Esto ha sido muy bien expresado por el Profesor J. Neyman, quien escribió\*:

«Cada vez que utilizamos las matemáticas con el objeto de estudiar fenómenos observables es indispensable empezar por construir un modelo matemático (determinístico o probabilístico) para estos fenómenos. Necesariamente, este modelo debe simplificar las cosas y permitir la omisión de ciertos detalles. El éxito del modelo depende de si los detalles que se omitieron tienen o no importancia en el desarrollo de los fenómenos estudiados. La solución del problema matemático puede ser correcta y aún así estar muy en desacuerdo con los datos observados, debido sencillamente a que no estaba probada la validez de las suposiciones básicas que se hicieron. Corrientemente, es bastante difícil afirmar con certeza si un modelo matemático es adecuado o no, *antes* de obtener algunos datos, mediante la observación. Para verificar la validez del modelo, debemos *deducir* un cierto número de consecuencias del mismo y luego comparar con las observaciones esos resultados *predichos*».

Tendremos presentes las ideas anteriores mientras estemos considerando algunos fenómenos obtenidos en la observación y los modelos apropiados para su descripción. Examinemos primero lo que podría llamarse adecuadamente *un modelo determinístico*. Así designamos al modelo que estipula que las condiciones bajo las cuales se verifica un experimento determinan el resultado del mismo. Por ejemplo, si colocamos una batería en un circuito simple, el modelo matemático que posiblemente describiría el flujo observable de corriente sería  $I = E/R$ , que es la ley de Ohm. El modelo predice el valor de  $I$  tan pronto como se dan

\* *University of California Publications in Statistics*, Vol. I, University of California Press, 1954.

3.35. En una ciudad se publican los periódicos  $A$ ,  $B$  y  $C$ . Una encuesta reciente de lectores indica lo siguiente: 20 por ciento lee  $A$ , 16 por ciento lee  $B$ , 14 por ciento lee  $C$ , 8 por ciento lee  $A$  y  $B$ , 5 por ciento lee  $A$  y  $C$ , y 2 por ciento lee  $A$ ,  $B$  y  $C$ . Para un adulto escogido al azar, calcular la probabilidad de que (a) no lea ninguno de los periódicos (b) lea exactamente uno de los periódicos (c) lea al menos  $A$  y  $B$  si se sabe que lee al menos uno de los periódicos publicados.

3.36. Una moneda normal se lanza  $2n$  veces.

- (a) Obtener la probabilidad de que haya un número igual de caras y sellos.
- (b) Verificar que la probabilidad calculada en (a) es una función decreciente de  $n$ .

3.37. Cada una de las urnas 1, urna 2, ..., urna  $n$ , contiene  $\alpha$  esferas blancas y  $\beta$  esferas negras. Se pasa una esfera de la urna 1 a la urna 2 y luego se pasa una de la urna 2 a la urna 3, etc. Finalmente, se escoge una esfera de la urna  $n$ . Si la primera esfera que se pasó era blanca, ¿cuál es la probabilidad de que la última esfera elegida sea blanca? ¿Qué sucede cuando  $n \rightarrow \infty$ ? [Indicación: sea  $p_n = \text{Prob}(n\text{-ésima esfera pasada sea blanca})$  y exprese  $p_n$  en función de  $p_{n-1}$ .]

3.38. La urna 1 contiene  $\alpha$  esferas blancas y  $\beta$  esferas negras mientras que una urna 2 contiene  $\alpha$  esferas blancas y  $\beta$  negras. Se escoge una esfera (de una de las urnas) y luego se devuelve a esa urna. Si la esfera escogida es blanca, se escoge la esfera siguiente de la urna 1; si la esfera escogida es negra, se escoge la siguiente de la urna 2. Continúe de esta manera. Como la primera esfera escogida proviene de la urna 1, obtener  $\text{Prob}(n\text{-ésima esfera escogida sea blanca})$  y también el límite de esta probabilidad cuando  $n \rightarrow \infty$ .

3.39. Una máquina impresora puede imprimir  $n$  «letras», digamos  $\alpha_1, \dots, \alpha_n$ . Esta máquina es operada por impulsos eléctricos y cada letra es producida por un impulso diferente. Supóngase que exista una probabilidad constante  $p$  de imprimir la letra correcta y también suponga independencia. Uno de los  $n$  impulsos, escogido al azar, alimentó la máquina dos veces y las dos veces se imprimió la letra  $\alpha_1$ . Calcule la probabilidad de que el impulso escogido estuviese proyectado para imprimir  $\alpha_1$ .

## Variables aleatorias unidimensionales

### 4.1 Noción general de una variable aleatoria

Al describir el espacio muestral de un experimento, no especificamos que un resultado individual necesariamente tiene que ser un número. De hecho, hemos citado varios ejemplos en los cuales el resultado del experimento no fue una cantidad numérica. Por ejemplo, al clasificar un artículo manufacturado simplemente podríamos usar las categorías «defectuoso» y «no defectuoso». En otro caso, para observar la temperatura durante un período de 24 horas sencillamente podríamos mantener un registro de la curva trazada por el termógrafo. Sin embargo, en muchas situaciones experimentales vamos a interesarnos en medir algo y anotarlo como un *número*. Aún en los casos citados anteriormente podremos asignar un número a cada uno de los resultados (no numéricos) del experimento. Por ejemplo, pudimos asignar el valor uno a artículos no defectuosos y el valor cero a los defectuosos. Pudimos anotar la temperatura máxima del día, o la mínima, o el promedio de las temperaturas máxima y mínima.

Las ilustraciones anteriores son características de una clase muy general de problemas. En muchas situaciones experimentales deseamos asignar un número real  $x$  a cada uno de los elementos  $s$  del espacio muestral  $S$ . Esto es,  $x = X(s)$  es el valor de una función  $X$  del espacio muestral a los números reales. Teniendo esto presente, hagamos la siguiente definición formal.

**Definición.** Sea un experimento  $\varepsilon$  y  $S$  el espacio muestral asociado con el experimento. Una *función*  $X$  que asigna a cada uno de los elementos  $s \in S$ , un número real  $X(s)$ , se llama variable aleatoria.

*Observaciones:* (a) La terminología anterior es algo desafortunada, pero como es tan universalmente aceptada, nosotros no nos apartaremos de ella. Hemos hecho lo más claro posible que  $X$  es una *función* y todavía la llamamos variable (aleatoria).

(b) Resulta que *no toda* función que se conciba puede ser considerada como una variable aleatoria. Una exigencia (aunque no la más general) es que para todo número real  $x$  el suceso  $\{X(s) = x\}$  y para todo intervalo  $I$ , el suceso  $\{X(s) \in I\}$  tiene probabilidades bien definidas y consecuentes con los axiomas básicos. En la mayoría de las aplicaciones no aparece esta dificultad y no haremos referencia posterior.

(c) En algunos casos el resultado  $s$  del espacio muestral es ya la característica numérica que queremos anotar. Sencillamente tomemos  $X(s) = s$ , la función identidad.

(d) En la mayoría de las discusiones de variables aleatorias que siguen, no necesitamos indicar la naturaleza funcional de  $X$ . Generalmente nos interesamos en los valores posibles de  $X$ , en vez de indagar de dónde provienen esos valores. Por ejemplo, supongamos que lanzamos dos monedas y consideremos el espacio muestral asociado con este experimento. Esto es,

$$S = \{CC, CS, SC, SS\}.$$

Definamos la variable aleatoria  $X$  como sigue:  $X$  es el número de caras obtenidas en los dos lanzamientos. Por lo tanto  $X(CC) = 2$ ,  $X(CS) = X(SC) = 1$ , y  $X(SS) = 0$ .

$S$  = espacio muestral de  $\varepsilon$      $R_X$  = valores posibles de  $X$




FIGURA 4.1

(e) Es muy importante comprender que una exigencia básica de una función (uní-varia): a cada  $s \in S$  le corresponde exactamente un valor  $X(s)$ . Esto se demuestra esquemáticamente en la figura 4.1. Valores diferentes de  $s$  pueden dar el mismo valor de  $X$ . Por ejemplo en la ilustración anterior encontramos que  $X(CS) = X(SC) = 1$ .

El espacio  $R_X$ , el conjunto de todos los valores posibles de  $X$ , se llama algunas veces el *recorrido*. En ciertos sentidos podemos considerar a  $R_X$  como otro espacio muestral. El espacio muestral (original)  $S$  corresponde a los resultados no numéricos (posiblemente) del experimento, mientras que  $R_X$  es el espacio muestral asociado con la variable aleatoria  $X$ , que representa la característica numérica que puede ser de interés. Si  $X(s) = s$ , tenemos  $S = R_X$ .

Aunque estamos conscientes del peligro pedagógico que existe al dar muchas explicaciones de la misma cosa, señalemos sin embargo que podemos concebir una variable aleatoria  $X$  de dos maneras:

(a) Realizamos el experimento  $\varepsilon$  que tiene como resultado  $s \in S$ . Luego evaluamos el número  $X(s)$ .

(b) Efectuamos  $\varepsilon$ , y obtenemos el resultado  $s$ , e (inmediatamente) calculamos  $X(s)$ . El número  $X(s)$  se considera entonces como el resultado obtenido en el experimento y  $R_X$  llega a ser el espacio muestral del experimento.

La diferencia entre las interpretaciones (a) y (b) es muy difícil de captar. Relativamente es muy pequeña, pero es digna de atención. En (a) el experimento termina, de hecho, con la observación de  $s$ . La evaluación de  $X(s)$  se considera como algo que se hace posteriormente y que no está afectada por la aleatoriedad de  $\varepsilon$ . En (b) se considera que el experimento no está terminado hasta que

el número  $X(s)$  ya se ha calculado y ha resultado así en el espacio muestral  $R_X$ . Aunque la primera interpretación, (a), es la que se pretende corrientemente, el segundo punto de vista, (b), puede ser muy útil y el lector deberá recordarlo. Lo que queremos decir, y esto será más evidente en las últimas secciones, es que al estudiar variables aleatorias estamos más interesados respecto a los valores que toma  $X$  que de su forma funcional. Por lo tanto, en muchos casos ignoraremos completamente el espacio muestral sobre el cual se puede definir  $X$ .

**EJEMPLO 4.1.** Supongamos que se pone una bombilla en un portalámparas. Se considera que el experimento termina cuando la bombilla se apaga. ¿Cuál es un resultado posible, digamos  $s$ ? Una manera de describir  $s$  sería anotando simplemente la fecha y la hora del día en la cual la bombilla se quema, por ejemplo 19 de mayo, 4:32 p.m. Por lo tanto el espacio muestral se puede representar como  $S = \{(d, t) \mid d = \text{fecha}, t = \text{hora del día}\}$ . Posiblemente la variable aleatoria de interés es  $X$ , la duración del encendido. Nótese que una vez que se ha observado  $s = (d, t)$ , la evaluación de  $X(s)$  no indica ninguna aleatoriedad. Cuando está especificado  $s$ ,  $X(s)$  está completamente determinado.

Los dos puntos de vista expresados anteriormente pueden aplicarse a este ejemplo como sigue. En (a) consideramos que el experimento termina con la observación  $s = (d, t)$ , la fecha y la hora del día. El cálculo de  $X(s)$  se efectúa, entonces, haciendo una sencilla operación aritmética. En (b) consideramos que el experimento está terminado sólo *después* de que se haya calculado  $X(s)$  y el número  $X(s) = 107$  horas, por ejemplo, se considera como el resultado del experimento.

Podría señalarse que un análisis similar se podría aplicar a otra variable aleatoria de interés, por ejemplo,  $Y(s)$  la temperatura en la habitación en el instante en que la bombilla se quemó.

**EJEMPLO 4.2.** En una mesa se lanzan tres monedas. Tan pronto como las monedas caen en la mesa, la fase "aleatoria" del experimento ha terminado. Un solo resultado  $s$  podría consistir en una descripción detallada de cómo y dónde cayeron las monedas. Posiblemente estamos interesados sólo en ciertas características numéricas asociadas con este experimento. Por ejemplo, podríamos calcular

$X(s)$  = número de caras que aparecen,

$Y(s)$  = distancia máxima entre dos monedas cualesquiera,

$Z(s)$  = distancia mínima de las monedas de cualquier arista de la mesa.

Si la variable aleatoria  $X$  es de interés, como indicamos en el ejemplo anterior podríamos incluir la evaluación de  $X(s)$  en la descripción del experimento y por lo tanto indicar simplemente que el espacio muestral asociado con el experimento es  $\{0, 1, 2, 3\}$ , que corresponden a los valores de  $X$ . Aunque muy a menudo

adoptaremos precisamente este punto de vista, es importante establecer que la cuenta del número de caras se hace *después* de que ha terminado la parte aleatoria del experimento.

**Observación:** al referirnos a variables aleatorias usaremos, casi sin excepción, letras mayúsculas tales como  $X, Y, Z$ , etc. Sin embargo, cuando hablamos del *valor* de esas variables aleatorias suponemos que en general usaremos letras minúsculas tales como  $x, y, z$ , etc. Esta es una *distinción muy importante* que debemos hacer y el estudiante debe considerarla detenidamente. Por ejemplo, cuando hablamos de escoger al azar una persona de alguna población señalada y medir su altura (en pulgadas, por ejemplo), podríamos referirnos a los resultados posibles como una variable aleatoria  $X$ . Podríamos luego hacer varias preguntas acerca de  $X$ , tales como  $P(X) \geq 60$ . Sin embargo, una vez que escogemos una persona y medimos su altura, obtenemos un valor específico de  $X$ , por ejemplo  $x$ . Así no sería importante preguntar por  $P(x \geq 60)$  puesto que  $x$  es o no  $\geq 60$ . Esta distinción entre una variable aleatoria y su valor es importante, y haremos referencias posteriores a ella.

Así como nos interesamos por los sucesos asociados con el espacio muestral  $S$ , también será necesario tratar sucesos con respecto a la variable aleatoria  $X$ , esto es, subconjunto del recorrido  $R_X$ . Muy a menudo ciertos sucesos asociados con  $S$  están «relacionados» (en un sentido que luego describiremos) con sucesos asociados con  $R_X$  de la manera siguiente.

**Definición.** Sea  $\varepsilon$  un experimento y  $S$  su espacio muestral. Sea  $X$  una variable aleatoria definida en  $S$  y sea  $R_X$  su recorrido. Sea  $B$  un suceso respecto a  $R_X$ ; esto es,  $B \subset R_X$ . Supongamos que  $A$  se define

$$A = \{s \in S \mid X(s) \in B\}. \quad (4.1)$$

En palabras:  $A$  consta de todos los resultados en  $S$  para los cuales  $X(s) \in B$  (figura 4.2). En este caso decimos que  $A$  y  $B$  son sucesos equivalentes.




FIGURA 4.2

**Observaciones:** (a) Expresando más informalmente lo anterior,  $A$  y  $B$  son sucesos equivalentes siempre que ocurran juntos. Esto es, siempre que  $A$  ocurre, ocurre  $B$  y viceversa. Si ocurrió  $A$ , entonces se obtuvo un resultado  $s$  para el cual  $X(s) \in B$  y por lo tanto ocurrió  $B$ . Recíprocamente, si  $B$  ocurrió, se observó un valor  $X(s)$  para el cual  $s \in A$  y por lo tanto ocurrió  $A$ .

(b) Es importante destacar que en nuestra definición de sucesos equivalentes,  $A$  y  $B$  están asociados con espacios muestrales *diferentes*.

**EJEMPLO 4.3.** Consideremos el lanzamiento de dos monedas. En este caso  $S = \{CC, CS, SC, SS\}$ . Sea  $X$  el número de caras obtenidas. En este caso  $R_X = \{0, 1, 2\}$ . Sea  $B = \{1\}$ . Puesto que  $X(CS) = X(SC) = 1$  si y sólo si  $X(s) = 1$ , tenemos que  $A = \{CS, SC\}$  es equivalente a  $B$ .

Ahora damos la siguiente definición importante.

**Definición.** Sea  $B$  un suceso en el recorrido  $R_X$ . Definimos entonces  $P(B)$  como sigue:

$$P(B) = P(A), \quad \text{en donde} \quad A = \{s \in S \mid X(s) \in B\}. \quad (4.2)$$

En palabras: Definimos  $P(B)$  igual a la probabilidad del suceso  $A \subset S$ , que es equivalente a  $B$ , en el sentido de la ecuación (4.1).

**Observaciones:** (a) Suponemos que las probabilidades se pueden asociar con sucesos en  $S$ . Por tanto la definición anterior hace posible asignar probabilidades a sucesos asociados con  $R_X$  en función de probabilidades definidas en  $S$ .

(b) Realmente es posible *probar* que  $P(B)$  debe ser como se definió. Sin embargo, esto implicaría alguna dificultad teórica que queremos evitar y, por tanto, proseguiremos como antes.

(c) Puesto que en la formulación de la ecuación (4.2) los sucesos  $A$  y  $B$  se refieren a espacios muestrales diferentes, realmente deberíamos usar una notación diferente cuando nos referimos a las probabilidades definidas en  $S$  y para las definidas en  $R_X$ , por ejemplo algo como  $P(A)$  y  $P_X(B)$ . Sin embargo, no haremos esto sino que continuaremos escribiendo simplemente  $P(A)$  y  $P(B)$ . El contexto dentro del cual aparecerán estas expresiones harán evidente la interpretación.

(d) Las probabilidades asociadas con sucesos en el espacio muestral  $S$  (original) están, en un sentido, determinadas por «fuerzas que escapan a nuestro control» o, como se dice algunas veces «por naturaleza». La constitución de una fuente radioactiva que emite partículas, la distribución de un gran número de personas que podría hacer una llamada telefónica durante cierta hora y la agitación térmica que resulta de una corriente o las condiciones atmosféricas que dan origen a una fuente de tormenta, ilustran este punto. Cuando introducimos una variable aleatoria  $X$  y su recorrido asociado  $R_X$ , *inducimos* probabilidades sobre los sucesos asociados con  $R_X$  que se determinan estrictamente si las posibilidades asociadas con los sucesos en  $S$  están especificadas.

**EJEMPLO 4.4.** Si las monedas consideradas en el ejemplo 4.3 son «normales», tenemos  $P(CS) = P(SC) = \frac{1}{4}$ . Por tanto  $P(CS, SC) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$ . (Los cálculos anteriores son una consecuencia directa de nuestra suposición básica que se refiere a la regularidad de las monedas.) Puesto que el suceso  $\{X = 1\}$  es equivalente al suceso  $\{CS, SC\}$ , usando la ecuación (4.1), tenemos que  $P(X = 1) = P(CS, SC) = \frac{1}{2}$ . [Realmente no había elección acerca del valor de  $P(X = 1)$ , consistente con la ecuación (4.2), una vez que se determinó  $P(CS, SC)$ . En este sentido se *inducen* las probabilidades asociadas con sucesos  $R_X$ .]

**Observación:** ahora que hemos establecido la existencia de una función de probabilidades inducidas sobre el recorrido de  $X$  (ecuaciones 4.1 y 4.2) encontraremos conveniente *suprimir* la naturaleza funcional de  $X$ . Por lo tanto escribiremos (como lo hicimos en el ejem-

plo anterior),  $P(X = 1) = \frac{1}{2}$ . Lo que se quiere decir es que un suceso en el espacio muestral  $S$ , llamado  $\{CS, SC\} = \{s \mid X(s) = 1\}$  ocurre con probabilidad  $\frac{1}{2}$ . Por lo tanto asignamos esa misma probabilidad al suceso  $\{X = 1\}$  en el recorrido. Continuaremos escribiendo expresiones como  $P(X = 1)$ ,  $P(X \leq 5)$ , etc. Es *muy importante* que el lector se dé cuenta de lo que esas expresiones representan realmente.

Una vez que se han determinado (o más exactamente inducido) las probabilidades asociadas con varios resultados (o sucesos) en el recorrido  $R_X$  ignoraremos a menudo el espacio muestral original  $S$  que dio lugar a esas probabilidades. Así, en el ejemplo anterior, estamos simplemente interesados en  $R_X = \{0, 1, 2\}$  y las probabilidades asociadas  $(\frac{1}{4}, \frac{1}{2}, \frac{1}{4})$ . El hecho de que estas probabilidades estén *determinadas* por una función de probabilidad definida en el espacio muestral original  $S$  no nos preocupa si estamos interesados sólo en estudiar los valores de la variable aleatoria  $X$ .

Al discutir, en detalle, muchos de los conceptos importantes asociados con variables aleatorias, encontraremos conveniente distinguir dos casos importantes: las variables aleatorias discretas y las continuas.

## 4.2 Variables aleatorias discretas

**Definición.** Sea  $X$  una variable aleatoria. Si el número de valores posibles de  $X$  (esto es,  $R_X$ , el recorrido) es finito o infinito numerable, llamamos a  $X$  una *variable aleatoria discreta*. Esto es, se pueden anotar los valores posibles de  $X$  como  $x_1, x_2, \dots, x_n, \dots$ . En el caso finito la lista termina y en el caso infinito numerable la lista continúa indefinidamente.

**EJEMPLO 4.5.** Una fuente radioactiva emite partículas alfa. Un contador observa la emisión de esas partículas durante un periodo de tiempo especificado. La siguiente variable aleatoria es de interés:  $X$  = número de partículas observadas. ¿Cuáles son los valores posibles de  $X$ ? Supondremos que estos valores constan de todos los enteros no negativos. Esto es,  $R_X = \{0, 1, 2, \dots, n, \dots\}$ . Una objeción que vimos anteriormente puede aparecer de nuevo en este punto. Podría argüirse que durante un intervalo de tiempo especificado (finito) es imposible observar más de  $N$  partículas, por ejemplo, en donde  $N$  puede ser un entero positivo muy grande. Por tanto los valores posibles de  $X$  realmente serían:  $0, 1, 2, \dots, N$ . Sin embargo resulta que matemáticamente es más sencillo considerar la descripción idealizada dada anteriormente. De hecho, cada vez que suponemos que los valores posibles de una variable aleatoria  $X$  son infinitos numerables estamos considerando en ese momento una representación idealizada de  $X$ .

En vista de nuestros comentarios previos sobre la descripción probabilística de sucesos con número finito de elementos o infinitos numerables, la descripción probabilística de una variable aleatoria discreta no nos causará ninguna dificultad. Procederemos como se indica a continuación.

**Definición.** Sea  $X$  una variable aleatoria discreta. Por tanto  $R_X$ , el recorrido de  $X$ , consta, a lo más, de un número de valores,  $x_1, x_2, \dots$  infinito numerable. Con cada resultado posible  $x_i$  asociamos un número  $p(x_i) = P(X = x_i)$ , llamado la probabilidad de  $x_i$ . Los números  $p(x_i), i = 1, 2, \dots$  deben satisfacer las condiciones siguientes:

$$(a) \quad p(x_i) \geq 0 \quad \text{para todo } i, \quad (4.3)$$

$$(b) \quad \sum_{i=1}^{\infty} p(x_i) = 1.$$

La función  $p$  definida anteriormente se llama *función de probabilidad* (o función de probabilidad puntual) de la variable aleatoria  $X$ . La colección de pares  $(x_i, p(x_i)), i = 1, 2, \dots$ , se llama algunas veces distribución de probabilidad de  $X$ .




FIGURA 4.3

**Observaciones:** (a) La elección particular de los números  $p(x_i)$  posiblemente está determinada por la función de probabilidad asociada con sucesos en el espacio muestral  $S$  sobre el cual se define  $X$ . Esto es,  $p(x_i) = P[S \mid X(s) = x_i]$ . (Ver ecuaciones 4.1 y 4.2.) Sin embargo, puesto que sólo estamos interesados en los valores de  $X$ , esto es,  $R_X$ , y en las probabilidades asociadas con esos valores, omitimos nuevamente la naturaleza funcional de  $X$ . (Ver figura 4.3). Aunque en la mayoría de los casos, de hecho, los números se determinarán de la distribución de probabilidades en algún espacio muestral fundamental  $S$ , cualquier conjunto de números  $p(x_i)$  que satisfaga la ecuación (4.3) puede servir como una descripción probabilística propia de una variable aleatoria discreta.

(b) Si  $X$  toma sólo un número finito de valores, por ejemplo  $x_1, \dots, x_N$ , entonces  $p(x_i) = 0$  para  $i > N$ , y por lo tanto la serie infinita en la ecuación (4.3) llega a ser una suma finita.

(c) Nuevamente podemos observar una analogía con la mecánica al considerar una masa total unitaria distribuida sobre la recta real con la masa completa ubicada en los puntos  $x_1, x_2, \dots$ . Los números  $p(x_i)$  representan la cantidad de masa ubicada en  $x_i$ .

(d) La interpretación geométrica (figura 4.4) de una distribución de probabilidades es siempre útil.




FIGURA 4.4




FIGURA 4.5

Sea  $B$  un suceso asociado con la variable aleatoria  $X$ . Esto es  $B \subset R_X$  (figura 4.5). Específicamente, supongamos que  $B = \{x_{i_1}, x_{i_2}, \dots\}$ . Por tanto

$$P(B) = P[s | X(s) \in B] \quad (\text{puesto que estos sucesos son equivalentes})$$

$$= P[s | X(s) = x_{i_j}, j = 1, 2, \dots] = \sum_{j=1}^{\infty} p(x_{i_j}). \quad (4.4)$$

En palabras: la probabilidad de un suceso  $B$  es igual a la suma de las probabilidades de los resultados individuales asociados con  $B$ .

**Observaciones:** (a) Supóngase que la variable aleatoria discreta  $X$  puede tomar sólo un número finito de valores, por ejemplo  $x_1, \dots, x_N$ . Si cada resultado es igualmente probable, obviamente tenemos  $p(x_1) = \dots = p(x_N) = 1/N$ .

(b) Si  $X$  toma un número infinito numerable de valores, entonces es imposible tener todos los resultados igualmente probables. Porque no podemos satisfacer posiblemente la condición  $\sum_{i=1}^{\infty} p(x_i) = 1$  si debemos tener  $p(x_i) = c$  para todo  $i$ .

(c) En cada intervalo finito habrá cuando más un número finito de valores posibles de  $X$ . Si uno de tales intervalos no contiene ninguno de los valores posibles le asignamos probabilidad cero. Esto es, si  $R_X = \{x_1, x_2, \dots, x_n\}$  y si ningún  $x_i \in [a, b]$ , entonces  $P[a \leq X \leq b] = 0$ .

**EJEMPLO 4.6.** Supóngase que se pone un tubo de radio en un soporte y se prueba. Supóngase que la probabilidad de que el control sea positivo es igual a  $\frac{3}{4}$ ; por tanto la probabilidad de que el control sea negativo es  $\frac{1}{4}$ . Supóngase además, que probamos una gran cantidad de tales tubos. La prueba continúa hasta que aparece el primer tubo positivo. Defínase la variable aleatoria  $X$  como sigue:  $X$  es el número de pruebas necesarias para finalizar el experimento. El espacio muestral asociado con este experimento es

$$S = \{+, - +, - - +, - - - +, \dots\}.$$

Para determinar la distribución de probabilidades de  $X$  razonamos como sigue. Los valores posibles de  $X$  son  $1, 2, \dots, n, \dots$  (obviamente estamos considerando el espacio muestral idealizado). Y  $X = n$  si y sólo si los primeros  $(n-1)$  tubos son negativos y el  $n$ -ésimo tubo es positivo. Si suponemos que la condición de un tubo no afecta la condición de otro podemos escribir

$$p(n) = P(X = n) = \left(\frac{1}{4}\right)^{n-1} \left(\frac{3}{4}\right), \quad n = 1, 2, \dots$$

Para verificar que estos valores de  $p(n)$  satisfagan la ecuación (4.3), observemos que

$$\sum_{n=1}^{\infty} p(n) = \frac{3}{4} \left(1 + \frac{1}{4} + \frac{1}{16} + \dots\right)$$

$$= \frac{3}{4} \frac{1}{1 - \frac{1}{4}} = 1.$$

**Observaciones:** aquí empleamos el resultado de que la serie geométrica  $1 + r + r^2 + \dots$  converge a  $1/(1-r)$  siempre que  $|r| < 1$ . A este resultado nos referiremos varias veces. Supóngase que queremos calcular  $P(A)$ , en donde  $A$  se define como {El experimento termina después de un número par de repeticiones}. Usando la ecuación (4.4), tenemos

$$P(A) = \sum_{n=1}^{\infty} p(2n) = \frac{3}{16} + \frac{3}{256} + \dots$$

$$= \frac{3}{16} (1 + \frac{1}{16} + \dots)$$

$$= \frac{3}{16} \frac{1}{1 - \frac{1}{16}} = \frac{1}{5}.$$

### 4.3 La distribución binomial

En los capítulos finales consideraremos, en forma detallada diversas variables aleatorias discretas importantes. Por el momento sólo estudiaremos una de estas y luego la usaremos para ilustrar varios conceptos importantes.

**EJEMPLO 4.7.** Supóngase que los artículos que salen de una línea de producción se clasifican como defectuosos ( $D$ ) o no defectuosos ( $N$ ). Supongamos que se eligen al azar tres artículos de la producción de un día y se clasifican de acuerdo con este esquema. El espacio muestral para este experimento, digamos  $S$ , puede describirse así:

$$S = \{DDD, DDN, DND, NDD, NND, NDN, DNN, NNN\}.$$

(Otra manera de describir  $S$  es como  $S = S_1 \times S_2 \times S_3$ , el producto cartesiano de  $S_1, S_2$ , y  $S_3$ , en donde cada  $S_i = \{D, N\}$ .)

Supongamos que con probabilidad 0,2 un artículo es defectuoso y por lo tanto con probabilidad 0,8 un artículo no es defectuoso. Supongamos que esas probabilidades son iguales para cada artículo al menos durante nuestro estudio. Finalmente, supongamos que la clasificación de cualquier artículo particular es independiente de la clasificación de cualquier otro artículo. Usando estas suposiciones, se deduce que las probabilidades asociadas con los diversos resultados del espacio muestral  $S$  como se describió anteriormente son

$$(0,2)^3, (0,8)(0,2)^2, (0,8)(0,2)^2, (0,8)(0,2)^2, (0,2)(0,8)^2, (0,2)(0,8)^2, (0,2)(0,8)^2, (0,8)^3.$$

Corrientemente nuestro interés no se enfoca hacia los resultados individuales de  $S$ ; sino que, simplemente, deseamos saber cuántos artículos defectuosos se encuentran (sin considerar el orden en que ocurrieron). Es decir, deseamos considerar la variable aleatoria  $X$  que asigna a cada uno de los resultados  $s \in S$  el número de artículos defectuosos encontrados en  $s$ . Por tanto el conjunto de valores posibles de  $X$  es  $\{0, 1, 2, 3\}$ .

Podemos obtener la distribución de probabilidades para  $X$ ,  $p(x_i) = P(X = x_i)$  como sigue:

|         |                     |                        |
|---------|---------------------|------------------------|
| $X = 0$ | si y sólo si ocurre | $NNN$ ;                |
| $X = 1$ | si y sólo si ocurre | $DNN, NDN$ , o $NND$ ; |
| $X = 2$ | si y sólo si ocurre | $DDN, DND$ , o $NDD$ ; |
| $X = 3$ | si y sólo si ocurre | $DDD$ .                |

(Nótese que  $\{NNN\}$  es equivalente a  $\{X = 0\}$ , etc.) Por lo tanto

$$p(0) = P(X = 0) = (0,8)^3, \quad p(1) = P(X = 1) = 3(0,2)(0,8)^2,$$

$$p(2) = P(X = 2) = 3(0,2)^2(0,8), \quad p(3) = P(X = 3) = (0,2)^3.$$

Nótese que la suma de estas probabilidades es igual a 1, porque la suma puede escribirse  $(0,8 + 0,2)^3$ .

**Observación:** la presentación anterior ilustra cómo las probabilidades en el recorrido  $R_X$  (en este caso  $\{0, 1, 2, 3\}$ ) son *inducidas* por las probabilidades definidas en el espacio muestral  $S$ , porque la suposición de que los ocho resultados de

$$S = \{DDD, DDN, DND, NDD, NND, NDN, DNN, NNN\}$$

tienen las probabilidades dadas por el ejemplo 4.7, que *determina* el valor de  $p(x)$  para todo  $x \in R_X$ .

Generalicemos ahora las nociones presentadas en el ejemplo anterior.

**Definición.** Consideremos un experimento  $\varepsilon$  y sea  $A$  un suceso asociado con  $\varepsilon$ . Supongamos que  $P(A) = p$  y por lo tanto  $P(\bar{A}) = 1 - p$ . Consideremos  $n$  repeticiones independientes de  $\varepsilon$ . Por lo tanto el espacio muestral consiste en todas las sucesiones posibles  $\{a_1, a_2, \dots, a_n\}$ , en donde cada  $a_i$  es  $A$  o  $\bar{A}$ , según que  $A$  o  $\bar{A}$  ocurra en la  $i$ -ésima repetición de  $\varepsilon$ . (Hay  $2^n$  de tales sucesiones.) Aún más, supongamos que  $P(A) = p$  es el mismo para todas las repeticiones. Definamos la variable aleatoria  $X$  como sigue:  $X$  = número de veces que ocurrió el suceso  $A$ . Llamamos a  $X$  una variable aleatoria *binomial* con los parámetros  $n$  y  $p$ . Sus valores posibles obviamente son  $0, 1, 2, \dots, n$ . (Decimos en forma equivalente que  $X$  tiene una *distribución binomial*.) Las repeticiones individuales de  $\varepsilon$  se llamarán *ensayos de Bernoulli*.

**Teorema 4.1.** Sea  $X$  una variable binomial basada en  $n$  repeticiones. Entonces

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (4.5)$$

**Demostración:** consideremos un elemento particular del espacio muestral  $\varepsilon$  que satisfaga la condición de que  $X = k$ . Tal resultado aparecería, por ejemplo, si las primeras  $k$  repeticiones de  $\varepsilon$  resultasen en la ocurrencia de  $A$  mientras que las últimas  $n - k$  repeticiones resultasen en  $\bar{A}$ , es decir:

$$\underbrace{AAA \cdots A}_k \underbrace{\bar{A}\bar{A}\bar{A} \cdots \bar{A}}_{n-k}$$

Puesto que todas las repeticiones son independientes, la probabilidad de esta sucesión particular sería  $p^k(1 - p)^{n-k}$ . Pero exactamente la misma probabilidad estaría asociada con cualquier otro resultado para el cual  $X = k$ . El número total de tales resultados es igual a  $\binom{n}{k}$ , por lo que debemos elegir exactamente  $k$  posiciones (entre  $n$ ) para las  $A$ . Pero esto produce el resultado anterior ya que esos  $\binom{n}{k}$  resultados son mutuamente excluyentes.

**Observaciones:** (a) Para verificar nuestros cálculos observemos que, usando el teorema del binomio, tenemos  $\sum_{k=0}^n P(X = k) = \sum_{k=0}^n \binom{n}{k} p^k (1 - p)^{n-k} = [p + (1 - p)]^n = 1^n = 1$ , como debería ser. Puesto que las probabilidades  $\binom{n}{k} p^k (1 - p)^{n-k}$  se obtienen al desarrollar la expresión binomial  $[p + (1 - p)]^n$ , a ésta llamamos *distribución binomial*.

(b) Cada vez que realizamos repeticiones independientes de un experimento y nos interesamos sólo en una dicotomía —defectuosos o no defectuosos, dureza sobre o bajo un cierto valor estándar, nivel de ruido en un sistema de comunicaciones sobre o bajo un margen preasignado— consideramos potencialmente un espacio muestral en el cual podemos definir una variable aleatoria binomial. Si las condiciones del experimento permanecen suficientemente uniformes de modo que la probabilidad de algún atributo, por ejemplo  $A$ , permanezca constante, podemos usar el modelo anterior.

(c) Si  $n$  es pequeño, los términos individuales de la distribución binomial son relativamente sencillos de calcular. Sin embargo, si  $n$  es razonablemente grande estos cálculos llegan a ser un poco complicados. Afortunadamente, las probabilidades binomiales han sido calculadas. Existen muchas de tales tabulaciones. (Ver Apéndice.)

**EJEMPLO 4.8.** Supongamos que un tubo de radio puesto en cierto tipo de equipo tiene una probabilidad de 0,2 de funcionar más de 500 horas. Si probamos 20 tubos, ¿cuál es la probabilidad de que exactamente  $k$  de ellos funcionen más de 500 horas,  $k = 0, 1, 2, \dots, 20$ ?

Si  $X$  es el número de tubos que funcionan más de 500 horas, supondremos que  $X$  tiene una distribución binomial. Así  $P(X = k) = \binom{20}{k} (0,2)^k (0,8)^{20-k}$ .

Los siguientes valores pueden leerse en la tabla 4.1.

TABLA 4.1

|                    |                    |                                   |
|--------------------|--------------------|-----------------------------------|
| $P(X = 0) = 0,012$ | $P(X = 4) = 0,218$ | $P(X = 8) = 0,022$                |
| $P(X = 1) = 0,058$ | $P(X = 5) = 0,175$ | $P(X = 9) = 0,007$                |
| $P(X = 2) = 0,137$ | $P(X = 6) = 0,109$ | $P(X = 10) = 0,002$               |
| $P(X = 3) = 0,205$ | $P(X = 7) = 0,055$ | $P(X = k) = 0^+$ para $k \geq 11$ |

(Las probabilidades restantes son menores que 0,001).

Si dibujamos esta distribución de probabilidades obtenemos el gráfico que se muestra en la figura 4.6. El modelo que observamos aquí es muy general: las probabilidades binomiales aumentan monótonamente hasta que alcanzan un valor máximo y luego disminuyen monótonamente. (Ver problema 4.8.)




FIGURA 4.6

**EJEMPLO 4.9.** Al operar una máquina, existe cierta probabilidad de que el operario cometa un error. Puede suponerse de manera realista que el operario aprende en cuanto sabe que la probabilidad de cometer errores disminuye cuando él use repetidamente la máquina. Supongamos que el operario hace  $n$  intentos y que los  $n$  ensayos son estadísticamente independientes. Supongamos específicamente que  $P(\text{un error cometido en la } i\text{-ésima repetición}) = 1/(i+1)$ ,  $i = 1, 2, \dots, n$ . Supongamos que se consideran 4 intentos (esto es,  $n = 4$ ) y que se define la variable aleatoria  $X$  como el número de operaciones hechas sin error en la máquina. Observemos que  $X$  no está distribuida binomialmente porque la probabilidad de «éxito» no es constante.

Para calcular la probabilidad de  $X = 3$ , por ejemplo, procedemos como sigue:  $X = 3$  si y sólo si hay exactamente un intento no exitoso. Esto puede suceder en el primero, segundo, tercero, o cuarto ensayo. Por lo tanto

$$P(X = 3) = \frac{1}{2} \frac{2}{3} \frac{3}{4} \frac{4}{5} + \frac{1}{2} \frac{1}{3} \frac{3}{4} \frac{4}{5} + \frac{1}{2} \frac{1}{3} \frac{1}{4} \frac{4}{5} + \frac{1}{2} \frac{1}{3} \frac{2}{4} \frac{1}{5} = \frac{5}{12}.$$

**EJEMPLO 4.10.** Consideremos una situación semejante a la descrita en el ejemplo 4.9. Esta vez supondremos que hay una probabilidad constante  $p_1$  de no cometer error en la máquina durante cada uno de los primeros  $n_1$  intentos y una probabilidad constante  $p_2 \leq p_1$  de no cometer error en cada una de las siguientes  $n_2$  repeticiones. Sea  $X$  el número de operaciones exitosas de la máquina durante los  $n = n_1 + n_2$  intentos independientes. Encontramos una expresión general para  $P(X = k)$ . Por la misma razón dada en el ejemplo precedente,  $X$  no está distribuida binomialmente. Para obtener  $P(X = k)$  procedemos como sigue.

Sea  $Y_1$  el número de operaciones correctas durante los primeros  $n_1$  intentos y sea  $Y_2$  el número de operaciones correctas durante los segundos  $n_2$  intentos.

Por lo tanto,  $Y_1$  e  $Y_2$  son variables aleatorias independientes y  $X = Y_1 + Y_2$ . Así  $X = k$  si y sólo si  $Y_1 = r$  e  $Y_2 = k - r$ , para cualquier entero  $r$  que satisfaga  $0 \leq r \leq n_1$  y  $0 \leq k - r \leq n_2$ .

Las restricciones anteriores sobre  $r$  son equivalentes a  $0 \leq r \leq n_1$  y  $k - n_2 \leq r \leq k$ . Combinándolas podemos escribir

$$\max(0, k - n_2) \leq r \leq \min(k, n_1).$$

Por tanto tenemos

$$P(X = k) = \sum_{r=\max(0, k-n_2)}^{\min(k, n_1)} \binom{n_1}{r} p_1^r (1-p_1)^{n_1-r} \binom{n_2}{k-r} p_2^{k-r} (1-p_2)^{n_2-(k-r)}.$$

Con la convención corriente de que  $\binom{a}{b} = 0$  cada vez que  $b > a$  o  $b < 0$ , podemos escribir la probabilidad anterior como

$$P(X = k) = \sum_{r=0}^{n_1} \binom{n_1}{r} p_1^r (1-p_1)^{n_1-r} \binom{n_2}{k-r} p_2^{k-r} (1-p_2)^{n_2-k+r}. \quad (4.6)$$

Por ejemplo, si  $p_1 = 0.2$ ,  $p_2 = 0.1$ ,  $n_1 = n_2 = 10$ , y  $k = 2$ , la probabilidad anterior llega a ser

$$P(X = 2) = \sum_{r=0}^2 \binom{10}{r} (0.2)^r (0.8)^{10-r} \binom{10}{2-r} (0.1)^{2-r} (0.9)^{8+r} = 0.27,$$

después de un cálculo elemental.

*Observación:* supongamos que  $p_1 = p_2$ . En este caso, la ecuación (4.6) se reduciría a  $\binom{n}{k} p_1^k (1-p_1)^{n-k}$ , puesto que ahora la variable aleatoria  $X$  tiene una distribución binomial. Para ver que esto es así, obsérvese que podemos escribir (puesto que  $n_1 + n_2 = n$ )

$$P(X = k) = p_1^k (1-p_1)^{n-k} \sum_{r=0}^{n_1} \binom{n_1}{r} \binom{n_2}{k-r}.$$

Para mostrar que la suma anterior iguala  $\binom{n}{k}$  compárense simplemente los coeficientes de las potencias de  $x^k$  en ambos lados de la identidad  $(1+x)^{n_1}(1+x)^{n_2} = (1+x)^{n_1+n_2}$ .

#### 4.4 Variables aleatorias continuas

Supongamos que el recorrido de  $X$  está formado por un gran número de valores, por ejemplo todos los valores  $x$  en el intervalo  $0 \leq x \leq 1$  de la forma  $0; 0.01; 0.02; \dots, 0.98; 0.99; 1.00$ . Con cada uno de esos valores está asociado un número no negativo  $p(x_i) = P(X = x_i)$ ,  $i = 1, 2, \dots$ , cuya suma es igual a 1. Esta situación se representa geométricamente en la figura 4.7.

Hemos señalado antes que podría ser matemáticamente más fácil idealizar la

anterior descripción probabilística de  $X$  al suponer que  $X$  puede tomar *todos* los valores posibles,  $0 \leq x \leq 1$ . Si hacemos esto, ¿qué le sucede a las probabilidades puntuales  $p(x_i)$ ? Puesto que los valores posibles de  $X$  no son contables, no podemos hablar realmente del  $i$ -ésimo valor de  $X$  y por lo tanto  $p(x_i)$  pierde significado. Lo que haremos es sustituir la función  $p$ , definida sólo para  $x_1, x_2, \dots$ , por una función  $f$  definida (en el contexto presente) para *todos* los valores de  $x$ ,  $0 \leq x \leq 1$ . Las propiedades de la ecuación (4.3) se sustituirán por  $f(x) \geq 0$  y  $\int_0^1 f(x) dx = 1$ . Procederemos formalmente como sigue.




FIGURA 4.7

**Definición.** Se dice que  $X$  es una *variable aleatoria continua* si existe una función  $f$ , llamada función de densidad de probabilidad (fdp) de  $X$ , que satisface las siguientes condiciones:

$$(a) \quad f(x) \geq 0 \quad \text{para todo } x,$$

$$(b) \quad \int_{-\infty}^{+\infty} f(x) dx = 1. \quad (4.7)$$

$$(c) \quad \text{Para cualquier } a, b, \text{ tal que } -\infty < a < b < +\infty, \text{ tenemos } P(a \leq X \leq b) = \int_a^b f(x) dx. \quad (4.8)$$

**Observaciones:** (a) Fundamentalmente queremos decir que  $X$  es una variable aleatoria continua si  $X$  puede tomar todos los valores en algún intervalo  $(c, d)$  en donde  $c$  y  $d$  pueden ser  $-\infty$  y  $+\infty$ , respectivamente. La existencia estipulada de una fdp es un método matemático que tiene una base intuitiva considerable y hacen más sencillos nuestros cálculos. En relación con esto, de nuevo se debe señalar que cuando suponemos que  $X$  es una variable aleatoria continua, estamos considerando la descripción *idealizada* de  $X$ .

(b)  $P(c < X < d)$  representa el área bajo el gráfico en la figura 4.8 de la fdp  $f$  entre  $x = c$  y  $x = d$ .




FIGURA 4.8

(c) Una consecuencia de la descripción probabilística de  $X$  para *cualquier* valor específico de  $X$ , por ejemplo  $x_0$  es que tenemos  $P(X = x_0) = 0$ , puesto que  $P(X = x_0) = \int_{x_0}^{x_0} f(x) dx = 0$ . Este resultado puede parecer muy contrario a nuestra intuición. Debemos establecer, sin embargo, que si permitimos que  $X$  tome *todos* los valores en un intervalo, entonces la probabilidad cero no es equivalente con la imposibilidad. Por tanto, en el caso continuo,  $P(A) = 0$  no implica  $A = \emptyset$ , el conjunto vacío. (Ver teorema 1.1.) Para decirlo de un modo más informal, consideremos que elegimos un punto al azar en el segmento  $\{x | 0 \leq x \leq 2\}$ . Aunque quisiéramos estar de acuerdo (como un objetivo matemático) con que *cada* punto concebible del segmento pudiese ser el resultado de nuestro experimento, nos sorprenderíamos mucho si en realidad escogiéramos precisamente el punto medio del segmento, o cualquier otro punto *específico* de ese elemento. Cuando indicamos esto en un lenguaje matemático preciso, decimos que el suceso tiene «probabilidad 0». En vista de estas consideraciones, las siguientes probabilidades son todas *iguales* si  $X$  es una variable aleatoria continua:

$$P(c \leq X \leq d), \quad P(c \leq X < d), \quad P(c < X \leq d), \quad \text{y} \quad P(c < X < d).$$

(d) Aunque no verificaremos los detalles aquí, puede demostrarse que la anterior asignación de probabilidades a los sucesos en  $R_X$  satisface los axiomas básicos de probabilidades (ecuación 1.3), en donde podemos tomar  $\{x | -\infty < x < +\infty\}$  como el espacio muestral.

(e) Si una función  $f^*$  satisface las condiciones,  $f^*(x) \geq 0$ , para todo  $x$ , y  $\int_{-\infty}^{+\infty} f^*(x) dx = K$ , en donde  $K$  es un número positivo real (no necesariamente igual a 1), entonces  $f^*$  *no* satisface todas las condiciones para ser una fdp. Sin embargo, podemos definir fácilmente una nueva función, por ejemplo  $f$ , en función de  $f^*$  como sigue:

$$f(x) = \frac{f^*(x)}{K} \quad \text{para todo } x.$$

Por tanto  $f$  satisface todas las condiciones de una fdp.

(f) Si  $X$  sólo toma valores en un intervalo finito  $[a, b]$ , simplemente podemos establecer  $f(x) = 0$  para todo  $x \notin [a, b]$ . Por tanto la fdp está definida para *todos* los valores reales de  $x$ , y debemos exigir que  $\int_{-\infty}^{+\infty} f(x) dx = 1$ . Cuando quiera que la fdp se especifique sólo para ciertos valores de  $x$ , supondremos que es cero para cualquier otro.

(g) ¡ $f(x)$  no representa la probabilidad de nada! Hemos observado antes que  $P(X = 2) = 0$ , por ejemplo, y por tanto  $f(2)$  ciertamente no representa esta probabilidad. Sólo cuando la función se integra entre dos límites produce una probabilidad. Sin embargo, podemos dar una interpretación de  $f(x)\Delta x$  como sigue. Del teorema del valor medio del cálculo se deduce que

$$P(x \leq X \leq x + \Delta x) = \int_x^{x+\Delta x} f(s) ds = \Delta x f(\xi), \quad x \leq \xi \leq x + \Delta x.$$

Si  $\Delta x$  es pequeño,  $f(x)\Delta x$  es *aproximadamente* igual a  $P(x \leq X \leq x + \Delta x)$ . Si  $f$  es continuo por la derecha, esta aproximación llega a ser más segura cuando  $\Delta x \rightarrow 0$ .)

(h) Deberíamos señalar nuevamente que la distribución de probabilidades (en este caso la fdp) es inducida en  $R_X$  por las probabilidades asociadas con sucesos en  $S$ . Así cuando escribimos  $P(c < X < d)$ , queremos decir, como siempre  $P[c < X(s) < d]$ , que a su vez es igual a  $P[s | c < X(s) < d]$ , puesto que estos sucesos son equivalentes. La definición anterior, ecuación (4.8), estipula esencialmente la existencia de una fdp  $f$  definida en una  $R_X$  tal que

$$P[s | c < X(s) < d] = \int_c^d f(x) dx.$$

Nuevamente eliminaremos la naturaleza funcional de  $X$  y por tanto estaremos interesados sólo en  $R_X$  y la fdp  $f$ .

(i) En el caso continuo, nuevamente podemos considerar la siguiente *analogía con la mecánica*: supóngase que tenemos una masa total de una unidad, distribuida continuamente en el intervalo  $a \leq x \leq b$ . Entonces  $f(x)$  representa la densidad de la masa en el punto  $x$  y  $\int_c^d f(x)dx$  representa la masa total contenida en el intervalo  $c \leq x \leq d$ .

**EJEMPLO 4.11.** En la discusión precedente sobre variable aleatoria, se supuso la existencia de una fdp. Consideremos un ejemplo simple en el cual podamos determinar fácilmente la fdp, haciendo una suposición apropiada acerca de la conducta probabilística de la variable aleatoria. Supóngase que escogemos un punto en el intervalo  $(0, 1)$ . Representemos la variable aleatoria  $X$  cuyo valor es la coordenada  $x$  del punto escogido.

*Suposición:* si  $I$  es cualquier intervalo entre  $(0, 1)$ , entonces la  $\text{Prob}[X \in I]$  es directamente proporcional a la longitud de  $I$ , por ejemplo  $L(I)$ . Esto es,  $\text{Prob}[X \in I] = kL(I)$ , en donde  $k$  es la constante de proporcionalidad. (Es fácil ver, tomando  $I = (0, 1)$  y observando que  $L((0, 1)) = 1$  y  $\text{Prob}[X \in (0, 1)] = 1$ , que  $k = 1$ .)

Obviamente  $X$  toma todos los valores en  $(0, 1)$ . ¿Cuál es su fdp? Esto es, ¿podemos encontrar una función  $f$  tal que

$$P(a < X < b) = \int_a^b f(x)dx?$$

Nótese que si  $a < b < 0$  o  $1 < a < b$ ,  $P(a < X < b) = 0$  y por tanto  $f(x) = 0$ . Si  $0 < a < b < 1$ ,  $P(a < X < b) = b - a$  y por tanto  $f(x) = 1$ . Así encontramos,

$$f(x) = \begin{cases} 1, & 0 < x < 1, \\ 0, & \text{para cualquier otro valor.} \end{cases}$$




FIGURA 4.9




FIGURA 4.10

**EJEMPLO 4.12.** Supóngase que la variable aleatoria  $X$  es continua. (Ver figura 4.9.) Sea la fdp  $f$  dada por

$$f(x) = \begin{cases} 2x, & 0 < x < 1, \\ 0, & \text{para cualquier otro valor.} \end{cases}$$

Claramente,  $f(x) \geq 0$  y  $\int_{-\infty}^{+\infty} f(x)dx = \int_0^1 2x dx = 1$ . Para calcular  $P(X \leq \frac{1}{2})$ , debemos evaluar simplemente la integral  $\int_0^{1/2} (2x)dx = \frac{1}{4}$ .

El concepto de probabilidad condicional tratado en el capítulo 3 se puede aplicar debidamente a las variables aleatorias. Por ejemplo, en el ejemplo anterior debimos evaluar  $P(X \leq \frac{1}{2} | \frac{1}{3} \leq X \leq \frac{2}{3})$ . Aplicando directamente la definición de probabilidad individual, tenemos

$$\begin{aligned} P(X \leq \frac{1}{2} | \frac{1}{3} \leq X \leq \frac{2}{3}) &= \frac{P(\frac{1}{3} \leq X \leq \frac{1}{2})}{P(\frac{1}{3} \leq X \leq \frac{2}{3})} \\ &= \frac{\int_{1/3}^{1/2} 2x dx}{\int_{1/3}^{2/3} 2x dx} = \frac{5/36}{1/3} = \frac{5}{12}. \end{aligned}$$

**EJEMPLO 4.13.** Sea  $X$  la duración (en horas) de cierto tipo de bombilla eléctrica. Supóngase que  $X$  es una variable aleatoria continua y supóngase que la fdp  $f$  de  $X$  está dada por

$$f(x) = \begin{cases} a/x^3, & 1500 \leq x \leq 2500, \\ 0, & \text{para cualquier otro valor.} \end{cases}$$

(Es decir, asignamos probabilidad cero al suceso  $\{X \leq 1500\}$  y  $\{X > 2500\}$ .) Para evaluar la constante  $a$ , debemos acudir a la condición  $\int_{-\infty}^{+\infty} f(x)dx = 1$  que en este caso llega a ser  $\int_{1500}^{2500} a/x^3 dx = 1$ . De esto obtenemos  $a = 7,031,250$ . El gráfico de  $f$  aparece en la figura 4.10.

En un capítulo posterior estudiaremos, con mucho detalle, diversas variables aleatorias importantes, discretas y continuas. Mediante el uso de los determinísticos sabemos que ciertas funciones desempeñan un papel mucho más importante que otras. Por ejemplo, las funciones lineales, cuadráticas, exponenciales y trigonométricas juegan un papel primordial al describir modelos determinísticos. Al desarrollar los modelos no determinísticos (es decir, probabilísticos) encontraremos que ciertas variables aleatorias son particularmente importantes.

## 4.5 Función de distribución acumulativa

Queremos presentar otro importante concepto general en este capítulo.

**Definición.** Sea  $X$  una variable aleatoria, discreta o continua. Definimos que  $F$  es la *función de distribución acumulativa* de la variable aleatoria  $X$  (abreviada fda) como  $F(x) = P(X \leq x)$ .

**Teorema 4.2.** (a) Si  $X$  es una variable aleatoria discreta,

$$F(x) = \sum_j p(x_j), \quad (4.9)$$

en donde la suma se toma sobre todos los índices  $j$  que satisfacen  $x_j \leq x$ .

(b) Si  $X$  es una variable aleatoria continua con fdp  $f$ ,

$$F(x) = \int_{-\infty}^x f(s) ds. \quad (4.10)$$

*Demostración:* ambos resultados se deducen inmediatamente de la definición.




FIGURA 4.11

**EJEMPLO 4.14.** Supongamos que la variable aleatoria  $X$  toma los tres valores 0, 1, y 2 con probabilidades  $\frac{1}{3}$ ,  $\frac{1}{6}$ , y  $\frac{1}{2}$ , respectivamente. Entonces

$$\begin{aligned} F(x) &= 0 & \text{si } x < 0, \\ &= \frac{1}{3} & \text{si } 0 \leq x < 1, \\ &= \frac{1}{2} & \text{si } 1 \leq x < 2, \\ &= 1 & \text{si } x \geq 2. \end{aligned}$$

(Nótese que es muy importante indicar la inclusión o exclusión de los puntos extremos al describir los diversos intervalos.) El gráfico de  $F$  se da en la figura 4.11.

**EJEMPLO 4.15.** Supongamos que  $X$  es una variable aleatoria continua con fdp

$$\begin{aligned} f(x) &= 2x, & 0 < x < 1, \\ &= 0, & \text{para cualquier otro valor.} \end{aligned}$$

Por lo tanto la fda  $F$  está dada por

$$\begin{aligned} F(x) &= 0 & \text{si } x \leq 0, \\ &= \int_0^x 2s ds = x^2 & \text{si } 0 < x \leq 1, \\ &= 1 & \text{si } x > 1. \end{aligned}$$

El gráfico aparece en la figura 4.12.




FIGURA 4.12

Los gráficos obtenidos en las figuras 4.11 y 4.12 para las fda (en cada uno de los casos) son muy típicos en el siguiente sentido.

(a) Si  $X$  es una variable aleatoria discreta con un número finito de valores posibles, el gráfico de la fda  $F$  se formará de trazos horizontales (se llama función escalonada). La función  $F$  es continua excepto para los valores posibles de  $X$ , llamados,  $x_1, \dots, x_n$ . En el valor  $x_j$  el gráfico tendrá un «salto» de magnitud  $p(x_j) = P(X = x_j)$ .

(b) Si  $X$  es una función aleatoria continua,  $F$  será una función continua para todo  $x$ .

(c) La fda  $F$  está definida para todos los valores de  $x$ , lo cual es una razón importante para considerarla.

Hay dos propiedades importantes de la fda que resumiremos en el teorema siguiente.

**Teorema 4.3.** (a) La función  $F$  es no decreciente. Esto es, si  $x_1 \leq x_2$ , tenemos  $F(x_1) \leq F(x_2)$ .

(b)  $\lim_{x \rightarrow -\infty} F(x) = 0$  y  $\lim_{x \rightarrow \infty} F(x) = 1$ . [A menudo esto lo escribimos como  $F(-\infty) = 0$ ,  $F(\infty) = 1$ .]

*Demostración:* (a) Definamos los sucesos  $A$  y  $B$  como sigue:  $A = \{X \leq x_1\}$ ,  $B = \{X \leq x_2\}$ . Entonces, puesto que  $x_1 \leq x_2$ , tenemos  $A \subset B$  y por el teorema 1.5,  $P(A) \leq P(B)$ , que es el resultado pedido.

(b) En el caso continuo tenemos

$$\begin{aligned} F(-\infty) &= \lim_{x \rightarrow -\infty} \int_{-\infty}^x f(s) ds = 0, \\ F(\infty) &= \lim_{x \rightarrow \infty} \int_{-\infty}^x f(s) ds = 1 \end{aligned}$$

En el caso discreto el argumento es análogo.

La función de distribución acumulativa es importante por varias razones. Esto es particularmente cierto cuando tratamos con una variable aleatoria continua, porque en este caso no podemos estudiar la conducta probabilística de  $X$  al calcular

$P(X = x)$ . Esa probabilidad es siempre igual a cero en el caso continuo. Sin embargo, podemos inquirir acerca de  $P(X \leq x)$  y, como lo demostramos en el próximo teorema, obtener la fdp de  $X$ .

**Teorema 4.4.** (a) Sea  $F$  la fda de una variable aleatoria continua con fdp  $f$ . Luego

$$f(x) = \frac{d}{dx} F(x),$$

para toda  $x$  en la cual  $F$  es diferenciable.

(b) Sea  $X$  una variable aleatoria discreta con valores posibles  $x_1, x_2, \dots$ , y supongamos que es posible rotular esos valores de modo que  $x_1 < x_2 < \dots$ . Sea  $F$  la fda de  $X$ . Entonces

$$p(x_j) = P(X = x_j) = F(x_j) - F(x_{j-1}). \quad (4.12)$$

*Demostración:* (a)  $F(x) = P(X \leq x) = \int_{-\infty}^x f(s) ds$ . Así, aplicando al teorema fundamental del cálculo obtenemos,  $F'(x) = f(x)$ .

(b) Puesto que supusimos  $x_1 < x_2 < \dots$ , tenemos

$$F(x_j) = P(X = x_j \cup X = x_{j-1} \cup \dots \cup X = x_1) \\ = p(x_j) + p(x_{j-1}) + \dots + p(x_1).$$

y

$$F(x_{j-1}) = P(X = x_{j-1} \cup X = x_{j-2} \cup \dots \cup X = x_1) \\ = p(x_{j-1}) + p(x_{j-2}) + \dots + p(x_1).$$

Luego  $F(x_j) - F(x_{j-1}) = P(X = x_j) = p(x_j)$ .

*Observación:* reconsideremos brevemente (a) del teorema anterior. Recordemos la definición de derivada de la función  $F$ :

$$F'(x) = \lim_{h \rightarrow 0} \frac{F(x+h) - F(x)}{h} \\ = \lim_{h \rightarrow 0^+} \frac{P(X \leq x+h) - P(X \leq x)}{h} \\ = \lim_{h \rightarrow 0^+} \frac{1}{h} [P(x < X \leq x+h)].$$

Así si  $h$  es pequeño y positivo

$$F'(x) = f(x) \cong \frac{P(x < X \leq x+h)}{h}.$$

Es decir,  $f(x)$  es aproximadamente igual a la «cantidad de probabilidad en el intervalo  $(x, x+h)$  por longitud  $h$ ». De aquí el nombre de *función densidad de probabilidad*.

**EJEMPLO 4.16.** Supongamos que una variable aleatoria continua tiene fda  $F$  dada por

$$F(x) = 0, \quad x \leq 0, \\ = 1 - e^{-x}, \quad x > 0.$$

Entonces  $F'(x) = e^{-x}$  para  $x > 0$ , y así la fdp  $f$  es dada por

$$f(x) = e^{-x}, \quad x \geq 0, \\ = 0, \quad \text{para cualquier otro valor}$$

*Observación:* una advertencia sobre la terminología puede ser de utilidad. Esta terminología, aunque no es muy uniforme, ha llegado a estandarizarse. Cuando hablamos de la *distribución de probabilidades* de una variable aleatoria  $X$  indicamos su fdp  $f$  si  $X$  es continua, o de su función de probabilidad puntual  $p$  definida para  $x_1, x_2, \dots$  si  $X$  es discreta. Cuando hablamos de la función de distribución acumulativa, o algunas veces sólo de la *función de distribución*, siempre nos referimos a  $F$ , en donde  $F(x) = P(X \leq x)$ .

## 4.6 Distribuciones mixtas

Hemos restringido nuestra exposición sólo a variables aleatorias que son discretas o continuas. Tales variables aleatorias ciertamente son las más importantes en las aplicaciones. Sin embargo, hay situaciones en las cuales podemos encontrar variables del tipo *mixto*: la variable aleatoria  $X$  puede tomar ciertos valores distintos, por ejemplo  $x_1, \dots, x_n$ , con probabilidad positiva y tomar también todos los valores en algún intervalo, por ejemplo  $a \leq x \leq b$ . La distribución de probabilidades de tales variables aleatorias se obtendría al combinar las ideas consideradas anteriormente para la descripción de las variables aleatorias discretas y continuas como sigue. A cada uno de los valores  $x_i$  se le asigna un número  $p(x_i)$  tal que  $p(x_i) \geq 0$ , para todo  $i$ , y tal que  $\sum_{i=1}^n p(x_i) = p < 1$ . Entonces definimos una función  $f$  que satisface  $f(x) \geq 0$ ,  $\int_a^b f(x) dx = 1 - p$ . Para todo  $a, b$ , con  $-\infty < a < b < +\infty$ ,

$$P(a \leq X \leq b) = \int_a^b f(x) dx + \sum_{\{i: a \leq x_i \leq b\}} p(x_i).$$

De esta manera satisfacemos la condición

$$P(S) = P(-\infty < X < \infty) = 1.$$

Una variable aleatoria del tipo mixto puede aparecer como sigue. Supóngase que estamos probando un equipo y sea  $X$  el tiempo de funcionamiento. En la mayoría de los problemas describiríamos  $X$  como una variable aleatoria continua con valores posibles  $x \geq 0$ . Sin embargo, hay algunos casos en los cuales hay una probabilidad positiva, de que el artículo no funcione del todo, es decir, falla al tiempo  $X = 0$ . En tal caso desearíamos modificar nuestro modelo y asignar una

## Otras características de las variables aleatorias

### 7.1 El valor esperado de una variable aleatoria

Consideremos la relación determinística  $ax + by = 0$ . Reconozcámosla como una relación lineal entre  $x$  y  $y$ . Las constantes  $a$  y  $b$  son los *parámetros* de esta relación en el sentido de que para cualquier elección particular de  $a$  y  $b$  obtenemos una función lineal específica. En otros casos uno o más parámetros pueden representar la relación que se considera. Por ejemplo, si  $y = ax^2 + bx + c$ , son necesarios tres parámetros. Si  $y = e^{-kx}$ , es suficiente un parámetro. No sólo una relación particular se caracteriza por los parámetros sino, recíprocamente, por una cierta relación podemos definir varios parámetros pertinentes. Por ejemplo, si  $ay + bx = 0$ , entonces  $m = -b/a$  representa la pendiente de la recta 0, si  $y = ax^2 + bx + c$ , entonces  $-b/2a$  representa el valor para el cual existe un máximo relativo o un mínimo relativo.

En los modelos matemáticos no determinísticos o aleatorios que hemos venido considerando, los parámetros también pueden usarse para señalar la distribución de probabilidades. Con cada distribución de probabilidades podemos asociar ciertos parámetros que dan información valiosa acerca de la distribución (tal como la pendiente de una recta da una información útil acerca de la relación lineal que representa).

**EJEMPLO 7.1.** Supongamos que  $X$  es una variable aleatoria continua con fdp  $f(x) = ke^{-kx}$ ,  $x \geq 0$ . Para verificar que esta es una fdp observe que  $\int_0^{\infty} ke^{-kx} dx = 1$  para toda  $k > 0$ , y que  $ke^{-kx} > 0$  para  $k > 0$ . Esta distribución se llama distribución exponencial, que estudiaremos más adelante con mucho detalle. Es una distribución muy útil para representar la duración, digamos  $X$ , de cierta clase de componentes de equipos. La interpretación de  $k$ , en este sentido, se discutirá también posteriormente.

**EJEMPLO 7.2.** Supongamos que en una línea indefinida de montaje se produce un artículo dado. La probabilidad de que un artículo sea defectuoso es  $p$ , y este valor es el mismo para todos los artículos. Suponiendo también que los artículos sucesivos son defectuosos ( $D$ ) o no defectuosos ( $N$ ), independientemente uno de otro. Sea la variable aleatoria  $X$  el número de artículos inspeccionados

hasta que se encuentra el primer artículo defectuoso. Así un resultado típico del experimento sería de la forma  $NNNND$ . Por tanto  $X(NNNND) = 5$ . Los valores posibles de  $X$  son:  $1, 2, \dots, n, \dots$ . Puesto que  $X = k$  si y sólo si los primeros  $(k - 1)$  artículos no son defectuosos y el  $k$ -ésimo artículo es defectuoso, asignamos la probabilidad siguiente al suceso  $\{X = k\}$ :  $P(X = k) = p(1 - p)^{k-1}$ ,  $k = 1, 2, \dots, n, \dots$ . Para verificar que esta es una legítima distribución de probabilidades observemos que

$$\begin{aligned} \sum_{k=1}^{\infty} p(1-p)^{k-1} &= p[1 + (1-p) + (1-p)^2 + \dots] \\ &= p \frac{1}{1 - (1-p)} = 1 \quad \text{si } 0 < |p| < 1. \end{aligned}$$

Así el parámetro  $p$  puede ser cualquier número que satisfaga  $0 < p < 1$ .

Supongamos que se especifican una variable aleatoria y su distribución de probabilidades. ¿Hay alguna manera de establecer esta distribución en función de escasos parámetros numéricos apropiados?

Antes de investigar la pregunta anterior, motivemos nuestra presentación al considerar el siguiente ejemplo.

**EJEMPLO 7.3.** Una máquina corta alambre de una longitud determinada. Debido a cierta imprecisión del mecanismo de corte, el largo del alambre cortado (en pulgadas), digamos  $X$ , se puede considerar como una variable aleatoria distribuida uniformemente en  $[11.5, 12.5]$ . El largo específico es de 12 pulgadas. Si  $11.7 \leq X < 12.2$ , el alambre se puede vender con una utilidad de \$0.25. Si  $X \geq 12.2$ , el alambre se puede cortar de nuevo, y por consiguiente se obtiene una utilidad de \$0.10. Y si  $X < 11.7$ , el alambre se descarta con una pérdida de \$0.02. Un cálculo sencillo indica que  $P(X \geq 12.2) = 0.3$ ,  $P(11.7 \leq X < 12.2) = 0.5$ , y  $P(X < 11.7) = 0.2$ .

Supongamos que se corta un gran número de muestras de alambre, digamos  $N$ . Sea  $N_S$  el número de muestras para las cuales  $X < 11.7$ ,  $N_R$  el número de muestras para las cuales  $11.7 \leq X < 12.2$ , y  $N_L$  el número de muestras para las cuales  $X \geq 12.2$ . Por tanto, la utilidad total obtenida de la producción de  $N$  muestras es igual  $T = N_S(-0.02) + N_R(0.25) + N_L(0.10)$ . La *utilidad total por alambre cortado*, digamos  $W$ , es igual  $W = (N_S/N)(-0.02) + (N_R/N)(0.25) + (N_L/N)(0.1)$ . (Observemos que  $W$  es una variable aleatoria, puesto que  $N_S$ ,  $N_R$ , y  $N_L$  son variables aleatorias.)

Ya hemos mencionado que la frecuencia relativa de un suceso está próxima a la probabilidad de ese suceso si el número de repeticiones en las que se basa la frecuencia relativa es grande. (Discutiremos con más precisión esto en el capítulo 12.) Por tanto, si  $N$  es grande, esperaríamos que  $N_S/N$  fuera próximo a 0.2,  $N_R/N$  sea próximo a 0.5 y  $N_L/N$  sea próximo a 0.3. Luego para  $N$  grande,  $W$  podría aproximarse como sigue:

$$W \simeq (0.2)(-0.02) + 0.5(0.25) + (0.3)(0.1) = \$0.151.$$

Así, si se produjese un gran número de alambres, esperaríamos tener una utilidad de \$0,151 por alambre. El número 0,151 se llama valor esperado de una variable aleatoria  $W$ .

**Definición.** Sea  $X$  una variable aleatoria discreta con valores posibles  $x_1, \dots, x_n, \dots$ . Sea  $p(x_i) = P(X = x_i)$ ,  $i = 1, 2, \dots, n, \dots$ . El valor esperado de  $X$  (esperanza matemática de  $X$ ), denotada por  $E(X)$ , se define como

$$E(X) = \sum_{i=1}^{\infty} x_i p(x_i) \quad (7.1)$$

si la serie  $\sum_{i=1}^{\infty} x_i p(x_i)$  converge absolutamente, es decir, si  $\sum_{i=1}^{\infty} |x_i| p(x_i) < \infty$ . Este número también se designa como el valor promedio de  $X$ .

**Observaciones:** (a) Si  $X$  toma sólo un número finito de valores, la expresión anterior llega a ser  $E(X) = \sum_{i=1}^n p(x_i) x_i$ . Esta se puede considerar como un «promedio ponderado» de los valores posibles  $x_1, \dots, x_n$ . Si todos los valores posibles son igualmente probables,  $E(X) = (1/n) \sum_{i=1}^n x_i$ , lo que representa el promedio aritmético ordinario de los  $n$  valores posibles.

(b) Si se lanza un dado regular y la variable aleatoria  $X$  designa el número de puntos que salen, entonces  $E(X) = 1/6(1 + 2 + 3 + 4 + 5 + 6) = 7/2$ . Este ejemplo sencillo ilustra, categóricamente, que  $E(X)$  no es el resultado que esperaríamos cuando  $X$  se observa una sola vez. ¡De hecho, en la situación anterior,  $E(X) = 7/2$  no es siquiera un valor posible de  $X$ ! Por el contrario, sucede que si obtenemos un gran número de observaciones independientes de  $X$ , tales como  $x_1, \dots, x_n$ , y calculamos el promedio aritmético de esos resultados, entonces, bajo condiciones generales regulares, el promedio aritmético estará cerca a  $E(X)$  en un sentido probabilístico. Por ejemplo, en la situación anterior, si lanzáramos el dado un gran número de veces y luego calculáramos el promedio aritmético de los diversos resultados, esperaríamos que este promedio llegase a estar más próximo a  $7/2$  cuanto más a menudo fuese lanzado el dado.

(c) Se debe observar la similitud entre la noción de valor esperado como se definió anteriormente (especialmente si  $X$  puede tomar sólo un número finito de valores) y la noción del promedio de un conjunto de números como,  $z_1, \dots, z_n$ . Corrientemente definimos  $\bar{z} = (1/n) \sum_{i=1}^n z_i$  como el promedio aritmético de los números  $z_1, \dots, z_n$ . Supóngase, además que tenemos los números  $z'_1, \dots, z'_k$ , donde  $z'_i$  ocurre  $n_i$  veces,  $\sum_{i=1}^k n_i = n$ . Haciendo  $f_i = n_i/n$ ,  $\sum_{i=1}^k f_i = 1$ , definimos el promedio ponderado de los números  $z'_1, \dots, z'_k$  como

$$\frac{1}{n} \sum_{i=1}^k n_i z'_i = \sum_{i=1}^k f_i z'_i.$$

Aunque hay un fuerte parecido entre el promedio ponderado anterior y la definición de  $E(X)$ , es importante señalar que este último es un número (parámetro) asociado con una distribución de probabilidades teórica, mientras que el primero es simplemente el resultado de combinar un conjunto de números de una manera especial. Sin embargo, es más que un parecido superficial. Consideremos una variable aleatoria  $X$  y sean  $x_1, \dots, x_n$  los valores obtenidos cuando el experimento que da origen a  $X$  se realizó  $n$  veces independientes. (Es decir,  $x_1, \dots, x_n$  simple-

mente representa los resultados de  $n$  medidas repetidas de la característica numérica  $X$ .) Sea  $\bar{x}$  el promedio aritmético de esos  $n$  números. Entonces, como discutiremos mucho más precisamente en el capítulo 12, si  $n$  es suficientemente grande,  $\bar{x}$  estará «próxima» a  $E(X)$  en un determinado sentido. Este resultado está muy relacionado con la idea (que también será discutida en el capítulo 12) de que la frecuencia relativa  $f_A$  asociada con  $n$  repeticiones de un experimento estará próxima a la probabilidad  $P(A)$  si  $f_A$  está basada en un gran número de repeticiones de  $\varepsilon$ .

**EJEMPLO 7.4.** Un fabricante produce artículos de tal modo que el 10 por ciento son defectuosos y el 90 por ciento no lo son. Si se produce un artículo defectuoso, el fabricante pierde \$1, mientras que un artículo sin defectos le produce una utilidad de \$5. Si  $X$  es la utilidad neta por artículo, entonces  $X$  es una variable aleatoria cuyo valor esperado es calculado como  $E(X) = -1(0,1) + 5(0,9) = \$4,40$ . Supongamos que se produce un gran número de tales artículos. Entonces, puesto que el fabricante perderá \$1 alrededor del 10 por ciento de las veces y ganará \$5 alrededor del 90 por ciento de las veces, él esperará ganar alrededor de \$4,40 por artículo a la larga.

**Teorema 7.1.** Sea  $X$  una variable aleatoria distribuida binomialmente con parámetro  $p$ , basada en  $n$  repeticiones de un experimento. Entonces

$$E(X) = np.$$

**Demostración:** puesto que  $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$ , tenemos

$$\begin{aligned} E(X) &= \sum_{k=0}^n k \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\ &= \sum_{k=1}^n \frac{n!}{(k-1)!(n-k)!} p^k (1-p)^{n-k} \end{aligned}$$

(ya que el término con  $k = 0$  es igual a cero). Sea  $s = k - 1$  en la suma anterior. Como  $k$  toma valores de uno hasta  $n$ ,  $s$  toma valores de cero hasta  $(n - 1)$ . Sustituyendo  $k$  en todas partes por  $(s + 1)$  obtenemos

$$\begin{aligned} E(X) &= \sum_{s=0}^{n-1} n \binom{n-1}{s} p^{s+1} (1-p)^{n-s-1} \\ &= np \sum_{s=0}^{n-1} \binom{n-1}{s} p^s (1-p)^{n-1-s}. \end{aligned}$$

La suma en la última expresión es simplemente la suma de probabilidades binomiales con  $n$  sustituido por  $(n - 1)$  [esto es  $(p + (1 - p))^{n-1}$ ] que, por tanto, es igual a uno. Esto establece el resultado.

**Observación:** el resultado anterior corresponde ciertamente a nuestra noción intuitiva. Porque se supone que la probabilidad de algún suceso  $A$  es 0,3, por ejemplo, cuando se rea-

liza un experimento. Si repetimos este experimento 100 veces, por ejemplo, esperaríamos que  $A$  ocurriera alrededor de  $100(0,3) = 30$  veces. El concepto de valor esperado, presentado anteriormente para variables discretas, se extenderá brevemente en el caso continuo.

**EJEMPLO 7.5.** Una máquina impresora tiene una probabilidad constante de 0,05 de fallar en cualquier día. Si la máquina no tiene fallas durante la semana, se obtiene una utilidad de \$ $S$ . Si ocurren 1 o 2 fallas, se obtiene una utilidad de \$ $R$  ( $R < S$ ). Si ocurren 3 o más fallas, se obtiene una utilidad de \$ $(-L)$ . (Suponemos que  $R$ ,  $S$ , y  $L$  son mayores que cero; también suponemos que si la máquina falla cualquier día, permanece fuera de uso durante el resto del día.) Sea  $X$  la utilidad obtenida en una semana de cinco días. Los valores posibles de  $X$  son  $R$ ,  $S$  y  $(-L)$ . Sea  $B$  el número de fallas por semana. Tenemos

$$P(B = k) = \binom{5}{k} (0,05)^k (0,95)^{5-k}, \quad k = 0, 1, \dots, 5$$

Puesto que  $X = S$  si y sólo si  $B = 0$ ,  $X = R$  si y sólo si  $B = 1$  ó  $2$ , y  $X = (-L)$  si y sólo si  $B = 3, 4$ , ó  $5$ , encontramos que,

$$\begin{aligned} E(X) &= SP(B = 0) + RP(B = 1 \text{ ó } 2) + (-L)P(B = 3, 4 \text{ ó } 5) \\ &= S(0,95)^5 + R[5(0,05)(0,95)^4 + 10(0,05)^2(0,95)^3] \\ &\quad + (-L)[10(0,05)^3(0,95)^2 + 5(0,05)^4(0,95) + (0,05)^5] \text{ dólares.} \end{aligned}$$

**Definición.** Sea  $X$  una variable aleatoria continua con fdp  $f$ . El *valor esperado* de  $X$  se define como

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx \quad (7.2)$$

Nuevamente puede suceder que esta integral (impropia) no converja. Por lo tanto decimos que  $E(X)$  existe si y sólo si

$$\int_{-\infty}^{\infty} |x|f(x)dx$$

es finita.

**Observación:** debemos observar la analogía entre el valor esperado de una variable aleatoria y el concepto de «centro de masa». Si una masa unitaria está distribuida a lo largo de la recta en los puntos discretos  $x_1, \dots, x_n, \dots$  y si  $p(x_i)$  es la masa en  $x_i$ , vemos entonces que  $\sum_{i=1}^{\infty} x_i p(x_i)$  representa el centro de masa (respecto al origen). De modo semejante, si una masa unitaria está distribuida continuamente en una recta, y si  $f(x)$  representa la densidad de masa en  $x$ , entonces  $\int_{-\infty}^{+\infty} xf(x)dx$  se puede interpretar nuevamente como el centro de masa. En el sentido anterior,  $E(X)$  puede representar «un centro» de la distribución de probabilidad. También,  $E(X)$  se llama algunas veces medida de tendencia central y está en las mismas unidades que  $X$ .




FIGURA 7.1

**EJEMPLO 7.6.** Vamos a definir la variable aleatoria  $X$  como sigue. Supongamos que  $X$  es el tiempo (en minutos) durante el cual un dispositivo eléctrico se utiliza a su máxima carga cierto período de tiempo determinado. Supongamos que  $X$  es una variable aleatoria continua con la siguiente fdp:

$$\begin{aligned} f(x) &= \frac{1}{(1500)^2} x, & 0 \leq x \leq 1500, \\ &= \frac{-1}{(1500)^2} (x - 3000), & 1500 \leq x \leq 3000, \\ &= 0, & \text{para cualquier otro valor.} \end{aligned}$$

Así

$$\begin{aligned} E(X) &= \int_{-\infty}^{+\infty} xf(x)dx \\ &= \frac{1}{(1500)(1500)} \left[ \int_0^{1500} x^2 dx - \int_{1500}^{3000} x(x - 3000) dx \right] \\ &= 1500 \text{ minutos.} \end{aligned}$$

(Ver figura 7.1.)

**EJEMPLO 7.7.** El contenido de ceniza en el carbón (porcentaje), digamos  $X$ , se puede considerar como una variable aleatoria continua con la siguiente fdp:  $f(x) = \frac{1}{4875} x^2$ ,  $10 \leq x \leq 25$ . Por lo tanto  $E(X) = \frac{1}{4875} \int_{10}^{25} x^3 dx = 19,5$  por ciento. Así el contenido esperado de ceniza en la muestra particular de carbón que se considera es 19,5 por ciento.

**Teorema 7.2.** Supongamos a  $X$  distribuida uniformemente en el intervalo  $[a, b]$ . Entonces

$$E(X) = \frac{a + b}{2}.$$

**Demostración:** la fdp de  $X$  está dada por  $f(x) = 1/(b - a)$ ,  $a \leq x \leq b$ . Por tanto

$$E(X) = \int_a^b \frac{x}{b - a} dx = \frac{1}{b - a} \left. \frac{x^2}{2} \right|_a^b = \frac{a + b}{2}.$$

(Nótese que esto representa el *punto medio* del intervalo  $[a, b]$ , como intuitivamente lo esperaríamos.)

*Observación:* valdría la pena recordar en este punto que una variable aleatoria  $X$  es una función de un espacio muestral  $S$  con relación al recorrido  $R_X$ . Como repetidamente lo hemos señalado, para la mayoría de las aplicaciones esta nos ha interesado sólo en el recorrido y en las probabilidades definidas en él. Esta noción de valor esperado fue completamente definida en función del recorrido [ver ecuaciones (7.1) y (7.2)]. Ocasionalmente, sin embargo, deberíamos observar la naturaleza funcional de  $X$ . Por ejemplo, ¿cómo expresamos la ecuación (7.1.) en función de resultados  $s \in S$ , suponiendo que  $S$  es finito? Puesto que  $x_i = X(s)$  para una  $s \in S$  y puesto que

$$p(x_i) = P[s: X(s) = x_i],$$

podemos escribir

$$E(X) = \sum_{i=1}^n x_i p(x_i) = \sum_{s \in S} X(s) P(s), \quad (7.3)$$

en donde  $P(s)$  es la probabilidad del suceso  $\{s\} \subset S$ . Por ejemplo, si el experimento consiste en clasificar tres artículos como defectuosos ( $D$ ) o no defectuosos ( $N$ ), un espacio muestral para este experimento sería

$$S = \{NNN, NND, NDN, DNN, NDD, DND, DDN, DDD\}.$$

Si  $X$  está definida como el número de defectuosos, y si se supone que todos los resultados anteriores son igualmente posibles, tenemos de acuerdo con la ecuación (7.3.)

$$\begin{aligned} E(X) &= \sum_{s \in S} X(s) P(s) \\ &= 0 \cdot \left(\frac{1}{8}\right) + 1 \cdot \left(\frac{1}{8}\right) + 1 \cdot \left(\frac{1}{8}\right) + 1 \cdot \left(\frac{1}{8}\right) + 2 \cdot \left(\frac{1}{8}\right) + 2 \cdot \left(\frac{1}{8}\right) + 2 \cdot \left(\frac{1}{8}\right) + 3 \cdot \left(\frac{1}{8}\right) \\ &= \frac{3}{2}. \end{aligned}$$

Se habría podido obtener este resultado más fácilmente al aplicar directamente la ecuación (7.1.) Sin embargo, es bueno recordar que para emplear la ecuación (7.1) necesitábamos conocer los valores  $p(x_i)$ , lo que a su vez significaba la necesidad de un cálculo tal como el utilizado anteriormente. Lo importante es que una vez que se conoce la distribución de probabilidades sobre  $R_X$  [en este caso los valores de  $p(x_i)$ ], podemos suprimir la relación funcional entre  $R_X$  y  $S$ .

## 7.2 Esperanza de una función de una variable aleatoria

Como lo expusimos previamente, si  $X$  es una variable aleatoria y si  $Y = H(X)$ , es una función de  $X$ , entonces  $Y$  es también una variable aleatoria con una distribución de probabilidades. Por lo tanto será interesante y significativo evaluar  $E(Y)$ . Hay dos maneras de evaluar  $E(Y)$  que resultan equivalentes. Demostrar que en general son equivalentes no es trivial y probaremos sólo un caso especial. Sin embargo, es importante que el lector comprenda los dos enfoques presentados a continuación.

**Definición.** Sea  $X$  una variable aleatoria y sea  $Y = H(X)$ .

(a) Si  $Y$  es una variable aleatoria discreta con valores posibles  $y_1, y_2, \dots$  y si  $q(y_i) = P(Y = y_i)$ , definimos

$$E(Y) = \sum_{i=1}^{\infty} y_i q(y_i). \quad (7.4)$$

(b) Si  $Y$  es una variable aleatoria continua con fdp  $g$ , definimos

$$E(Y) = \int_{-\infty}^{+\infty} y g(y) dy. \quad (7.5)$$

*Observación:* naturalmente estas definiciones son enteramente consistentes con la definición previa dada para el valor esperado de una variable aleatoria. De hecho, lo anterior representa simplemente una repetición en función de  $Y$ . Una «desventaja» de aplicar la definición anterior a fin de obtener  $E(Y)$  es que la distribución de probabilidades de  $Y$  (es decir, la distribución de probabilidades en el recorrido  $R_Y$ ) es necesaria. En los capítulos anteriores, expusimos métodos mediante los cuales podemos obtener o las probabilidades puntuales  $q(y_i)$  o  $g$ , la fdp de  $Y$ . Sin embargo, el problema que aparece es si podemos obtener  $E(Y)$  sin encontrar primero la distribución de probabilidades de  $Y$ , sólo a partir del conocimiento de la distribución de probabilidades de  $X$ . La respuesta es afirmativa como lo indica el siguiente teorema.

**Teorema 7.3.** Sea  $X$  una variable aleatoria y sea  $Y = H(X)$ .

(a) Si  $X$  es una variable aleatoria discreta y  $p(x_i) = P(X = x_i)$ , tenemos

$$E(Y) = E(H(X)) = \sum_{j=1}^{\infty} H(x_j) p(x_j). \quad (7.6)$$

(b) Si  $X$  es una variable aleatoria continua con fdp  $f$ , tenemos

$$E(Y) = E(H(X)) = \int_{-\infty}^{+\infty} H(x) f(x) dx. \quad (7.7)$$

*Observación:* este teorema hace mucho más sencilla la evaluación de  $E(Y)$ , porque quiere decir que no necesitamos encontrar la distribución de probabilidades de  $Y$  a fin de evaluar  $E(Y)$ . Es suficiente el conocimiento de la distribución de probabilidades de  $X$ .

*Demostración:* [sólo demostraremos la ecuación (7.6). La demostración de la ecuación (7.7) es algo más complicada]. Consideremos la suma  $\sum_{j=1}^{\infty} H(x_j) p(x_j) = \sum_{j=1}^{\infty} (\sum_i H(x_i) p(x_i))$ , en donde la suma interior se toma sobre todos los índices  $i$  para los cuales  $H(x_i) = y_j$ , para un  $y_j$  fijo. Por tanto todos los términos  $H(x_i)$  son constantes en la suma interior. Por tanto

$$\sum_{j=1}^{\infty} H(x_j)p(x_j) = \sum_{j=1}^{\infty} y_j \sum_i p(x_i).$$

Pero,

$$\sum_i p(x_i) = \sum_i P[x|H(x_i) = y_j] = q(y_j).$$

Por tanto,  $\sum_{j=1}^{\infty} H(x_j)p(x_j) = \sum_{j=1}^{\infty} y_j q(y_j)$ , lo que establece la ecuación (7.6).

*Observación:* el método de demostración es equivalente esencialmente con el método de contar en el cual ponemos juntos todos los artículos que tienen el mismo valor. Así, si queremos encontrar la suma total de los valores 1, 1, 2, 3, 5, 3, 2, 1, 2, 2, 3, podemos sumarlos directamente o indicar que puesto que hay 3 unos, 4 doses, 3 treses y 1 cinco, la suma total es igual

$$3(1) + 4(2) + 3(3) + 1(5) = 25.$$

**EJEMPLO 7.8.** Sea  $V$  la velocidad del viento (kph) y supongamos que  $V$  está distribuida uniformemente en el intervalo  $[0, 10]$ . La presión,  $W$  (en lb/pie<sup>2</sup>), sobre la superficie del ala de un aeroplano está dada por la relación:  $W = 0,003 V^2$ . Para encontrar el valor esperado de  $W$ ,  $E(W)$ , podemos proceder de dos maneras:

(a) Usando el teorema 7.3., tenemos

$$\begin{aligned} E(W) &= \int_0^{10} 0,003v^2 f(v) dv \\ &= \int_0^{10} 0,003v^2 \frac{1}{10} dv \\ &= 0,1 \text{ lb/pie}^2 \end{aligned}$$

(b) Usando la definición de  $E(W)$ , necesitamos encontrar primero la fdp de  $W$ ,  $g$ , y luego evaluar  $\int_{-\infty}^{\infty} wg(w)dw$ . Para encontrar  $g(w)$ , observemos que  $w = 0,003v^2$  es una función monótona de  $v$ , para  $v \geq 0$ . Podemos aplicar el teorema 5.1 y obtenemos

$$\begin{aligned} g(w) &= \frac{1}{10} \left| \frac{dv}{dw} \right| \\ &= \frac{1}{2} \sqrt{\frac{10}{3}} w^{-1/2}, \quad 0 \leq w \leq 0,3, \\ &= 0, \quad \text{para cualquier otro valor.} \end{aligned}$$

Por tanto

$$E(W) = \int_0^{0,3} wg(w)dw = 0,1$$

después de un cálculo sencillo. Así, como lo indicó el teorema las dos evaluaciones de  $E(W)$  producen el mismo resultado.

**EJEMPLO 7.9.** En muchos problemas nos interesa sólo la *magnitud* de una variable aleatoria sin consideración a su signo algebraico. Es decir, nos interesa  $|X|$ . Supongamos que  $X$  es una variable aleatoria continua con la siguiente fdp:

$$\begin{aligned} f(x) &= \frac{e^x}{2} \quad \text{si } x \leq 0. \\ &= \frac{e^{-x}}{2} \quad \text{si } x > 0. \end{aligned}$$

Sea  $Y = |X|$ . Para obtener  $E(Y)$  debemos proceder de una de las dos maneras.

(a) Usando el teorema 7.3, tenemos

$$\begin{aligned} E(Y) &= \int_{-\infty}^{+\infty} |x|f(x)dx \\ &= \frac{1}{2} \left[ \int_{-\infty}^0 (-x)e^x dx + \int_0^{\infty} (x)e^{-x} dx \right] \\ &= \frac{1}{2} [1 + 1] = 1. \end{aligned}$$

(b) Para evaluar  $E(Y)$  usando la definición, necesitamos obtener la fdp de  $Y = |X|$ ,  $g$ . Sea  $G$  la fda de  $Y$ . Luego

$$G(y) = P(Y \leq y) = P[|X| \leq y] = P[-y \leq X \leq y] = 2P(0 \leq X \leq y),$$

puesto que la fdp de  $X$  es simétrica respecto al cero. Por lo tanto

$$G(y) = 2 \int_0^y f(x)dx = 2 \int_0^y \frac{e^{-x}}{2} dx = -e^{-y} + 1.$$

Así tenemos para  $g$ , la fdp de  $Y$ ,  $g(y) = G'(y) = e^{-y}$ ,  $y \geq 0$ . Por lo tanto  $E(Y) = \int_0^{\infty} yg(y)dy = \int_0^{\infty} ye^{-y}dy = 1$ , como antes.

**EJEMPLO 7.10.** En muchos problemas podemos usar el valor esperado de una variable aleatoria a fin de hacer ciertas decisiones de una manera óptima.

Supóngase que un fabricante produce cierto tipo de aceite lubricante que pierde alguno de sus atributos especiales si no se usa dentro de cierto período de tiempo. Sea  $X$  el número de unidades de aceite pedidas al fabricante durante cada año. (Una unidad es igual a 1000 galones.) Supongamos que  $X$  es una variable aleatoria continua, distribuida uniformemente en  $[2, 4]$ . Por lo tanto la fdp  $f$  tiene la forma,

$$\begin{aligned} f(x) &= \frac{1}{2}, \quad 2 \leq x \leq 4, \\ &= 0, \quad \text{para cualquier otro valor.} \end{aligned}$$

Supongamos que por cada una de las unidades vendidas se obtiene una utilidad de \$300, mientras que cada una de las unidades no vendidas (durante un año determinado) produce una pérdida de \$100, ya que una unidad no utilizada tendrá que ser descartada. Suponiendo que el fabricante debe decidir pocos meses antes del comienzo de cada año cuánto producirá, y que decide fabricar  $Y$  unidades. ( $Y$  no es una variable aleatoria, está especificada por el fabricante.) Sea  $Z$  la utilidad por año (en pesos). Aquí  $Z$  es evidentemente una variable aleatoria puesto que es una función de la variable aleatoria  $X$ . Específicamente,  $Z = H(X)$  en donde

$$\begin{aligned} H(X) &= 300Y & \text{si } X \geq Y, \\ &= 300X + (-100)(Y - X), & \text{si } X < Y. \end{aligned}$$

(La última expresión puede escribirse como  $400X - 100Y$ ).

A fin de obtener  $E(Z)$  aplicaremos el teorema 7.3 y escribimos

$$\begin{aligned} E(Z) &= \int_{-\infty}^{+\infty} H(x)f(x)dx \\ &= \frac{1}{2} \int_2^4 H(x)dx. \end{aligned}$$

FIGURA 7.2

Para evaluar esta integral debemos considerar tres casos:  $Y < 2$ ,  $2 \leq Y \leq 4$ , y  $Y > 4$ . Con ayuda de la figura 7.2 y después de algunas simplificaciones obtenemos

$$\begin{aligned} E(Z) &= 300Y & \text{si } Y \leq 2 \\ &= -100Y^2 + 700Y - 400 & \text{si } 2 < Y < 4 \\ &= 1200 - 100Y & \text{si } Y \geq 4. \end{aligned}$$

La pregunta siguiente es de interés. ¿Cómo elegiría el fabricante el valor de  $Y$  a fin de maximizar la utilidad esperada? Podemos responder fácilmente esta pregunta al poner simplemente  $dE(Z)/dY = 0$ . Esto produce  $Y = 3.5$ . (Ver figura 7.3.)




FIGURA 7.3

### 7.3 Variables aleatorias bidimensionales

Los conceptos discutidos anteriormente para el caso unidimensional también se mantienen para el caso de variables aleatorias de mayor dimensión. En particular para el caso bidimensional, hacemos la siguiente definición.

**Definición.** Sea  $(X, Y)$  una variable aleatoria bidimensional y sea  $Z = H(X, Y)$  una función real de  $(X, Y)$ . Por lo tanto  $Z$  es una variable aleatoria (unidimensional) y definimos  $E(Z)$  como sigue:

(a) Si  $Z$  es una variable aleatoria discreta con valores posibles  $z_1, z_2, \dots$  y con

$$p(z_i) = P(Z = z_i),$$

entonces

$$E(Z) = \sum_{i=1}^{\infty} z_i p(z_i). \quad (7.8)$$

(b) Si  $Z$  es una variable aleatoria continua con fdp  $f$ , tenemos

$$E(Z) = \int_{-\infty}^{+\infty} zf(z)dz. \quad (7.9)$$

Como en el caso unidimensional, se puede demostrar el teorema siguiente (análogo al teorema 7.3.)

**Teorema 7.4.** Sea  $(X, Y)$  una variable aleatoria bidimensional y sea  $Z = H(X, Y)$ .

(a) Si  $(X, Y)$  es una variable aleatoria discreta y si

$$p(x_i, y_j) = P(X = x_i, Y = y_j), \quad i, j = 1, 2, \dots,$$

tenemos

$$E(Z) = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} H(x_i, y_j) p(x_i, y_j). \quad (7.10)$$

(b) Si  $(X, Y)$  es una variable aleatoria continua con fdp conjunta  $f$ , tenemos

$$E(Z) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} H(x, y) f(x, y) dx dy. \quad (7.11)$$

**Observación:** no demostraremos el teorema 7.4. Otra vez, tal como en el caso unidimensional, este es un resultado muy útil puesto que indica que *no* necesitamos encontrar la distribución de probabilidades de la variable aleatoria  $Z$  a fin de evaluar su esperanza. Podemos encontrar directamente  $E(Z)$  a partir del conocimiento de la distribución conjunta de  $(X, Y)$ .

**EJEMPLO 7.11.** Reconsideremos el ejemplo 6.14 y encontremos  $E(E)$  en donde  $E = IR$ . Encontramos que  $I$  y  $R$  son variables aleatorias independientes con las siguientes fdp  $g$  y  $h$  respectivamente:

$$g(i) = 2i, \quad 0 \leq i \leq 1; \quad h(r) = r^2/9, \quad 0 \leq r \leq 3.$$

También encontramos que la fdp de  $E$  es  $p(e) = \frac{2}{9}e(3-e)$ ,  $0 \leq e \leq 3$ . Puesto que  $I$  y  $R$  son variables aleatorias independientes, la fdp conjunta de  $(I, R)$  es sencillamente el producto de las fdp de  $I$  y  $R$ :  $f(i, r) = \frac{2}{9}ir^2$ ,  $0 \leq i \leq 1$ ,  $0 \leq r \leq 3$ . Para evaluar  $E(E)$  usando el teorema 7.4 tenemos

$$\begin{aligned} E(E) &= \int_0^3 \int_0^1 ir f(i, r) di dr = \int_0^3 \int_0^1 ir^2 \frac{2}{9} ir^2 di dr \\ &= \frac{2}{9} \int_0^3 i^2 di \int_0^3 r^3 dr = \frac{3}{2}. \end{aligned}$$

Usando directamente la definición (7.9), tenemos

$$\begin{aligned} E(E) &= \int_0^3 ep(e) de = \int_0^3 e \frac{2}{9} e(3-e) de \\ &= \frac{2}{9} \int_0^3 (3e^2 - e^3) de = \frac{3}{2}. \end{aligned}$$

#### 7.4 Propiedades del valor esperado

Haremos una lista de propiedades del valor esperado de una variable aleatoria que será muy útil en el trabajo futuro. En cada caso supondremos que existen todos los valores esperados a los cuales nos referimos. Daremos las demostraciones sólo para el caso continuo. El lector debe ser capaz de dar el argumento para el caso discreto sustituyendo sencillamente las integrales por sumatorias.

**Propiedad 7.1.** Si  $X = C$  en donde  $C$  es una constante, entonces  $E(X) = C$ .

*Demostración*

$$E(X) = \int_{-\infty}^{+\infty} Cf(x) dx = C \int_{-\infty}^{+\infty} f(x) dx = C.$$




FIGURA 7.4

*Observación:* el significado de  $X$  igual  $C$  es el siguiente. Puesto que  $X$  es una función del espacio muestral a  $R_X$ , el significado de lo anterior es que  $R_X$  consta de un solo valor  $C$ . Por tanto  $X$  es igual a  $C$  si y sólo si  $P[X(s) = C] = 1$ . Esta noción se explica mejor en función de la fda de  $X$ . Llamada,  $F(x) = 0$ , si  $x < C$ ;  $F(x)$  es igual a 1, si  $x \geq C$  (figura 7.4). Tal variable aleatoria se llama *degenerada* algunas veces.

**Propiedad 7.2.** Supongamos que  $C$  es una constante y  $X$  es una variable aleatoria. Entonces  $E(CX) = CE(X)$ .

$$\text{Demostración: } E(CX) = \int_{-\infty}^{+\infty} Cx f(x) dx = C \int_{-\infty}^{+\infty} x f(x) dx = CE(X).$$

**Propiedad 7.3.** Sea  $(X, Y)$  una variable aleatoria bidimensional con una distribución de probabilidades conjunta. Sean  $Z = H_1(X, Y)$  y  $W = H_2(X, Y)$ . Entonces  $E(Z + W) = E(Z) + E(W)$ .

*Demostración*

$$\begin{aligned} E(Z + W) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [H_1(x, y) + H_2(x, y)] f(x, y) dx dy \\ &\quad [\text{en donde } f \text{ es la fdp conjunta de } (X, Y)] \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} H_1(x, y) f(x, y) dx dy + \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} H_2(x, y) f(x, y) dx dy \\ &= E(Z) + E(W). \end{aligned}$$

**Propiedad 7.4.** Sean  $X$  y  $Y$  dos variables aleatorias cualquiera. Entonces  $E(X + Y) = E(X) + E(Y)$ .

*Demostración:* esta se deduce de inmediato de la propiedad 7.3 al hacer  $H_1(X, Y) = X$ , y  $H_2(X, Y) = Y$ .

*Observaciones:* (a) Combinando las propiedades 7.1, 7.2 y 7.4 observamos el siguiente hecho importante: si  $Y = aX + b$ , en donde  $a$  y  $b$  son constantes, entonces  $E(Y) = aE(X) + b$ . En palabras: la esperanza de una función lineal es esa misma función lineal de las esperanzas. Esto *no* es cierto a menos que esté implicada una función lineal y es un error común creer de otro modo. Por ejemplo,  $E(X^2) \neq (E(X))^2$ ,  $E(\ln X) \neq \ln E(X)$ , etc. Así si  $X$  toma los valores  $-1$  y  $+1$ , cada uno con probabilidad  $\frac{1}{2}$ , entonces  $E(X) = 0$ . Sin embargo,

$$E(X^2) = (-1)^2\left(\frac{1}{2}\right) + (1)^2\left(\frac{1}{2}\right) = 1 \neq 0^2.$$

(b) En general, es difícil obtener expresiones para  $E(1/X)$  o  $E(X^{1/2})$ , por ejemplo, en función de  $1/E(X)$  o  $(E(X))^{1/2}$ . Sin embargo, están disponibles algunas desigualdades, que son muy fáciles de derivar. (Ver los artículos de Fleiss, Murthy y Pillai, y Gurland en los números de febrero y diciembre de 1966 y abril de 1967, respectivamente, de *The American Statistician*.)

Por ejemplo, tenemos:

- (1) Si  $X$  toma solo valores positivos y tiene una esperanza finita, entonces  $E(1/X) \geq 1/E(X)$ .
- (2) Bajo la misma hipótesis que en (1),  $E(X^{1/2}) \leq (E(X))^{1/2}$ .

**Propiedad 7.5.** Sean  $X_1, \dots, X_n$   $n$  variables aleatorias. Entonces

$$E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n).$$

**Demostración:** esta se deduce inmediatamente de la propiedad 7.4 al aplicar la inducción matemática.

**Observación:** combinando esta propiedad con la anterior, obtenemos

$$E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i E(X_i),$$

en donde las  $a_i$  son constantes.

**Propiedad 7.6.** Sea  $(X, Y)$  una variable aleatoria bidimensional y supongamos que  $X$  y  $Y$  son independientes. Entonces  $E(XY) = E(X)E(Y)$ .

**Demostración:**

$$\begin{aligned} E(XY) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf(x, y)dx dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyg(x)h(y)dx dy \\ &= \int_{-\infty}^{+\infty} xg(x)dx \int_{-\infty}^{+\infty} yh(y)dy = E(X)E(Y). \end{aligned}$$

**Observación:** la hipótesis adicional de independencia es necesaria para establecer la propiedad 7.6, mientras que no se necesitó ninguna suposición para obtener la propiedad 7.4.

**EJEMPLO 7.12.** (Este ejemplo se basa en un problema de *An Introduction to Probability Theory and Its Applications* de W. Feller, página 225.)

Supóngase que necesitamos examinar un gran número de personas, buscando cierta característica, con resultados positivo o negativo. Más aún, supongamos que se toman muestras de varias personas y se prueba la muestra combinada como una unidad, tal como puede ser el caso en ciertos tipos de exámenes de sangre.

**Suposición:** la muestra combinada dará un resultado negativo si y sólo si todas las muestras componentes son negativas.

Así, en el caso de resultados positivos (de la muestra combinada), todas las muestras deben ser individualmente probadas de nuevo para determinar cuáles son positivas. Si las  $N$  personas son divididas en  $n$  grupos de  $k$  personas (suponiendo  $N = kn$ ) aparecen las siguientes elecciones:

- (a) Examinar a todas las  $N$  personas individualmente, solicitando  $N$  pruebas.
- (b) Examinar grupos de  $k$  muestras, lo cual puede necesitar tan pocos como  $n = N/k$  o tantos como  $(k+1)n = N + n$  pruebas.

Nuestro objetivo será estudiar el número esperado de pruebas necesarias en (b) y luego compararlas con  $N$ .

**Suposición:** la probabilidad de que el resultado de la prueba sea positivo es

igual a  $p$  y es la misma para todas las personas. Aún más, los resultados de las pruebas para las personas del mismo grupo que se examina son independientes. Sea  $X$  = número de pruebas necesarias para determinar la característica que se estudia para todas las  $N$  personas, y sea  $X_i$  = número de pruebas necesarias para examinar personas en el  $i$ -ésimo grupo,  $i = 1, \dots, n$ .

Luego  $X = X_1 + \dots + X_n$ , y por lo tanto  $E(X) = E(X_1) + \dots + E(X_n)$ , lo cual es igual a  $nE(X_1)$ , puesto que todos los  $X_i$  tienen la misma esperanza.  $X_1$  sólo toma dos valores: 1 y  $k+1$ . Además,

$$\begin{aligned} P(X_1 = 1) &= P(\text{todas las } k \text{ personas en el grupo 1 son negativas}) \\ &= (1-p)^k. \end{aligned}$$

Por tanto

$$P(X_1 = k+1) = 1 - (1-p)^k$$

y luego

$$\begin{aligned} E(X_1) &= 1 \cdot (1-p)^k + (k+1)[1 - (1-p)^k] \\ &= k[1 - (1-p)^k] + k^{-1}. \end{aligned}$$

Así

$$E(X) = nE(X_1) = N[1 - (1-p)^k + k^{-1}].$$

(La fórmula anterior es válida sólo para  $k > 1$ , puesto que para  $k = 1$  da  $E(X) = N + pn$ , lo cual obviamente es falso.)

Un asunto de interés es la elección de  $k$  para el cual el anterior  $E(X)$  es más pequeño. Esto puede ser fácilmente manejado por algún procedimiento numérico. (Ver problema 7.11a.)

Finalmente, observemos que para que la «prueba en grupo» sea preferible a la prueba individual, deberíamos tener  $E(X) < N$ , esto es,  $1 - (1-p)^k + k^{-1} < 1$ , lo cual es equivalente a  $k^{-1} < (1-p)^k$ . Esto *no puede* ocurrir si  $(1-p) < \frac{1}{2}$ . Porque en ese caso  $(1-p)^k < \frac{1}{2}^k < 1/k$ , la última desigualdad proviene del hecho de que  $2^k > k$ . Así obtenemos la siguiente conclusión importante: si  $p$ , la probabilidad de una prueba positiva en cualquier persona determinada, es mayor que  $\frac{1}{2}$ , entonces *no es aconsejable* agrupar las muestras antes de examinar. (Ver problema 7.11b.)

**EJEMPLO 7.13.** Apliquemos algunas de las propiedades anteriores para derivar (nuevamente) la esperanza de una variable aleatoria distribuida binomialmente. El método usado puede aplicarse con ventaja en muchas situaciones semejantes.

Consideremos  $n$  repeticiones independientes y sea  $X$  el número de veces que ocurre un suceso  $A$ . Sea  $p$  igual a  $P(A)$  y supongamos que este número es constante para todas las repeticiones consideradas.

Definamos las variables auxiliares  $Y_1, \dots, Y_n$  como sigue:

$$\begin{aligned} Y_i &= 1 && \text{si el suceso } A \text{ ocurre en la } i\text{-ésima repetición,} \\ &= 0, && \text{en cualquier otro caso.} \end{aligned}$$

Por lo tanto

$$X = Y_1 + Y_2 + \cdots + Y_n,$$

y aplicando la propiedad 7.5, obtenemos

$$E(X) = E(Y_1) + \cdots + E(Y_n).$$

Sin embargo,

$$E(Y_i) = 1(p) + 0(1 - p) = p, \quad \text{para todo } i.$$

Así  $E(X) = np$ , lo que concuerda con el resultado previo.

*Observación:* reinterpretemos este importante resultado. Consideremos la variable aleatoria  $X/n$ . Esta representa la frecuencia relativa del suceso  $A$  entre las  $n$  repeticiones de  $\varepsilon$ . Usando la propiedad 7.2, tenemos  $E(X/n) = (np)/n = p$ . Esto, intuitivamente, es como debería ser, porque expresa que la frecuencia relativa esperada del suceso  $A$  es  $p$ , donde  $p = P(A)$ . Representa la primera verificación teórica del hecho de que hay una relación entre la frecuencia relativa de un suceso y la probabilidad de ese suceso. En un capítulo posterior, obtendremos más resultados que dan una relación mucho más precisa entre la frecuencia relativa y la probabilidad.

**EJEMPLO 7.14.** Supóngase que la demanda  $D$ , por semana, de cierto producto es una variable aleatoria con determinada distribución de probabilidades,  $P(D = n) = p(n)$ ,  $n = 0, 1, 2, \dots$ . Supóngase que el costo del fabricante es  $C_1$  dólares por artículo, mientras que él vende el artículo por  $C_2$  dólares. Cualquier artículo que no se venda al término de la semana debe almacenarse con un costo de  $C_3$  dólares por artículo. Si el fabricante decide producir  $N$  artículos al comienzo de la semana, ¿cuál es su utilidad esperada por semana? ¿Para qué valor de  $N$  es máxima la utilidad esperada? Si  $T$  es la utilidad por semana, tenemos

$$\begin{aligned} T &= NC_2 - NC_1 & \text{si } D > N, \\ &= DC_2 - C_1N - C_3(N - D) & \text{si } D \leq N. \end{aligned}$$

Reescribiendo lo anterior, obtenemos

$$\begin{aligned} T &= N(C_2 - C_1) & \text{si } D > N, \\ &= (C_2 + C_3)D - N(C_1 + C_3) & \text{si } D \leq N. \end{aligned}$$

Por tanto la utilidad esperada se obtiene como sigue:

$$\begin{aligned} E(T) &= N(C_2 - C_1)P(D > N) + (C_2 + C_3) \sum_{n=0}^N np(n) \\ &\quad - N(C_1 + C_3)P(D \leq N) \end{aligned}$$

$$\begin{aligned} &= N(C_2 - C_1) \sum_{n=N+1}^{\infty} p(n) + (C_2 + C_3) \sum_{n=0}^N np(n) \\ &\quad - N(C_1 + C_3) \sum_{n=0}^N p(n) \\ &= N(C_2 - C_1) + (C_2 + C_3) \left[ \sum_{n=0}^N np(n) - N \sum_{n=0}^N p(n) \right] \\ &= N(C_2 - C_1) + (C_2 + C_3) \sum_{n=0}^N p(n)(n - N). \end{aligned}$$

Supongamos que se sabe que para  $D$  es apropiada la siguiente distribución de probabilidades:  $P(D = n) = \frac{1}{5}$ ,  $n = 1, 2, 3, 4, 5$ . Por tanto

$$\begin{aligned} E(T) &= N(C_2 - C_1) + \frac{(C_2 + C_3)}{5} [N(N+1)/2 - N^2] & \text{si } N \leq 5, \\ &= N(C_2 - C_1) + (C_2 + C_3)\frac{1}{5}(15 - 5N) & \text{si } N > 5. \end{aligned}$$

Supongamos que  $C_2 = \$9$ ,  $C_1 = \$3$ , y  $C_3 = \$1$ . Por tanto

$$\begin{aligned} E(T) &= 6N + 2 \left[ \frac{N(N+1)}{2} - N^2 \right] & \text{si } N \leq 5, \\ &= 6N + 2(15 - 5N) & \text{si } N > 5, \\ &= 7N - N^2 & \text{si } N \leq 5, \\ &= 30 - 4N & \text{si } N > 5. \end{aligned}$$




FIGURA 7.5

Luego el máximo ocurre para  $N = 3,5$ . (Ver figura 7.5.) Para  $N = 3$  ó  $4$ , tenemos  $E(T) = 12$ , el cual es el máximo obtenible puesto que  $N$  es un entero.

## 7.5 La varianza de una variable aleatoria

Supongamos que para una variable aleatoria  $X$  encontramos que  $E(X)$  es igual a 2. ¿Cuál es la importancia de esto? Es importante que no atribuyamos más significado a esta información que la justificada. Significa, sencillamente, que si consideramos un gran número de valores de  $X$ ,  $x_1, \dots, x_n$ , y promediamos esos valores de  $X$ , este promedio se aproximará a 2 si  $n$  es grande. Sin embargo, es muy importante que no demos mucha importancia a un valor esperado. Por ejemplo supóngase que  $X$  representa la duración de una bombilla que se recibe de un fabricante, y que  $E(X) = 1000$  horas. Esto podría significar una de varias posibilidades. Podría significar que se espera que la mayor parte de las bombillas dure entre 900 y 1100 horas. También podría significar que las bombillas que se entregan están formadas por dos tipos de bombillas muy diferentes: alrededor de la mitad son de muy alta calidad y con duración de cerca de 1300 horas, mientras que la otra mitad son de muy mala calidad y durarán cerca de 700 horas.

Hay una necesidad obvia de presentar una medida cuantitativa que distinga entre tales situaciones. Varias medidas se sugieren por sí mismas, pero la siguiente es la cantidad usada más comúnmente.

**Definición.** Sea  $X$  una variable aleatoria. Definimos la *varianza* de  $X$ , denotada por  $V(X)$  o  $\sigma_X^2$ , como sigue:

$$V(X) = E[X - E(X)]^2. \quad (7.12)$$

La raíz cuadrada positiva de  $V(X)$  se llama *desviación estándar* de  $X$  y está denotada por  $\sigma_X$ .

**Observaciones:** (a) El número  $V(X)$  está expresado en *unidades cuadradas* de  $X$ . Esto es, si  $X$  se mide en horas, entonces  $V(X)$  está expresada en (horas)<sup>2</sup>. Esta es una razón para considerar la desviación estándar. Se expresa en las *mismas* unidades que  $X$ .

(b) Otra medida posible podría haber sido  $E|X - E(X)|$ . Por diferentes razones, una de las cuales es que  $X^2$  es una función «mejor comportada» que  $|X|$ , se prefiere la varianza.

(c) Si interpretamos a  $E(X)$  como el centro de una masa unitaria distribuida sobre una recta, podemos interpretar  $V(X)$  como el momento de inercia de esta masa, respecto a un eje perpendicular a través del centro de masa.

(d)  $V(X)$  como se definió en la ecuación (7.12) es un caso especial del concepto más general siguiente. El  $k$ -ésimo momento de la variable aleatoria  $X$  respecto a su esperanza se define como  $\mu_k = E[X - E(X)]^k$ . Evidentemente para  $k = 2$ , obtenemos la varianza.

El cálculo de  $V(X)$  se simplifica con la ayuda del resultado siguiente.

**Teorema 7.5.**

$$V(X) = E(X^2) - [E(X)]^2.$$

**Demostración:** desarrollando  $E[X - E(X)]^2$  y usando las propiedades de la esperanza establecidas previamente, obtenemos

$$\begin{aligned} V(X) &= E[X - E(X)]^2 \\ &= E\{X^2 - 2XE(X) + [E(X)]^2\} \\ &= E(X^2) - 2E(X)E(X) + [E(X)]^2 \quad [\text{Recuérdese que } E(X) \text{ es una constante.}] \\ &= E(X^2) - [E(X)]^2. \end{aligned}$$

**EJEMPLO 7.15.** La oficina meteorológica clasifica el tipo de cielo que es visible en relación con los «grados de nubosidad». Se usa una escala con 11 categorías: 0, 1, 2, ..., 10, en donde 0 representa un cielo perfectamente claro, 10 representa un cielo completamente cubierto, mientras que los otros valores representan diversas condiciones intermedias. Supongamos que tal clasificación se hace en una estación meteorológica determinada en un día y hora determinados. Sea  $X$  la variable aleatoria que toma uno de los 11 valores anteriores. Supongamos que la distribución de probabilidades de  $X$  es

$$p_0 = p_{10} = 0,05;$$

$$p_1 = p_2 = p_8 = p_9 = 0,15;$$

$$p_3 = p_4 = p_5 = p_6 = p_7 = 0,06.$$

Por tanto

$$\begin{aligned} E(X) &= 1(0,15) + 2(0,15) + 3(0,06) + 4(0,06) + 5(0,06) \\ &\quad + 6(0,06) + 7(0,06) + 8(0,15) + 9(0,15) \\ &\quad + 10(0,05) = 5,0. \end{aligned}$$

A fin de calcular  $V(X)$  necesitamos calcular  $E(X^2)$ .

$$\begin{aligned} E(X^2) &= 1(0,15) + 4(0,15) + 9(0,06) + 16(0,06) + 25(0,06) \\ &\quad + 36(0,06) + 49(0,06) + 64(0,15) + 81(0,15) \\ &\quad + 100(0,05) = 35,6. \end{aligned}$$




FIGURA 7.6

Luego

$$V(X) = E(X^2) - [E(X)]^2 = 35,6 - 25 = 10,6,$$

y la desviación estándar  $\sigma = 3,25$ .

**EJEMPLO 7.16.** Supongamos que  $X$  es una variable aleatoria continua con fdp

$$f(x) = 1 + x, \quad -1 \leq x \leq 0, \\ = 1 - x, \quad 0 \leq x \leq 1.$$

(Ver figura 7.6.) Debido a la simetría de la fdp,  $E(X) = 0$ . (Ver la observación abajo.) Más aún,

$$E(X^2) = \int_{-1}^0 X^2(1+x)dx \\ + \int_0^1 x^2(1-x)dx = \frac{1}{6}.$$

Por tanto  $V(X) = \frac{1}{6}$ .

**Observación:** supóngase que una variable aleatoria continua tiene una fdp que es simétrica respecto a  $x = 0$ . Es decir,  $f(-x) = f(x)$  para todo  $x$ . Luego, siempre que exista  $E(X)$ ,  $E(X) = 0$ , que es una consecuencia inmediata de la definición de  $E(X)$ . Esto puede extenderse a un punto arbitrario de simetría  $x = a$ , en tal caso  $E(X) = a$  (Ver el problema 7.33).

## 7.6 Propiedades de la varianza de una variable aleatoria

Hay varias propiedades importantes, en parte análogas a las expuestas para la esperanza de una variable aleatoria, que se mantienen para la varianza.

**Propiedad 7.7.** Si  $C$  es una constante,

$$V(X + C) = V(X). \quad (7.13)$$

**Demostración:**

$$V(X + C) = E[(X + C) - E(X + C)]^2 = E[(X + C) - E(X) - C]^2 \\ = E[X - E(X)]^2 = V(X).$$

**Observación:** esta propiedad es intuitivamente evidente, porque al agregar una constante a un resultado  $X$  no cambia su variabilidad, que es lo que mide la varianza. Simplemente «desplaza» los valores de  $X$  a la derecha o a la izquierda, dependiendo del signo de  $C$ .

**Propiedad 7.8.** Si  $C$  es una constante,

$$V(CX) = C^2 V(X). \quad (7.14)$$

**Demostración:**

$$V(CX) = E(CX)^2 - (E(CX))^2 = C^2 E(X^2) - C^2 (E(X))^2 \\ = C^2 [E(X^2) - (E(X))^2] = C^2 V(X).$$

**Propiedad 7.9.** Si  $(X, Y)$  es una variable aleatoria bidimensional, y si  $X$  y  $Y$  son independientes entonces

$$V(X + Y) = V(X) + V(Y). \quad (7.15)$$

**Demostración:**

$$V(X + Y) = E(X + Y)^2 - (E(X + Y))^2 \\ = E(X^2 + 2XY + Y^2) - (E(X))^2 - 2E(X)E(Y) - (E(Y))^2 \\ = E(X^2) - (E(X))^2 + E(Y^2) - (E(Y))^2 = V(X) + V(Y).$$

**Observación:** es importante establecer que, en general, la varianza *no es aditiva* como lo es el valor esperado. Con la hipótesis adicional de independencia, la propiedad 7.9 es válida. La varianza no posee la propiedad de linealidad que dimos para la esperanza, es decir,  $V(aX + b) \neq aV(X) + b$ . En su lugar tenemos  $V(aX + b) = a^2 V(X)$ .

**Propiedad 7.10.** Sean  $X_1, \dots, X_n$   $n$  variables aleatorias independientes. Entonces

$$V(X_1 + \dots + X_n) = V(X_1) + \dots + V(X_n). \quad (7.16)$$

**Demostración:** ésta se deduce de la propiedad 7.9 con inducción matemática.

**Propiedad 7.11.** Sea  $X$  una variable aleatoria con varianza finita. Luego para cualquier número real  $\alpha$ ,

$$V(X) = E[(X - \alpha)^2] - [E(X) - \alpha]^2. \quad (7.17)$$

**Demostración:** ver el problema 7.36.

**Observaciones:** (a) Esta es una extensión obvia del teorema 7.5, porque al hacer  $\alpha = 0$  obtenemos el teorema 7.5.

(b) Si interpretamos  $V(X)$  como el momento de inercia y  $E(X)$  como el centro de una masa unitaria, entonces la propiedad anterior es una formulación del teorema muy conocido en mecánica de los *ejes paralelos*: el momento de inercia respecto a un punto arbitrario es igual al momento de inercia respecto al centro de masa más el cuadrado de la distancia de este punto arbitrario al centro de masa.

(c)  $E[X - \alpha]^2$  es minimizado si  $\alpha = E(X)$ . Esto se deduce de inmediato de la propiedad anterior. Así el momento de inercia (de una masa unitaria distribuida en una recta) respecto a un eje que pasa por un punto arbitrario se minimiza si este punto se escoge como el centro de masa.

**EJEMPLO 7.17.** Calculemos la varianza de una variable aleatoria distribuida binomialmente con parámetro  $p$ .

Para calcular  $V(X)$  podemos proceder de dos maneras. Puesto que ya conocemos que  $E(X) = np$ , sencillamente debemos calcular  $E(X^2)$  y luego calcular  $V(X)$  como  $E(X^2) - (E(X))^2$ . Para calcular  $E(X^2)$  usamos el hecho de que

$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$ ,  $k = 0, 1, \dots, n$ . Por tanto  $E(X^2) = \sum_{k=0}^n k^2 \binom{n}{k} p^k (1-p)^{n-k}$ . Esta suma puede calcularse fácilmente, pero en vez de hacer esto, emplearemos un método más simple.

Nuevamente usaremos la representación de  $X$  presentada en el ejemplo 7.13,  $X = Y_1 + Y_2 + \dots + Y_n$ . Observemos que las  $Y_i$  son variables aleatorias independientes puesto que el valor de  $Y_i$  depende solo del resultado de la  $i$ -ésima repetición, y se supone que las repeticiones sucesivas son independientes. Por tanto podemos aplicar la propiedad 7.10 y obtener

$$V(X) = V(Y_1 + \dots + Y_n) = V(Y_1) + \dots + V(Y_n).$$

Pero  $V(Y_i) = E(Y_i)^2 - [E(Y_i)]^2$ . Ahora

$$E(Y_i) = 1(p) + 0(1-p) = p, \quad E(Y_i)^2 = 1^2(p) + 0^2(1-p) = p.$$

Por tanto

$$V(Y_i) = p - p^2 = p(1-p) \text{ para todo } i. \text{ Así } V(X) = np(1-p).$$

*Observación:* consideremos  $V(X) = np(1-p)$  como una función de  $p$  para un  $n$  dado. Dibujemos un gráfico como se muestra en la figura 7.7.

Resolviendo  $(d/dp)np(1-p) = 0$  encontramos que el valor máximo para  $V(X)$  ocurre cuando  $p = \frac{1}{2}$ . El valor mínimo de  $V(X)$  ocurre evidentemente en los extremos del intervalo en  $p = 0$  y  $p = 1$ . Esto es intuitivamente como debería ser. Recordando que la varianza es una medida de la variación de la variable aleatoria  $X$  definida como el número de veces que ocurre el suceso  $A$  en  $n$  repeticiones, encontramos que esta variación es nula si  $p = 0$  ó  $1$  (es decir, si  $A$  ocurre con probabilidad 0 ó 1) y es máxima cuando están «sin certeza como podemos estar» acerca de la ocurrencia o no ocurrencia de  $A$ , es decir, cuando  $P(A) = \frac{1}{2}$ .




FIGURA 7.7

**EJEMPLO 7.18.** Supóngase que la variable aleatoria  $X$  está distribuida uniformemente en  $[a, b]$ . Como lo calculamos previamente,  $E(X) = (a+b)/2$ .

Para calcular  $V(X)$  hallemos el valor de  $E(X^2)$ :

$$E(X^2) = \int_a^b x^2 \frac{1}{b-a} dx = \frac{b^3 - a^3}{3(b-a)}.$$

Por tanto

$$V(X) = E(X^2) - [E(X)]^2 = \frac{(b-a)^2}{12}$$

después de un cálculo sencillo.

*Observaciones:* (a) Este resultado es intuitivamente significativo. Indica que la varianza de  $X$  no depende individualmente de  $a$  y  $b$  sino sólo de  $(b-a)^2$ , es decir, del cuadrado de su diferencia. Por tanto dos variables aleatorias distribuidas cada una uniformemente en un intervalo (no necesariamente el mismo) tendrán iguales varianzas mientras las longitudes de los intervalos sean iguales.

(b) Es bien sabido el hecho de que los momentos de inercia de una barra delgada de masa  $M$  y longitud  $L$  respecto a un eje transversal que pasa por el centro están dados por  $ML^2/12$ .

## 7.7. Expresiones aproximadas para la esperanza y la varianza

Ya hemos observado que para evaluar  $E(Y)$  o  $V(Y)$ , en donde  $Y = H(X)$ , no necesitamos conocer la distribución de probabilidades de  $Y$ , sino que podemos trabajar directamente con la distribución de probabilidades de  $X$ . De un modo semejante, si  $Z = H(X, Y)$ , podemos calcular  $E(Z)$  y  $V(Z)$  sin obtener primero la distribución de  $Z$ .

Si la función  $H$  es muy complicada, la evaluación de la esperanza y varianza anteriores puede conducir a integraciones (o sumas) que son muy difíciles. De aquí que sean muy útiles las aproximaciones siguientes.

**Teorema 7.6.** Sea una variable aleatoria  $X$  con  $E(X) = \mu$ , y  $V(X) = \sigma^2$ .

Supongamos que  $Y = H(X)$ . Luego

$$E(Y) \simeq H(\mu) + \frac{H''(\mu)}{2} \sigma^2, \quad (7.18)$$

$$V(Y) \simeq [H'(\mu)]^2 \sigma^2. \quad (7.19)$$

(A fin de hacer útiles las aproximaciones anteriores necesitamos evidentemente que  $H$  sea a lo menos diferenciable dos veces para  $x = \mu$ ).

*Demostración:* (sólo un bosquejo): a fin de establecer la ecuación (7.18), desarrollemos la función  $H$  en una serie de Taylor para  $x = \mu$  con dos términos. Así

$$Y = H(\mu) + (X - \mu)H'(\mu) + \frac{(X - \mu)^2 H''(\mu)}{2} + R_1,$$

en donde  $R_1$  es un resto. Si descartamos el término resto  $R_1$ , entonces, tomando el valor esperado en ambos miembros, tenemos

$$E(Y) \simeq H(\mu) + \frac{H''(\mu)}{2} \sigma^2,$$

## La variable aleatoria de Poisson y otras variables aleatorias

### 8.1 La distribución de Poisson

Tal como en los modelos determinísticos, en los cuales ciertas relaciones funcionales desempeñan un papel importante (tales como lineales, cuadráticas, exponenciales, trigonométricas, etc.) también, al elaborar modelos no determinísticos para fenómenos observables, encontramos que ciertas distribuciones de probabilidades aparecen más a menudo que otras. Una razón de esto es que, como en el caso determinístico, ciertos modelos matemáticos relativamente simples parecen ser capaces de describir un gran número de fenómenos.

En este capítulo expondremos con mucho detalle diversas variables aleatorias discretas. En el capítulo siguiente haremos lo mismo con variables aleatorias continuas.

Presentemos formalmente la siguiente variable aleatoria. Posteriormente indicaremos bajo qué condiciones esta variable aleatoria podría representar al resultado de un experimento aleatorio.

**Definición.** Sea  $X$  una variable aleatoria que toma los valores posibles:  $0, 1, \dots, n, \dots$ . Si

$$P(X = k) = \frac{e^{-\alpha} \alpha^k}{k!}, \quad k = 0, 1, \dots, n, \dots, \quad (8.1)$$

decimos que  $X$  tiene una *distribución de Poisson* con parámetro  $\alpha > 0$ .

Para verificar que la anterior representa a una legítima distribución de probabilidades, sencillamente observemos que  $\sum_{k=0}^{\infty} P(X = k) = \sum_{k=0}^{\infty} (e^{-\alpha} \alpha^k / k!) = e^{-\alpha} e^{\alpha} = 1$ .

*Observación:* puesto que estamos definiendo directamente la variable aleatoria en función de su recorrido y distribución de probabilidades, sin referencia a ningún espacio muestral original  $S$ , podemos suponer que el espacio muestral  $S$  ha sido identificado con  $R_X$  y que  $X(s) = s$ . Es decir, los resultados del experimento son sencillamente los números  $0, 1, 2, \dots$  y las probabilidades asociadas con cada uno de esos resultados están dados por la ecuación (8.1).

**Teorema 8.1.** Si  $X$  tiene una distribución de Poisson con parámetro  $\alpha$ , entonces  $E(X) = \alpha$  y  $V(X) = \alpha$ .

*Demostración:* 
$$E(X) = \sum_{k=0}^{\infty} k \frac{e^{-\alpha} \alpha^k}{k!} = \sum_{k=1}^{\infty} \frac{e^{-\alpha} \alpha^k}{(k-1)!}.$$

Haciendo  $s = k - 1$ , encontramos que se transforma

$$E(X) = \sum_{s=0}^{\infty} \frac{e^{-\alpha} \alpha^{s+1}}{s!} = \alpha \sum_{s=0}^{\infty} \frac{e^{-\alpha} \alpha^s}{s!} = \alpha.$$

De modo semejante,

$$E(X^2) = \sum_{k=0}^{\infty} k^2 \frac{e^{-\alpha} \alpha^k}{k!} = \sum_{k=1}^{\infty} k \frac{e^{-\alpha} \alpha^k}{(k-1)!}.$$

Haciendo nuevamente  $s = k - 1$ , obtenemos

$$E(X^2) = \sum_{s=0}^{\infty} (s+1) \frac{e^{-\alpha} \alpha^{s+1}}{s!} = \alpha \sum_{s=0}^{\infty} s \frac{e^{-\alpha} \alpha^s}{s!} + \alpha \sum_{s=0}^{\infty} \frac{e^{-\alpha} \alpha^s}{s!} = \alpha^2 + \alpha$$

[puesto que la primera suma representa  $E(X)$  mientras que la segunda suma es igual a uno]. Luego

$$V(X) = E(X^2) - (E(X))^2 = \alpha^2 + \alpha - \alpha^2 = \alpha.$$

*Observación:* nótese la interesante propiedad que posee la variable aleatoria de Poisson: su esperanza es igual a su varianza.

### 8.2 La distribución de Poisson como una aproximación a la distribución binomial

La distribución de Poisson desempeña un papel importante por derecho propio como un modelo probabilístico apropiado para un gran número de fenómenos aleatorios. Este punto se expondrá en la sección siguiente. Aquí nos interesa la importancia de esta distribución para aproximar las probabilidades binomiales.

**EJEMPLO 8.1.** Suponiendo que las llamadas telefónicas llegan a una gran central telefónica y que en un período especial de tres horas (180 minutos) se han recibido un total de 270 llamadas, o sea 1,5 llamadas por minuto. Supóngase que, con base en la evidencia anterior, queremos calcular la probabilidad de recibir 0, 1, 2, etc. llamadas durante los próximos tres minutos.

Al considerar el fenómeno de llamadas recibidas, podríamos llegar a la conclusión de que en *cualquier* instante es tan probable que ocurra una llamada telefónica como en cualquier otro instante. Es decir, la probabilidad permanece constante en un intervalo de tiempo. La dificultad es que aún en un intervalo de tiempo muy corto, el número de puntos no sólo es infinito sino que no puede ser enumerado. Esto nos lleva a una serie de aproximaciones que describiremos ahora.

Para empezar, podríamos considerar la subdivisión del intervalo de tres minutos en nueve subintervalos de 20 segundos cada uno. Podríamos considerar entonces cada uno de esos nueve intervalos como un experimento de Bernoulli durante el cual observamos una llamada (éxito) o ninguna llamada (fracaso) con  $P(\text{éxito}) = (1,5) 20/60 = 0,5$ . Así podríamos estar inclinados a decir que la pro-

babilidad de dos llamadas durante el intervalo de tres minutos (es decir, 2 éxitos en 9 experimentos con  $P(\text{éxito}) = (0,5)$  es igual a  $\binom{9}{2}(1/2)^9 = 9/128$ .

La dificultad con esta aproximación es que ignoramos las posibilidades de, digamos, dos o tres, etc., llamadas durante uno de nuestros ensayos con períodos de 20 segundos. Si esta posibilidad se tomase en consideración, el uso anterior de la distribución binomial no sería legítimo ya que esa distribución es aplicable sólo cuando existe una dicotomía, una llamada o ninguna llamada.

Para evitar esta dificultad hacemos la aproximación siguiente y, realmente, nos lleva a una sucesión completa de aproximaciones. Una manera de estar más o menos seguro de que al menos se recibe una llamada en la central durante un pequeño intervalo de tiempo, es hacer que ese intervalo sea muy corto. Así, en vez de considerar nueve intervalos de 20 segundos de duración, consideremos los 18 intervalos siguientes, cada uno de 10 segundos de largo. Podemos representar ahora nuestro experimento como 18 experimentos de Bernoulli con  $P(\text{éxito}) = P(\text{recibir una llamada durante un subintervalo}) = (1,5)10/60 = 0,25$ . Por tanto  $P(\text{dos llamadas durante el intervalo de tres minutos}) = \binom{18}{2}(0,25)^2(0,75)^{16}$ . Nótese que aunque ahora tratamos una distribución binomial diferente a la de antes (es decir, que tiene parámetros  $n = 18$ ,  $p = 0,25$  en vez de  $n = 9$ ,  $p = 0,5$ ), el valor esperado es el mismo, a saber  $np = 18(0,25) = 9(0,5) = 4,5$ .

Si continuamos de esta manera, aumentando el número de subintervalos (es decir,  $n$ ), disminuiríamos al mismo tiempo la probabilidad de recibir una llamada (es decir,  $p$ ) de tal manera que  $np$  permanece constante.

Así, el ejemplo precedente nos conduce a formular la pregunta siguiente: ¿qué sucede a las probabilidades binomiales  $\binom{n}{k}p^k(1-p)^{n-k}$  si  $n \rightarrow \infty$  y  $p \rightarrow 0$ , de tal manera que  $np$  permanezca constante, es decir,  $np = \alpha$ ?

Los cálculos siguientes dan la respuesta a esta pregunta muy importante.

Consideremos la expresión general para la probabilidad binomial,

$$\begin{aligned} P(X = k) &= \binom{n}{k} p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\ &= \frac{n(n-1)(n-2) \cdots (n-k+1)}{k!} p^k (1-p)^{n-k}. \end{aligned}$$

Hagamos  $np = \alpha$ . Por tanto  $p = \alpha/n$ , y  $1-p = 1 - \alpha/n = (n-\alpha)/n$ . Sustituyendo todos los términos que contienen  $p$  por sus expresiones equivalentes en función de  $\alpha$ , obtenemos

$$\begin{aligned} P(X = k) &= \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\alpha}{n}\right)^k \left(\frac{n-\alpha}{n}\right)^{n-k} \\ &= \frac{\alpha^k}{k!} \left[ \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \right] \left[1 - \frac{\alpha}{n}\right]^{n-k} \\ &= \frac{\alpha^k}{k!} \left[ \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \right] \\ &\quad \times \left(1 - \frac{\alpha}{n}\right)^n \left(1 - \frac{\alpha}{n}\right)^{-k}. \end{aligned}$$

Ahora hagamos  $n \rightarrow \infty$  de tal manera que  $np = \alpha$  permanezca constante. Esto significa obviamente que  $p \rightarrow 0$  cuando  $n \rightarrow \infty$ , porque de otra manera  $np$  no podría permanecer constante. (Análogamente, podríamos necesitar que  $n \rightarrow \infty$  y  $p \rightarrow 0$  de tal manera que  $np \rightarrow \alpha$ .)

En la expresión anterior los términos de la forma  $(1 - 1/n)$ ,  $(1 - 2/n)$ , ... tienden a uno cuando  $n$  tiende a infinito, tal como lo hace  $(1 - \alpha/n)^{-k}$ . Es bien sabido (de la definición del número  $e$ ) que  $(1 - \alpha/n)^n \rightarrow e^{-\alpha}$  cuando  $n \rightarrow \infty$ .

Así,  $\lim_{n \rightarrow \infty} P(X = k) = e^{-\alpha} \alpha^k / k!$ . Es decir, en el límite obtenemos la distribución de Poisson con parámetro  $\alpha$ . Resumamos este importante resultado en el siguiente teorema.

**Teorema 8.2.** Sea  $X$  una variable aleatoria distribuida binomialmente con parámetro  $p$  (con base en  $n$  repeticiones del experimento). Esto es,

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Supóngase que cuando  $n \rightarrow \infty$ ,  $np = \alpha$  (constante), o equivalente, cuando  $n \rightarrow \infty$ ,  $p \rightarrow 0$  tal que  $np \rightarrow \alpha$ . Bajo estas condiciones tenemos

$$\lim_{n \rightarrow \infty} P(X = k) = \frac{e^{-\alpha} \alpha^k}{k!},$$

la distribución de Poisson con parámetro  $\alpha$ .

*Observaciones:* (a) El teorema anterior, esencialmente, dice que podemos aproximar las probabilidades binomiales con las probabilidades de la distribución de Poisson siempre que  $n$  sea grande y  $p$  pequeño.

(b) Ya hemos verificado que si  $X$  tiene una distribución binomial,  $E(X) = np$ , mientras que si  $X$  tiene una distribución de Poisson (con parámetro  $\alpha$ ),  $E(X) = \alpha$ .

(c) La distribución binomial está caracterizada por dos parámetros,  $n$  y  $p$ , mientras que la distribución de Poisson está caracterizada por un solo parámetro,  $\alpha = np$ , que representa al número esperado de éxitos por unidad de tiempo (o por unidad de espacio en algún otro caso). Este parámetro también se designa como la *intensidad* de la distribución. Es importante distinguir entre el número esperado de ocurrencias por *unidad* de tiempo y el número esperado de ocurrencias en el tiempo especificado. Así, en el ejemplo 8.1 la intensidad es 1,5 llamadas por minuto y por lo tanto el número esperado de llamadas es un período de 10 minutos, por ejemplo, sería 15.

(d) También podemos considerar el siguiente argumento para evaluar la varianza de una variable aleatoria  $X$  de Poisson con parámetro  $\alpha$ :  $X$  se puede considerar un caso límite de una variable aleatoria  $Y$  distribuida binomialmente con parámetro  $n$  y  $p$ , en donde  $n \rightarrow \infty$  y  $p \rightarrow 0$  de tal manera que  $np \rightarrow \alpha$ . Puesto que  $E(Y) = np$  y  $\text{Var}(Y) = np(1-p)$ , observemos que en el límite  $\text{Var}(Y) \rightarrow \alpha$ .

Hay extensas tablas disponibles para la distribución de Poisson. (E. C. Molina, *Poisson's Exponential Binomial Limit*, D. Van Nostrand Company, Inc., New York, 1942). Una breve tabulación de esta distribución se da en el apéndice.

Consideremos otros tres ejemplos adicionales que ilustran las aplicaciones de la distribución de Poisson mencionadas previamente.

**EJEMPLO 8.2.** En una concurrida intersección de tráfico la probabilidad  $p$  de que un automóvil tenga un accidente es muy escasa, digamos  $p = 0,0001$ . Sin embargo, durante cierta parte del día, entre las 4 p.m., y las 6 p.m., un gran número de automóviles pasa por la intersección, digamos 1000. Bajo dichas condiciones, ¿cuál es la probabilidad de que dos o más accidentes ocurran durante ese período?

Formulemos algunas hipótesis. Supongamos, en primer lugar, que el valor anterior de  $p$  es el mismo para cada uno de los automóviles. En segundo lugar, supongamos que si un automóvil tiene o no accidentes, no depende de lo que suceda a cualquier otro automóvil. (Esta suposición, obviamente, no es realista pero sin embargo la formularemos). Podemos suponer así que si  $X$  es el número de accidentes entre los 1000 automóviles que llegan, entonces  $X$  tiene una distribución binomial con  $p = 0,0001$ . (Otra hipótesis, no indicada explícitamente, es que  $n$ , el número de automóviles que pasa por la intersección entre 4p.m. y 6p.m., está predeterminada en 1000. Evidentemente, un enfoque más realista sería considerar  $n$  misma como una variable aleatoria cuyo valor depende de un mecanismo aleatorio. Sin embargo, no haremos esto aquí, sino que consideraremos  $n$  como fija). Por tanto podemos obtener el valor exacto de la probabilidad buscada:

$$\begin{aligned} P(X \geq 2) &= 1 - P(X = 0) - P(X = 1) \\ &= 1 - (0,9999)^{1000} - 1000(0,0001)(0,9999)^{999}. \end{aligned}$$

La evaluación de los valores anteriores da origen a una dificultad considerable. Puesto que  $n$  es grande y  $p$  es pequeño, aplicamos el teorema 8.2 y obtenemos la aproximación siguiente:

$$P(X = k) \cong \frac{e^{-0,1}(0,1)^k}{k!}.$$

Por tanto,

$$P(X \geq 2) \cong 1 - e^{0,1}(1 + 0,1) = 0,0045.$$

**EJEMPLO 8.3.** Supóngase que un proceso de fabricación produce artículos de tal manera que cierta proporción (constante) de artículos, digamos  $p$ , son defectuosos. Si se obtiene un lote  $n$  de tales artículos, la probabilidad de obtener exactamente  $k$  defectuosos puede ser calculada de la distribución binomial como  $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$ , en donde  $X$  es el número de defectuosos en el lote. Si  $n$  es grande y  $p$  es pequeña (como a menudo es el caso), debemos aproximar la probabilidad anterior por

$$P(X = k) \cong \frac{e^{-np}(np)^k}{k!}.$$

Supóngase, por ejemplo, que un fabricante produce artículos de los cuales alrededor de 1 en 1000 son defectuosos. Esto es,  $p = 0,001$ . Por tanto, usando la dis-

tribución binomial, encontramos que en un lote de 500 artículos la probabilidad de que ninguno sea defectuoso es  $(0,999)^{500} = 0,609$ . Si aplicamos la aproximación de Poisson, esta probabilidad puede escribirse como  $e^{-0,5} = 0,61$ . La probabilidad de encontrar 2 o más artículos defectuosos es, de acuerdo con la aproximación de Poisson,  $1 - e^{-0,5}(1 + 0,5) = 0,085$ .

**EJEMPLO 8.4.** [Sugerido por una exposición en *Cálculo de Probabilidades* de A. Renyi (en alemán), VEB Deutscher Verlag der Wissenschaft, Berlín, 1962].

En la fabricación de botellas de vidrio, se encuentran partículas duras y pequeñas en el vidrio fundido del cual se hacen las botellas. Si aparece una sola partícula en una botella, la botella no puede ser usada y debe ser descartada. Puede suponerse que las partículas están esparcidas al azar en el vidrio fundido. Supondremos que el vidrio fundido se produce de tal manera que el número de partículas es (en promedio) el mismo para una cantidad constante de vidrio fundido. Supóngase en particular que en 100 kilos de vidrio fundido, se encuentran  $x$  de tales partículas y que es necesario 1 kilo de vidrio fundido para hacer una de estas botellas.

*Pregunta:* ¿qué porcentaje de botellas tendrá que ser descartado debido a que son defectuosas? A primera vista la «solución» de este problema podría ser como sigue. Puesto que el material para 100 botellas contiene  $x$  partículas, aproximadamente el  $x$  por ciento de las botellas deberá ser descartado. Una pequeña reflexión indicará, sin embargo, que la solución anterior no es correcta, ya que una botella defectuosa puede tener más de 1 partícula, bajando así el porcentaje de botellas defectuosas obtenidas del material que sobra.

A fin de obtener una solución «correcta», hagamos las siguientes hipótesis simplificantes: (a) cada una de las partículas puede aparecer en el material de cada una de las botellas con igual probabilidad y (b) la distribución de cualquier partícula es independiente de cualquier otra partícula. Con estas hipótesis, podemos reducir nuestro problema al siguiente modelo de «urna». Entre  $N$  urnas, se distribuyen al azar  $n$  esferas. ¿Cuál es la probabilidad de que en una urna elegida aleatoriamente, se encuentren exactamente  $k$  esferas? (Las urnas evidentemente corresponden a las partículas.)

Siendo  $Z$  el número de esferas encontradas en una urna escogida aleatoriamente, se deduce, de la hipótesis anterior, que  $Z$  está distribuida binomialmente con parámetro  $1/N$ . Luego,

$$P(Z = k) = \binom{n}{k} \left(\frac{1}{N}\right)^k \left(1 - \frac{1}{N}\right)^{n-k}.$$

Supóngase ahora que el vidrio fundido se prepara en cantidades muy grandes. En realidad, supongamos que se prepara en unidades de 100 kilos, y que se han suministrado  $M$  de tales unidades. Luego  $N = 100M$  y  $n = xM$ . Sea  $\alpha = x/100$ , lo que iguala la proporción de partículas por botella. Así  $N = n/\alpha$  y la probabilidad anterior puede escribirse como

$$P(Z = k) = \binom{n}{k} \left(\frac{\alpha}{n}\right)^k \left(1 - \frac{\alpha}{n}\right)^{n-k}.$$

Así, cuando el proceso de producción continúa (esto es,  $M \rightarrow \infty$  y luego  $n \rightarrow \infty$ ) obtenemos

$$P(Z = k) \simeq \frac{e^{-\alpha} \alpha^k}{k!} \quad \text{en donde } \alpha = \frac{x}{100}.$$

Calculemos la probabilidad de que deba descartarse una botella. Esta es igual a  $1 - P(Z = 0)$ . Luego  $P(\text{botella defectuosa}) \simeq 1 - e^{-x/100}$ . Si el número de botellas producidas es muy grande, debemos identificar obligadamente la probabilidad de una botella defectuosa con la frecuencia relativa de botellas defectuosas. Por tanto el porcentaje de botellas defectuosas es aproximadamente  $100(1 - e^{-x/100})$ . Si desarrollamos  $100(1 - e^{-x/100})$  en una serie de Maclaurin, obtenemos

$$100 \left[ 1 - \left( 1 - \frac{x}{100} + \frac{x^2}{2(100)^2} - \frac{x^3}{3!(100)^3} + \dots \right) \right] \\ = x - \frac{x^2}{2(100)} + \frac{x^3}{6(100)^2} - \dots$$

Así, si  $x$  es pequeña, la proporción de botellas descartadas es aproximadamente  $x$  como se sugirió primero. Sin embargo, para un  $x$  mayor esto no es válido. En caso que  $x = 100$ , el porcentaje de botellas descartadas no es 100, sino que  $100(1 - e^{-1}) = 63,21$  por ciento. Este, naturalmente, es un caso extremo y no se encontraría en un proceso controlado razonablemente. Supongamos que  $x = 30$  (un número más realista). Por tanto en vez de descartar el 30 por ciento (nuestra solución inicial nuevamente), descartaríamos sólo  $100(1 - e^{-0,3}) = 25,92$  por ciento. Podríamos observar que si  $x$  es razonablemente grande, es más económico producir botellas más pequeñas. Por ejemplo, si necesitamos solo 0,25 kilos de vidrio fundido por botella en vez de 1 kilo, y si  $x = 30$ , entonces el porcentaje descartado se reduce de 25,92 por ciento a 7,22 por ciento.

### 8.3 El proceso de Poisson

En la sección anterior se usó la distribución de Poisson como un medio para aproximar una distribución conocida, a saber, binomial. Sin embargo, la distribución de Poisson desempeña un papel muy importante por derecho propio, puesto que representa un modelo probabilístico apropiado para un gran número de fenómenos observables.

Aunque no vamos a dar una deducción completamente rigurosa de algunos resultados que vamos a exponer, el enfoque general es de tal importancia que se deberá tomar en cuenta para comprenderlos, aún cuando no podamos justificar cada uno de los pasos.

Para referirnos a un ejemplo específico mientras concluimos los detalles matemáticos, consideremos una fuente de material radiactivo que emite partículas  $\alpha$ . Sea definido  $X_t$  como el número de partículas emitidas durante un periodo especificado de tiempo  $[0, t]$ . Vamos a enunciar algunas hipótesis acerca de la variable aleatoria (discreta)  $X_t$ , que nos permitirán determinar la distribución de

probabilidades de  $X_t$ . La posibilidad de estas hipótesis (recordando lo que  $X_t$  representa) está comprobada por el hecho de que la evidencia empírica sostiene una cantidad muy considerable de resultados teóricos que vamos a derivar.

Puede ser útil señalar que en la deducción de cualquier resultado matemático, debemos aceptar algunos postulados o axiomas fundamentales. En la búsqueda de axiomas para describir fenómenos observables, algunos axiomas pueden ser más apropiados (y menos arbitrarios) que otros. Por ejemplo, al describir el movimiento de un objeto impulsado hacia arriba con cierta velocidad inicial, podríamos suponer que la distancia sobre el suelo, llamémosla  $s$ , es una función cuadrática del tiempo  $t$ ; es decir,  $s = at^2 + bt + c$ . Esta sería, difícilmente, una hipótesis intuitiva, de acuerdo con nuestra experiencia. En lugar, podríamos suponer que la aceleración es una constante y luego deducir de esto que  $s$  debe ser una función cuadrática de  $t$ . Lo importante, naturalmente, es que si debemos suponer algo con el objeto de elaborar nuestro modelo matemático, preferiríamos suponer lo que es apropiado, en vez de lo que no lo es.

El mismo objetivo nos guía a elaborar un modelo probabilístico para la emisión de partículas  $\alpha$  de una fuente radiactiva. La variable aleatoria  $X_t$  definida anteriormente puede tomar los valores 0, 1, 2, ... Sea  $p_n(t) = P[X_t = n]$ ,  $n = 0, 1, 2, \dots$

Vamos a enunciar ahora las cinco hipótesis siguientes.

- A<sub>1</sub>: El número de partículas emitidas durante intervalos de tiempo no sobrepuestos son variables aleatorias independientes.
- A<sub>2</sub>: Si  $X_t$  se define como antes y si  $Y_t$  es igual al número de partículas emitidas durante  $[t_1, t_1 + t]$ , para cualquier  $t_1 > 0$ , las variables aleatorias  $X_t$  y  $Y_t$  tienen la misma distribución de probabilidades. (En otras palabras, la distribución del número de partículas emitidas durante cualquier intervalo depende sólo de la longitud del intervalo y no de los puntos extremos.)
- A<sub>3</sub>:  $p_1(\Delta t)$  es igual aproximadamente a  $\lambda \Delta t$ , si  $\Delta t$  es suficientemente pequeña, donde  $\lambda$  es una constante positiva. Esto lo escribimos como  $p_1(\Delta t) \sim \lambda \Delta t$ . En esta sección  $a(\Delta t) \sim b(\Delta t)$  significa que  $a(\Delta t)/b(\Delta t) \rightarrow 1$  cuando  $\Delta t \rightarrow 0$ . También supondremos que  $\Delta t > 0$ . (Esta hipótesis expresa que si el intervalo es suficientemente pequeño, la probabilidad de obtener exactamente una emisión durante ese intervalo es directamente proporcional a la longitud del intervalo).
- A<sub>4</sub>:  $\sum_{k=2}^{\infty} p_k(\Delta t) \sim 0$ . (Esto implica que  $p_k(\Delta t) \rightarrow 0$ ,  $k \geq 2$ .) Esto nos dice que la probabilidad de obtener dos o más emisiones en un intervalo suficientemente pequeño es despreciable.
- A<sub>5</sub>:  $X_0 = 0$ , o equivalentemente,  $p_0(0) = 1$ . Esto equivale a una condición inicial para el modelo que estamos describiendo.

Como lo demostraremos en breve, las cinco hipótesis anotadas anteriormente harán posible que deduzcamos una expresión para  $p_n(t) = P[X_t = n]$ . Saquemos ahora ciertas conclusiones de las hipótesis anteriores.

(a) Las hipótesis  $A_1$  y  $A_2$  juntas implican que la variable aleatoria  $X_{\Delta t}$  y  $[X_{t+\Delta t} - X_t]$  son variables aleatorias independientes con la misma *distribución* de probabilidades. (Ver figura 8.1.)



FIGURA 8.1

(b) De las hipótesis  $A_3$  y  $A_4$  podemos concluir que

$$p_0(\Delta t) = 1 - p_1(\Delta t) - \sum_{k=2}^{\infty} p_k(\Delta t) \sim 1 - \lambda \Delta t. \quad (8.2)$$

(c) Podemos escribir

$$\begin{aligned} p_0(t + \Delta t) &= P[X_{t+\Delta t} = 0] \\ &= P[X_t = 0 \text{ y } (X_{t+\Delta t} - X_t) = 0] \\ &= p_0(t)p_0(\Delta t). \quad [\text{Ver conclusión (a).}] \\ &\sim p_0(t)[1 - \lambda \Delta t]. \quad [\text{Ver ecuación (8.2).}] \end{aligned}$$

(d) Luego tenemos

$$\frac{p_0(t + \Delta t) - p_0(t)}{\Delta t} \sim -\lambda p_0(t).$$

Haciendo  $\Delta t \rightarrow 0$ , y observando que el lado izquierdo representa al cociente de la diferencia de la función  $p_0$  y por tanto tiende a  $p'_0(t)$  (más precisamente, a la derivada por la derecha, puesto que  $\Delta t > 0$ ), tenemos

$$p'_0(t) = -\lambda p_0(t) \quad \text{o, equivalentemente,} \quad \frac{p'_0(t)}{p_0(t)} = -\lambda.$$

Integrando en ambos miembros con respecto a  $t$ , obtenemos  $\ln p_0(t) = -\lambda t + C$ , en donde  $C$  es una constante de integración. De la hipótesis  $A_5$  encontramos, al hacer  $t = 0$ , que  $C = 0$ . Luego

$$p_0(t) = e^{-\lambda t}. \quad (8.3)$$

Así, nuestras hipótesis nos han conducido a una expresión para  $P[X_t = 0]$ . Utilizando esencialmente el mismo enfoque, obtendremos ahora  $p_n(t)$  para  $n \geq 1$ .

(e) Considerando  $p_n(t + \Delta t) = P[X_{t+\Delta t} = n]$ .

Ahora  $X_{t+\Delta t} = n$  si y sólo si  $X_t = x$  y  $[X_{t+\Delta t} - X_t] = n - x$ ,  $x = 0, 1, 2, \dots$ ,  $n$ . Utilizando las hipótesis  $A_1$  y  $A_2$ , tenemos

$$\begin{aligned} p_n(t + \Delta t) &= \sum_{x=0}^n p_x(t)p_{n-x}(\Delta t) \\ &= \sum_{x=0}^{n-2} p_x(t)p_{n-x}(\Delta t) + p_{n-1}(t)p_1(\Delta t) + p_n(t)p_0(\Delta t). \end{aligned}$$

Utilizando las hipótesis  $A_3$  y  $A_4$  y también la ecuación (8.2), obtenemos

$$p_n(t + \Delta t) \sim p_{n-1}(t)\lambda \Delta t + p_n(t)[1 - \lambda \Delta t].$$

Luego

$$\frac{p_n(t + \Delta t) - p_n(t)}{\Delta t} \sim \lambda p_{n-1}(t) - \lambda p_n(t).$$

Nuevamente haciendo  $\Delta t \rightarrow 0$ , y observando nuevamente que el lado izquierdo representa el cociente diferencial de la función  $p_n$ , obtenemos

$$p'_n(t) = -\lambda p_n(t) + \lambda p_{n-1}(t), \quad n = 1, 2, \dots$$

Esta representa a un sistema lineal infinito de ecuaciones diferenciales de diferencias. El lector interesado puede verificar que si definimos la función  $q_n$  por la relación  $q_n(t) = e^{\lambda t} p_n(t)$ , el sistema anterior se transforma en  $q'_n(t) = \lambda q_{n-1}(t)$ ,  $n = 1, 2, \dots$ . Puesto que  $p_0(t) = e^{-\lambda t}$ , encontramos que  $q_0(t) = 1$ . [Nótese también que  $q_n(0) = 0$  para  $n > 0$ .] Así obtenemos, recursivamente,

$$\begin{aligned} q'_1(t) &= \lambda, & \text{y por tanto } q_1(t) &= \lambda t; \\ q'_2(t) &= \lambda q_1(t) = \lambda^2 t, & \text{y por tanto } q_2(t) &= \frac{(\lambda t)^2}{2}. \end{aligned}$$

En general,  $q'_n(t) = \lambda q_{n-1}(t)$  y por tanto  $q_n(t) = (\lambda t)^n / n!$ . Recordando la definición de  $q_n$ , finalmente obtenemos

$$p_n(t) = e^{-\lambda t} (\lambda t)^n / n!, \quad n = 0, 1, 2, \dots \quad (8.4)$$

Hemos demostrado así que el número de partículas emitidas durante el intervalo de tiempo  $[0, t]$  de una fuente radiactiva, bajo las suposiciones hechas anteriormente, es una variable aleatoria, con una distribución de Poisson con parámetro  $(\lambda t)$ .

*Observaciones:* (a) Es importante darse cuenta de que la distribución de Poisson apareció como una consecuencia de ciertas suposiciones que hicimos. Esto significa que cada vez que dichas suposiciones sean válidas (o al menos lo sean aproximadamente) la distribución de Poisson debe usarse como un modelo apropiado. Resulta que hay una gran cantidad de fenómenos para los cuales es apropiado el modelo de Poisson.

(i) Representemos por  $X_t$  el número de llamadas telefónicas que llegan a una central telefónica durante un período de tiempo de longitud  $t$ . Las suposiciones anteriores se satisfacen aproximadamente, en especial durante el «período congestionado» del día. Luego  $X_t$  tiene una distribución de Poisson.

(ii) Representemos por  $X_t$  al número de electrones que salen del cátodo de un tubo al vacío. Nuevamente las suposiciones son apropiadas y, por tanto,  $X_t$  tiene una distribución de Poisson.

(iii) El ejemplo siguiente (de astronomía) indica que el razonamiento anterior puede aplicarse no sólo al número de ocurrencias de un suceso durante un período de tiempo fijo, sino también al número de ocurrencias de un suceso dentro de los límites fijados de un área o un volumen. Supóngase que un astrónomo investiga una parte de la Vía Láctea y supóngase que en la parte considerada la densidad de estrellas, llamémosla  $\lambda$ , es constante. (Esto significa que en un volumen de  $V$  (unidades cúbicas), se encontrarían, en promedio,  $\lambda V$  estrellas). Sea  $X_V$  igual al número de estrellas encontradas en una parte de la Vía Láctea, que tiene un volumen  $V$ . Si se satisfacen las suposiciones anteriores (sustituyendo «volumen» por «tiempo»), entonces  $P[X_V = n] = (\lambda V)^n e^{-\lambda V} / n!$ . (Las suposiciones, interpretadas en el ejemplo presente, establecerían esencialmente que el número

de estrellas que aparecen en partes no sobrepuestas del firmamento, representa variables aleatorias independientes y que la probabilidad de que aparezca más de una estrella en una porción pequeña del cielo es cero.)

(iv) Se nos ocurre otra aplicación en el campo biológico, si hacemos que  $X_A$  sea el número de células sanguíneas visibles bajo el microscopio, en donde el área de la superficie visible bajo el microscopio es dada por  $A$  unidades cuadradas.

(b) La constante  $\lambda$  apareció originalmente como una constante de proporcionalidad en la hipótesis  $A_3$ . Vale la pena mencionar las siguientes interpretaciones de  $\lambda$ : si  $X_t$  representa el número de ocurrencias de un suceso durante un intervalo de tiempo de longitud  $t$ , entonces,  $E(X_t) = \lambda t$ , y por tanto  $\lambda = [E(X_t)]/t$  representa la razón esperada con la cual se emiten las partículas. Si  $X_V$  representa al número de ocurrencias de algún suceso dentro de un volumen especificado  $V$ , entonces  $E(X_V) = \lambda V$ , y por lo tanto  $\lambda = [E(X_V)]/V$  representa la densidad esperada con la cual aparecen las estrellas.

(c) Es importante señalar que nuestra exposición en la sección 8.3 no se refirió sólo a una variable aleatoria  $X$  que posee una distribución de Poisson, sino que para cada  $t > 0$ , encontramos que  $X_t$  tenía una distribución de Poisson con un parámetro dependiente de  $t$ . Tal colección (infinita) de variables aleatorias también se conoce como un proceso de Poisson. (Recíprocamente, se genera un proceso de Poisson cada vez que ocurre un suceso en algún intervalo de tiempo de modo que se satisfagan las hipótesis  $A_1$  hasta  $A_5$ .) De manera análoga podemos definir un proceso de Bernoulli: si  $X_1, X_2, \dots, X_n, \dots$  son los números de ocurrencias de sucesos en  $1, 2, \dots, n$ , experimentos de Bernoulli, entonces la colección de variables aleatorias  $X_1, \dots, X_n, \dots$  se llaman un proceso de Bernoulli.

**EJEMPLO 8.5.** Una complicada maquinaria, cuando funciona perfectamente, puede producir una utilidad de  $C$  pesos por hora ( $C > 2$ ) a una compañía. Sin embargo, esta máquina tiene una tendencia a fallar a horas inesperadas e impredecibles. Supóngase que el número de fallas durante cualquier período de longitud  $t$  horas es una variable aleatoria con una distribución de Poisson de período  $t$ . Si la máquina falla  $x$  veces durante  $t$  horas, la pérdida ocasionada (la improductividad de la máquina más la reparación) es igual a  $(x^2 + x)$  pesos. Luego la utilidad total  $P$  durante cualquier período de  $t$  horas es igual a  $P = Ct - (X^2 + X)$ , en donde  $X$  es la variable aleatoria que indica el número de fallas de la máquina. Por tanto  $P$  es una variable aleatoria, y podría ser de interés elegir  $t$  (lo que está a nuestra voluntad) de manera tal que la utilidad esperada sea maximizada. Tenemos

$$E(P) = Ct - E(X^2 + X).$$

Según el teorema 8.1 encontramos que  $E(X) = t$  y  $E(X^2) = t + (t)^2$ . Luego se deduce que  $E(P) = Ct - 2t - t^2$ . Para encontrar el valor de  $t$  para la cual  $E(P)$  es maximizada, diferenciamos  $E(P)$  e igualamos la expresión resultante a cero. Obtenemos  $C - 2 - 2t = 0$ , obteniendo  $t = \frac{1}{2}(C - 2)$  horas.

**EJEMPLO 8.6.** Sea  $X_t$  igual al número de partículas emitidas por una fuente radiactiva durante un intervalo de tiempo de longitud  $t$ . Supóngase que  $X_t$  tiene una distribución de Poisson con parámetro  $\alpha t$ . Se instala un instrumento para anotar el número de partículas emitidas. Supóngase que hay una probabilidad constante  $p$  de que cualquier partícula emitida no sea contada. Si  $R_t$  es igual al número de partículas contadas durante el intervalo específico, ¿cuál es la distribución de probabilidades de  $R_t$ ?

Para  $X_t = x$ , dado la variable aleatoria  $R_t$  tiene una distribución binomial con base en  $x$  repeticiones con parámetro  $(1 - p)$ . Esto es,

$$P(R_t = k | X_t = x) = \binom{x}{k} (1 - p)^k p^{x-k}.$$

Usando la fórmula de la probabilidad total, (ecuación 3.4), tenemos

$$\begin{aligned} P(R_t = k) &= \sum_{x=k}^{\infty} P(R_t = k | X_t = x) P(X_t = x) \\ &= \sum_{x=k}^{\infty} \binom{x}{k} (1 - p)^k p^{x-k} e^{-\alpha t} (\alpha t)^x / x! \\ &= \left( \frac{1 - p}{p} \right)^k \frac{e^{-\alpha t}}{k!} \sum_{x=k}^{\infty} \frac{1}{(x - k)!} (p \alpha t)^{x-k}. \end{aligned}$$

Sea  $i = x - k$ . Entonces

$$\begin{aligned} P(R_t = k) &= \left( \frac{1 - p}{p} \right)^k \frac{e^{-\alpha t}}{k!} \sum_{i=0}^{\infty} \frac{(p \alpha t)^{i+k}}{i!} \\ &= \left( \frac{1 - p}{p} \right)^k \frac{e^{-\alpha t}}{k!} (p \alpha t)^k e^{p \alpha t} \\ &= \frac{e^{-\alpha(1-p)t} [(1-p)\alpha t]^k}{k!}. \end{aligned}$$

Así encontramos que  $R_t$  tiene una distribución de Poisson con parámetro  $(1 - p)\alpha t$ .

## 8.4 La distribución geométrica

Supóngase que efectuamos un experimento  $\varepsilon$  y estamos interesados sólo en la ocurrencia o no ocurrencia de algún suceso  $A$ . Supóngase como en la presentación de la distribución binomial, que repetidamente efectuamos  $\varepsilon$ , que las repeticiones son independientes, y que en cada una de las repeticiones  $P(A) = p$  y  $P(\bar{A}) = 1 - p = q$  permanecen constantes. Supóngase que repetimos el experimento hasta que  $A$  ocurre por primera vez. (Aquí nos separamos de las hipótesis que conducen a la distribución binomial. Allí el número de repeticiones era predeterminado, mientras que aquí es una variable aleatoria.)

Definamos la variable aleatoria  $X$  como el número de repeticiones necesarias hasta incluir la primera ocurrencia de  $A$ . Así,  $X$  toma los valores posibles  $1, 2, \dots$ . Puesto que  $X = k$  si y sólo si las primeras  $(k - 1)$  repeticiones de  $\varepsilon$  resultan en  $\bar{A}$  mientras que la  $k$ -ésima resulta en  $A$ , tenemos

$$P(X = k) = q^{k-1} p, \quad k = 1, 2, \dots \quad (8.5)$$

Se dice que una variable aleatoria con una distribución de probabilidades ecuación (8.5), tiene una distribución geométrica.

Un cálculo sencillo indica que la ecuación (8.5) define una distribución de probabilidades legítima. Obviamente tenemos  $P(X = k) \geq 0$ . Y

$$\sum_{k=1}^{\infty} P(X = k) = p(1 + q + q^2 + \cdots) = p \left[ \frac{1}{1 - q} \right] = 1.$$

Podemos obtener el valor esperado de  $X$  como sigue.

$$\begin{aligned} E(X) &= \sum_{k=1}^{\infty} k p q^{k-1} = p \sum_{k=1}^{\infty} \frac{d}{dq} q^k \\ &= p \frac{d}{dq} \sum_{k=1}^{\infty} q^k = p \frac{d}{dq} \left[ \frac{q}{1 - q} \right] = \frac{1}{p}. \end{aligned}$$

(El intercambio de diferenciales y sumatorias se justifica aquí puesto que la serie converge para  $|q| < 1$ ). Un cálculo similar enseña que  $V(X) = q/p^2$ . (Nuevamente obtendremos los dos resultados en el capítulo 10, usando un enfoque distinto.) Para resumir lo anterior tenemos el teorema siguiente.

**Teorema 8.3.** Si  $X$  tiene una distribución geométrica como se da en la ecuación (8.5),

$$E(X) = 1/p \quad \text{y} \quad V(X) = q/p^2.$$

*Observación:* el hecho de que  $E(X)$  sea el recíproco de  $p$  es interesante intuitivamente, puesto que dice que con valores pequeños de  $p = P(A)$  se necesitan muchas repeticiones a fin de que ocurra  $A$ .

**EJEMPLO 8.7.** Supóngase que el costo de efectuar un experimento es \$ 1000. Si el experimento falla, se incurre en un costo adicional de \$ 300 debido a ciertos cambios que deben efectuarse antes de que se intente un nuevo ensayo. Si la probabilidad de éxito en cualquiera de los ensayos es 0,2, si los ensayos aislados son independientes y si los experimentos continúan hasta que se obtiene el primer resultado exitoso, ¿cuál es el costo esperado del procedimiento completo?

Si  $C$  es el costo y  $X$  el número de ensayos necesarios para obtener éxito, tenemos que  $C = 1000X + 300(X - 1) = 1300X - 300$ . Luego

$$E(C) = 1300E(X) - 300 = 1300 \frac{1}{0,2} - 300 = \$6200.$$

**EJEMPLO 8.8.** En cierta región la probabilidad de que una tormenta con truenos ocurra en un día cualquiera durante el verano (digamos enero y febrero) es igual a 0,1. Suponiendo la independencia de un día con otro, ¿cuál es la probabilidad de que la primera tormenta con truenos del verano ocurra el 3 de febrero?

Sea  $X$  el número de días (empezando el 1 de enero) hasta la primera tormenta y busquemos  $P(X = 34)$  la cual es igual  $(0,9)^{33}(0,1) = 0,003$ .

**EJEMPLO 8.9.** Si la probabilidad de que cierto examen dé una reacción «positiva» igual a 0,4, ¿cuál es la probabilidad de que ocurran menos de 5 reacciones

«negativas» antes de la primera positiva? Haciendo que  $Y$  sea el número de reacciones negativas antes de la primera positiva, tenemos

$$P(Y = k) = (0,6)^k(0,4), \quad k = 0, 1, 2, \dots$$

Luego

$$P(Y < 5) = \sum_{k=0}^4 (0,6)^k(0,4) = 0,92.$$

*Observación:* Si  $X$  tiene una distribución geométrica como se describió en la ecuación (8.5) y si hacemos  $Z = X - 1$ , podemos interpretar a  $Z$  como el número de fallas que preceden al primer éxito. Tenemos que  $P(Z = k) = q^k p$ ,  $k = 0, 1, 2, \dots$ , en donde  $p = P(\text{éxito})$  y  $q = P(\text{falla})$ .

La distribución geométrica tiene una propiedad interesante que está resumida en el teorema siguiente.

**Teorema 8.4.** Supóngase que  $X$  tiene una distribución geométrica dada por la ecuación (8.5). Entonces para dos enteros positivos cualesquiera  $s$  y  $t$ ,

$$P(X \geq s + t \mid X > s) = P(X \geq t). \quad (8.6)$$

*Demostración:* ver el problema 8.18.

*Observaciones:* (a) El teorema anterior indica que la distribución geométrica «no tiene memoria» en el sentido siguiente. Supongamos que el suceso  $A$  no ha ocurrido durante las primeras  $s$  repeticiones de  $\varepsilon$ . Entonces la probabilidad de que no ocurra durante las próximas  $t$  repeticiones es la misma que la probabilidad de que no ocurra durante las primeras  $t$  repeticiones. En otras palabras, la información de ningún éxito es «olvidada» en lo que se refiere a cálculos subsecuentes.

(b) El recíproco del teorema anterior, es también cierto: si la ecuación (8.6) es válida para una variable aleatoria que toma sólo valores positivos, entonces la variable aleatoria debe tener una distribución geométrica. (No demostraremos esto aquí. Se puede encontrar tal exposición en *An Introduction to Probability Theory and Its Applications*, de Feller, John Wiley and Sons, Inc., 2.<sup>a</sup> edición, New York, 1957, pág. 304.)

(c) Observaremos en el capítulo siguiente que existe una variable aleatoria continua con una distribución que posee una propiedad análoga a la ecuación (8.6), es decir la distribución exponencial.

**EJEMPLO 8.10.** Supongamos que un mecanismo es inspeccionado al finalizar cada día para ver si aún funciona regularmente. Sea  $p = P$  [falla durante cualquier día dado]. Por tanto si  $X$  es el número de inspecciones necesarias para obtener la primera falla,  $X$  tiene una distribución de probabilidades geométricas y tenemos  $P(X = n) = (1 - p)^{n-1} p$ . Análogamente,  $(1 - p)^{n-1} p = P$  [el artículo se encontrará que ha fallado en la  $n$ -ésima inspección y no en la  $(n - 1)$  ésima inspección.]

El valor máximo de esta probabilidad se obtiene resolviendo

$$\frac{d}{dp} P(X = n) = 0.$$

Esto da

$$p(n-1)(1-p)^{n-2}(-1) + (1-p)^{n-1} = 0,$$

lo que equivale a

$$(1-p)^{n-2}[(1-p) - (n-1)p] = 0,$$

de la cual obtenemos  $p = 1/n$ .

### 8.5 La distribución de Pascal

Una generalización obvia de la distribución geométrica aparece si hacemos la siguiente pregunta. Supongamos que un experimento se continúa hasta que un suceso particular  $A$  ocurre por  $r$ -ésima vez. Si

$$P(A) = p, \quad P(\bar{A}) = q = 1 - p$$

en cada una de las repeticiones, definimos la variable aleatoria  $Y$  como sigue.

$Y$  es el número de repeticiones necesarias a fin que  $A$  ocurra exactamente  $r$  veces.

Necesitamos la distribución de probabilidades de  $Y$ . Debe ser evidente que si  $r = 1$ ,  $Y$  tiene la distribución geométrica dada por la ecuación (8.5).

Ahora  $Y = k$  si y sólo si  $A$  ocurre en la  $k$ -ésima repetición y precisamente  $A$  ocurrió  $(r-1)$  veces en las  $(k-1)$  repeticiones previas. La probabilidad de este suceso es simplemente  $p(r-1)p^{r-1}q^{k-r}$ , puesto que lo que sucede en las primeras  $(k-1)$  repeticiones es independiente de lo que sucede en la  $k$ -ésima repetición.

Luego

$$P(Y = k) = \binom{k-1}{r-1} p^r q^{k-r}, \quad k = r, r+1, \dots \quad (8.7)$$

Se ve muy sencillamente que para  $r = 1$ , lo anterior se reduce a la ecuación (8.5). Una variable aleatoria que tenga una distribución de probabilidades dada por la ecuación (8.7) tiene una distribución de *Pascal*.

*Observación:* la distribución de Pascal es también conocida comúnmente como la distribución *binomial negativa*. La razón para esto es que al verificar la condición

$$\sum_{k=r}^{\infty} P(Y = k) = 1$$

obtenemos

$$\sum_{k=r}^{\infty} \binom{k-1}{r-1} p^r q^{k-r} = p^r \sum_{k=r}^{\infty} \binom{k-1}{r-1} q^{k-r} = p^r (1-q)^{-r}$$

lo cual obviamente es igual a 1. La última igualdad resulta del desarrollo en serie de

$$(1-q)^{-r} = \sum_{n=0}^{\infty} \binom{-r}{n} (-q)^n,$$

es igual

$$\sum_{k=r}^{\infty} \binom{k-1}{r-1} q^{k-r}$$

después de algunas simplificaciones algebraicas y recordando la definición del coeficiente binomial (generalizado) (ver la observación antes del ejemplo 2.7). Debido al exponente negativo  $(-r)$  en la expresión anterior esta distribución se llama distribución binomial negativa. Para calcular  $E(Y)$  y  $V(Y)$  podemos proceder directamente, tratando de calcular las diversas sumas, o bien podemos proceder de la siguiente manera.

Sea

$Z_1$  = número de repeticiones necesarias hasta incluir la primera ocurrencia de  $A$ .

$Z_2$  = número de repeticiones necesarias entre la primera ocurrencia de  $A$  hasta incluir la segunda ocurrencia de  $A$ .

$\vdots$

$Z_r$  = número de repeticiones necesarias entre la  $(r-1)$  ocurrencia hasta incluir la  $r$ -ésima ocurrencia de  $A$ .

Así vemos que todas las  $Z_i$  son variables aleatorias independientes, que tiene cada una, una distribución geométrica. También,  $Y = Z_1 + \dots + Z_r$ . Por tanto usando el teorema 8.3, tenemos el siguiente teorema.

**Teorema 8.5.** Si  $Y$  tiene una distribución de Pascal dada por la ecuación (8.7), luego

$$E(Y) = r/p, \quad V(Y) = rq/p^2. \quad (8.8)$$

**EJEMPLO 8.11.** La probabilidad de que un experimento sea exitoso es 0,8. Si el experimento se repite hasta que ocurran cuatro resultados exitosos, ¿cuál es el número esperado de repeticiones necesarias? De lo anterior, tenemos  $E(\text{número de repeticiones}) = 4/0,8 = 5$ .

### 8.6 Relación entre las distribuciones binomial y de Pascal

Sea  $X$  una distribución binomial con parámetros  $n$  y  $p$ . (Es decir,  $X$  = número de éxitos en  $n$  ensayos de Bernoulli con  $P(\text{éxito}) = p$ ). Sea  $Y$  una distribución de Pascal con parámetros  $r$  y  $p$ . (Es decir,  $Y$  = número de ensayos de Bernoulli necesarios para obtener  $r$  éxitos con  $P(\text{éxito}) = p$ .) Por tanto se establece la siguiente relación:

$$(a) P(Y \leq n) = P(X \geq r),$$

$$(b) P(Y > n) = P(X < r).$$

*Demostración:* (a) Si hay  $r$  o más éxitos en los primeros  $n$  ensayos, entonces es necesario  $n$  o menos ensayos para obtener los primeros  $r$  éxitos.

(b) Si hay menos que  $r$  éxitos en los primeros  $n$  ensayos entonces se necesitan más de  $n$  ensayos para obtener  $r$  éxitos.

**Observaciones:** (a) Las propiedades anteriores hacen posible el empleo de la distribución binomial tabulada para evaluar probabilidades asociadas con la distribución de Pascal. Por ejemplo, supóngase que deseamos calcular la probabilidad de que más de 10 repeticiones sean necesarias para obtener el tercer éxito cuando  $p = P(\text{éxito}) = 0,2$ . Tenemos, usando la notación anterior para  $X$  y  $Y$ ,

$$P(Y > 10) = P(X < 3) = \sum_{k=0}^2 \binom{10}{k} (0,2)^k (0,8)^{10-k} = 0,678$$

(de la tabla del apéndice).

(b) Comparemos brevemente las distribuciones binomial y de Pascal. En cada uno de los casos, nos interesan los ensayos repetidos de Bernoulli. La distribución binomial aparece cuando consideramos un número fijo (digamos  $n$ ) de tales ensayos y estamos interesados en el número de éxitos que ocurren. La distribución de Pascal se encuentra cuando prefijamos el número de éxitos que debemos obtener y luego anotamos el número de ensayos de Bernoulli necesarios. Esto es particularmente útil para un problema estadístico que presentaremos con más detalles más tarde (ver ejemplo 14.1).

## 8.7 La distribución hipergeométrica

Supóngase que tenemos un lote de  $N$  artículos, de los cuales  $r$  son defectuosos y  $(N - r)$  no son defectuosos. Supóngase que escogemos, al azar,  $n$  artículos del lote ( $n \leq N$ ), sin sustitución. Sea  $X$  el número de artículos defectuosos encontrados. Puesto que  $X = k$  si y sólo si obtenemos exactamente  $k$  artículos defectuosos (de los  $r$  defectuosos del lote) y exactamente  $(n - k)$  no defectuosos [de los  $(N - r)$  no defectuosos del lote], tenemos

$$P(X = k) = \frac{\binom{r}{k} \binom{N-r}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, \dots \quad (8.9)$$

Se dice que una variable aleatoria discreta que tiene la distribución de probabilidades de la ecuación (8.9) tiene una *distribución hipergeométrica*.

**Observación:** puesto que  $\binom{r}{k} = 0$  cada vez que  $k > r$ , si  $a$  y  $b$  son enteros negativos, podemos definir las probabilidades anteriores para todo  $k = 0, 1, 2, \dots$ . Obviamente no podemos obtener más que  $r$  defectuosos, pero la probabilidad cero será asignada a ese suceso según ecuación (8.9).

**EJEMPLO 8.12.** Se embarcan motores eléctricos pequeños en lotes de 50. Antes de que tal cargamento sea aceptado, un inspector elige 5 motores y los inspecciona. Si ninguno de los motores probados es defectuoso, el lote es aceptado. Si se encuentra que uno o más son defectuosos, se inspecciona el cargamento completo. Supongamos que, en realidad, hay tres motores defectuosos en el lote. ¿Cuál es la probabilidad de que sea necesaria una inspección de 100 por ciento?

Si hacemos que  $X$  sea el número de motores defectuosos encontrados, se necesitará una inspección de 100 por ciento si y sólo si  $X \geq 1$ . Luego,

$$P(X \geq 1) = 1 - P(X = 0) = 1 - \frac{\binom{3}{0} \binom{47}{5}}{\binom{50}{5}} = 0,28.$$

**Teorema 8.6.** Sea  $X$  una distribución hipergeométrica dada por la ecuación (8.9). Sea  $p = r/N$ ,  $q = 1 - p$ . Luego tenemos

$$(a) E(X) = np;$$

$$(b) V(X) = npq \frac{N-n}{N-1};$$

$$(c) P(X = k) \simeq \binom{n}{k} p^k (1-p)^{n-k},$$

para  $N$  grande.

**Demostración:** dejaremos los detalles de la demostración al lector. (Ver problema 8.19.)

**Observación:** la propiedad (c) del teorema 8.6 establece que si el tamaño  $N$  del lote es suficientemente grande, la distribución de  $X$  puede ser aproximada por la distribución binomial. Esto es razonablemente intuitivo. La distribución binomial se aplica cuando muestreamos con sustitución (puesto que en ese caso la probabilidad de obtener un artículo defectuoso permanece constante), mientras que la distribución hipergeométrica se aplica cuando muestreamos sin sustitución. Si el tamaño del lote es grande, no sería mucha la diferencia si un artículo en particular es devuelto o no al lote antes de escoger el siguiente. La propiedad (c) del teorema 8.6 es simplemente una expresión matemática de ese hecho. Nótese también que el valor esperado de una variable aleatoria hipergeométrica  $X$  es el mismo que el de la variable aleatoria correspondiente distribuida binomialmente, mientras que la varianza de  $X$  es un poco más pequeña que la correspondiente en el caso binomial. El «término de corrección»  $(N-n)/(N-1)$  es aproximadamente igual a 1, para un  $N$  grande.

Podemos ilustrar el significado de (c) con el siguiente ejemplo sencillo. Supóngase que queremos evaluar  $P(X = 0)$ .

Para  $n = 1$ , obtenemos de la distribución hipergeométrica,  $P(X = 0) = (N - r)/N = 1 - r/N = q$ . De la distribución binomial obtenemos directamente  $P(X = 0) = q$ . Por tanto estas respuestas son las mismas, como deberían ser, además, para  $n = 1$ .

Para  $n = 2$ , obtenemos de la distribución hipergeométrica

$$P(X = 0) = \frac{N-r}{N} \frac{N-r-1}{N-1} = \left(1 - \frac{r}{N}\right) \left(1 - \frac{r}{N-1}\right).$$

De la distribución binomial obtenemos  $P(X = 0) = q^2$ . Debe observarse que  $(1 - r/N) = q$ , mientras que  $[1 - r/(N-1)]$  es casi igual a  $q$ .

En general, la aproximación de la distribución hipergeométrica mediante la distribución binomial es muy buena si  $n/N \leq 0,1$ .

## 8.8 La distribución multinomial

Finalmente, consideremos una variable aleatoria discreta importante de mayor dimensión, que puede ser considerada como una generalización de la distribución binomial. Consideremos un experimento  $\varepsilon$ , su espacio muestral  $S$ , y una

partición de  $S$  en  $k$  sucesos mutuamente excluyentes  $A_1, \dots, A_k$ . (Es decir, cuando se efectúa  $\varepsilon$  uno y sólo uno de los sucesos  $A_i$  ocurre). Considérese  $n$  repeticiones independientes de  $\varepsilon$ . Sea  $p_i = P(A_i)$  y supóngase que  $p_i$  permanece constante durante todas las repeticiones. Evidentemente tenemos  $\sum_{i=1}^k p_i = 1$ . Definamos las variables aleatorias  $X_1, \dots, X_k$  como sigue.

$X_i$  es el número de veces que  $A_i$  ocurre entre las  $n$  repeticiones de  $\varepsilon$ ,  $i = 1, \dots, k$ .

Las  $X_i$  no son variables aleatorias independientes puesto que  $\sum_{i=1}^k X_i = n$ . Entonces tan pronto como el valor de cualquiera de las  $(k-1)$  variables aleatorias es conocido, se determina el valor de la otra. Tenemos el resultado siguiente.

**Teorema 8.7.** Si  $X_i$ ,  $i = 1, 2, \dots, k$ , están definidas como antes, tenemos

$$P(X_1 = n_1, X_2 = n_2, \dots, X_k = n_k) = \frac{n!}{n_1! n_2! \cdots n_k!} p_1^{n_1} \cdots p_k^{n_k}, \quad (8.10)$$

en donde  $\sum_{i=1}^k n_i = n$ .

*Demostración:* el argumento es idéntico al utilizado para establecer las probabilidades binomiales. Simplemente debemos observar que el número de maneras de agrupar  $n$  objetos,  $n_1$  de los cuales son de una clase,  $n_2$  de los cuales son de segunda clase,  $\dots$ ,  $n_k$  de los cuales son de una  $k$ -ésima clase está dado por

$$\frac{n!}{n_1! \cdots n_k!}.$$

*Observaciones:* (a) Si  $k = 2$  lo anterior se reduce a la distribución binomial. En este caso designamos los dos sucesos posibles «éxito» y «fracaso».

(b) La distribución anterior se conoce como la *distribución multinomial de probabilidades*. Recordemos que los términos de la distribución binomial se obtuvieron del desarrollo de la expresión binomial  $[p + (1-p)]^n = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k}$ . De una manera análoga, las probabilidades anteriores pueden obtenerse de un desarrollo de la expresión multinomial  $(p_1 + p_2 + \cdots + p_k)^n$ .

**Teorema 8.8.** Suponiendo que  $(X_1, \dots, X_k)$  tiene una distribución binomial dada por la ecuación (8.10). Entonces

$$E(X_i) = np_i \quad \text{y} \quad V(X_i) = np_i(1-p_i), \quad i = 1, 2, \dots, k.$$

*Demostración:* ésta es una consecuencia inmediata de la observación que cada  $X_i$  como se definió anteriormente tiene una distribución binomial con probabilidad de éxito (es decir, la ocurrencia de  $A_i$ ) igual a  $p_i$ .

**EJEMPLO 8.13.** Se fabrica una barra de un largo específico. Suponiendo que el largo verdadero  $X$  (pulgadas) es una variable aleatoria distribuida uniformemente en  $[10, 12]$ . Supóngase que sólo es de interés saber si ha ocurrido uno de los tres sucesos siguientes:

$$A_1 = \{X < 10.5\}, \quad A_2 = \{10.5 \leq X \leq 11.8\}, \quad \text{y} \quad A_3 = \{X > 11.8\}.$$

Tenemos

$$p_1 = P(A_1) = 0.25, \quad p_2 = P(A_2) = 0.65, \quad \text{y} \quad p_3 = P(A_3) = 0.1.$$

Así si se fabrican 10 de tales barras, la probabilidad de obtener exactamente 5 barras de longitud menor que 10,5 pulgadas y exactamente 2 de longitud mayor que 11,8 pulgadas está dada por

$$\frac{10!}{5!3!2!} (0.25)^5 (0.65)^3 (0.1)^2.$$

## PROBLEMAS

8.1. Si  $X$  tiene una distribución de Poisson con parámetro  $\beta$ , y si  $P(X = 0) = 0.2$  calcular  $P(X > 2)$ .

8.2. Sea  $X$  una distribución de Poisson con parámetro  $\lambda$ . Encontrar el valor de  $k$  para el cual  $P(X = k)$  es la mayor. [Indicación: comparar  $P(X = k)$  con  $P(X = k-1)$ .]

8.3. (Este problema es tomado de *Probability and Statistical Inference for Engineers* por Derman y Klein, Oxford University Press, Londres, 1959.) El número de buques tanques, digamos  $N$ , que llegan cada día a cierta refinería tiene una distribución de Poisson con parámetro  $\lambda = 2$ . Las actuales instalaciones portuarias pueden despachar tres buques al día. Si más de tres buques tanques llegan en un día, los que están en exceso deben enviarse a otro puerto.

- En un día determinado, ¿cuál es la probabilidad de tener que hacer salir buques tanques?
- ¿En cuánto deben aumentarse las instalaciones actuales para permitir la atención a todos los buques tanques aproximadamente el 90 por ciento de los días?
- ¿Cuál es el número esperado de buques tanques que llegan al día?
- ¿Cuál es el número más probable de buques tanques que llegan diariamente?
- ¿Cuál es el número esperado de buques tanques atendidos diariamente?
- ¿Cuál es el número esperado de buques tanques devueltos diariamente?

8.4. Supóngase que la probabilidad de que un artículo producido por una máquina especial sea defectuoso es igual a 0.2. Si 10 artículos producidos, se seleccionan al azar, ¿cuál es la probabilidad de que no se encuentre más de un artículo defectuoso? Use las distribuciones binomial y de Poisson y compare las respuestas.

8.5. Una compañía de seguros ha descubierto que sólo alrededor del 0.1 por ciento de la población tiene cierto tipo de accidente cada año. Si los 10.000 asegurados fueran seleccionados aleatoriamente en la población, ¿cuál será la probabilidad de que no más de 5 de estos clientes tengan un accidente de ese tipo el próximo año?

8.6. Supóngase que  $X$  tiene una distribución de Poisson. Si

$$P(X = 2) = \frac{2}{3}P(X = 1),$$

calcular  $P(X = 0)$  y  $P(X = 3)$ .

8.7. Un productor de películas produce 10 rollos de una película especialmente sensible cada año. Si la película no se vende dentro del año, debe descartarse. Experiencias pasadas indican que  $D$ , la demanda (pequeña) para la película es una variable aleatoria distribuida de Poisson con parámetro 8. Si se obtiene una utilidad de \$ 7 en cada rollo vendido, mientras que ocurre una pérdida de \$ 3 en cada rollo que debe ser descartado, calcular la utilidad esperada que el fabricante puede obtener con los 10 rollos que produce.

8.8. Supóngase que una fuente radiactiva emite partículas y que el número de tales partículas emitidas durante el período de una hora tiene una distribución de Poisson con parámetro  $\lambda$ . Se emplea un instrumento para contar y para anotar el número de las partículas emitidas. Si más de 30 partículas llegan durante cualquier período de una hora, el instrumento para anotar es incapaz de controlar el exceso y simplemente anota 30. Si  $Y$  es la variable aleatoria definida como el número de partículas anotadas por el instrumento que cuenta, obtenga la distribución de probabilidades de  $Y$ .

8.9. Supóngase que una fuente radiactiva emite partículas y que el número de las mismas emitidas durante un período de una hora tiene una distribución de Poisson con parámetro  $\lambda$ . Consideremos que el instrumento para contar esas emisiones falla ocasionalmente en anotar una partícula emitida. Supóngase, específicamente, que cualquier partícula emitida tiene una probabilidad  $p$  de ser anotada.

(a) Si  $Y$  está definida como el número de partículas anotadas, ¿cuál es una expresión para la distribución de probabilidades de  $Y$ ?

(b) Calcule  $P(Y = 0)$  si  $\lambda = 4$  y  $p = 0,9$ .

8.10. Supóngase que un depósito contiene 10.000 partículas. La probabilidad de que una de esas partículas salga del depósito es igual a 0,0004. ¿Cuál es la probabilidad de que ocurran más de 5 salidas? (Puede suponerse que las diversas salidas son independientes unas de otras.)

8.11. Supóngase que un libro de 585 páginas contiene 43 errores tipográficos. Si esos errores están distribuidos aleatoriamente en el libro, ¿cuál es la probabilidad de que 10 páginas, seleccionadas al azar, estén libres de errores? [Indicación: suponga que  $X$  = número de errores por página tiene una distribución de Poisson.]

8.12. Se observa una fuente radiactiva durante 7 intervalos de 10 segundos de duración cada uno y se cuenta el número de partículas emitidas durante cada período. Suponiendo que el número de partículas emitidas, digamos  $X$ , durante cada período observado tiene una distribución de Poisson con parámetro 5,0. (Es decir, las partículas son emitidas a razón de 0,5 partículas por segundo.)

(a) ¿Cuál es la probabilidad de que en cada uno de los 7 intervalos de tiempo, sean emitidas 4 o más partículas?

(b) ¿Cuál es la probabilidad de que al menos en uno de los 7 intervalos de tiempo, sean emitidas 4 o más partículas?

8.13. Se ha encontrado que el número de fallas de transistores en un computador electrónico en cualquier período de una hora puede considerarse como una variable aleatoria que tiene una distribución de Poisson con parámetro 0,1. (Es decir, en promedio hay una falla de un transistor cada 10 horas). Se inicia cierto proceso que necesita 20 horas de tiempo de cómputo.

(a) Encuentre la probabilidad de que el proceso anterior pueda ser completado exitosamente sin una falla. (Se supone que la máquina llega a ser inoperante sólo si fallan 3 o más transistores).

(b) Lo mismo que en (a) excepto que la máquina llega a ser inoperante si fallan 2 o más transistores.

8.14. Al formar números binarios con  $n$  dígitos, la probabilidad de que aparezca un dígito incorrecto es, digamos, 0,002. Si los errores son independientes, ¿cuál es la probabilidad de encontrar cero, uno o más de un dígito incorrecto en un número binario de 25 dígitos? Si el computador forma  $10^6$  de tales números de 25 dígitos por segundo, ¿cuál es la probabilidad de que se forme un número incorrecto durante cualquier período de un segundo?

8.15. Se emplean dos procedimientos independientes en la operación de lanzamiento de cohetes. Supóngase que cada uno de los procedimientos se continúa hasta que se produce un lanzamiento exitoso. Se supone que al usar el procedimiento I,  $P(S)$ , la probabilidad de un lanzamiento exitoso es igual a  $p_1$ , mientras que para el procedimiento II,  $P(S) = p_2$ . Se supone además, que cada semana se hace un intento con cada uno de los dos métodos. Representemos con  $X_1$  y  $X_2$  al número de semanas necesarias para obtener un lanzamiento exitoso por medio de I y II respectivamente. (Luego  $X_1$  y  $X_2$  son variables aleatorias independientes, que tiene cada una una distribución geométrica). Sea  $W$  el mínimo ( $X_1, X_2$ ) y sea  $Z$  el máximo ( $X_1, X_2$ ). Por tanto  $W$  representa al número de semanas necesarias para obtener un lanzamiento exitoso mientras que  $Z$  representa el número de semanas necesarias para obtener lanzamientos exitosos con ambos procedimientos. (Luego si el procedimiento I resulta en  $\bar{S}\bar{S}\bar{S}\bar{S}$ , mientras que el procedimiento II resulta en  $SSS$ , tenemos  $W = 3$ ,  $Z = 4$ ).

(a) Obtener una expresión para la distribución de probabilidades de  $W$ . [Indicación: exprese en función de  $X_1$  y  $X_2$ , el suceso  $\{W = k\}$ .]

(b) Obtener una expresión para la distribución de probabilidades de  $Z$ .

(c) Escribir nuevamente las expresiones anteriores si  $p_1 = p_2$ .

8.16. Se arman cuatro componentes en un solo aparato. Las componentes originan fuentes independientes y  $p_i = P(i\text{-ésima componente es defectuosa})$ ,  $i = 1, 2, 3, 4$ .

(a) Obtener una expresión de la probabilidad para que el aparato completo funcione.

(b) Obtener una expresión de la probabilidad para que al menos tres componentes funcionen.

(c) Si  $p_1 = p_2 = 0,1$  y  $p_3 = p_4 = 0,2$ , calcule la probabilidad de que funcionen exactamente dos componentes.

8.17. Un mecánico mantiene un gran número de arandelas en un depósito. El 50 por ciento de esas arandelas son de  $\frac{1}{4}$  pulgada de diámetro, el 30 por ciento son de  $\frac{1}{8}$  pulgada de diámetro, y el 20 por ciento restante con  $\frac{3}{8}$  pulgada de diámetro. Se supone que se eligen 10 arandelas.

(a) ¿Cuál es la probabilidad de que haya exactamente cinco arandelas de  $\frac{1}{4}$  pulgada, cuatro de  $\frac{1}{8}$  de pulgada, y una de  $\frac{3}{8}$  de pulgada?

(b) ¿Cuál es la probabilidad de que sólo haya dos clases de arandelas entre las elegidas?

(c) ¿Cuál es la probabilidad de que las tres clases de arandelas estén entre las elegidas?

(d) ¿Cuál es la probabilidad de que haya tres de una clase, tres de otra clase, y cuatro de la tercera clase en una muestra de 10?

8.18. Demostrar el teorema 8.4.

8.19. Demostrar el teorema 8.6.

8.20. El número de partículas emitidas por una fuente radiactiva durante un período específico es una variable aleatoria con una distribución de Poisson. Si la probabilidad de ninguna emisión es igual a  $\frac{1}{3}$ , ¿cuál es la probabilidad de que ocurran 2 o más emisiones?